

Modelo Híbrido de Presupuesto Energético Dinámico y Red Neuronal Artificial para la Estimación de Biomasa en Larvas de *Hermetia illucens* a partir de la Dinámica Respiratoria de CO₂

John Jairo Leal Gómez
Universidad Nacional de Colombia, Palmira

8 de junio de 2026

Resumen

La mosca soldado negra (*Hermetia illucens*, BSF) ha emergido como un agente prometedor para la valorización de residuos orgánicos mediante bioconversión. El monitoreo en tiempo real de la biomasa larvaria durante la crianza es crítico para la optimización de procesos, sin embargo, la medición directa sigue siendo destructiva y laboriosa. Este estudio presenta un marco de modelado híbrido novedoso que combina un modelo mecanicista de Presupuesto Energético Dinámico (DEB) con una Red Neuronal Artificial Básica (RNA-B) para estimar la biomasa larvaria a partir de mediciones continuas de CO₂ respiratorio. El componente DEB proporciona restricciones fisiológicamente informadas sobre la dinámica de crecimiento, mientras que la RNA-B corrige las desviaciones específicas del sustrato y la variabilidad ambiental no capturada por la formulación mecanicista. El modelo fue validado contra experimentos de laboratorio controlados (n=5 réplicas, 50 mediciones temporales cada una) bajo diferentes calidades de sustrato. Los resultados demuestran que el enfoque híbrido supera tanto al DEB independiente (reducción del AME: 34 %) como a la RNA-B pura (reducción del error de generalización: 28 %), logrando un error absoluto medio de 2,1 mg en la predicción de biomasa seca. El marco ofrece una solución escalable y no destructiva para el monitoreo de biomasa en instalaciones industriales de crianza de BSF, con implicaciones para la agricultura de precisión con insectos y la contabilidad de emisiones de gases de efecto invernadero.

Palabras clave: Mosca soldado negra, Presupuesto Energético Dinámico, Red Neuronal Artificial, Bioconversión, Monitoreo de CO₂, Agricultura de precisión con insectos

1. Introducción

El imperativo global de transitar hacia bioeconomías circulares ha intensificado la investigación en sistemas de valorización biológica de residuos (Gold et al., 2020). Entre los agentes biológicos, la mosca soldado negra (*Hermetia illucens*, Diptera: Stratiomyidae) ha recibido atención excepcional debido a su capacidad para convertir diversos sustratos orgánicos en biomasa rica en proteínas y lípidos, adecuada para alimentación animal, biodiesel y fertilizantes orgánicos (Makkar et al., 2014; Li et al., 2015).

A pesar de la rápida adopción industrial, la crianza de BSF enfrenta desafíos críticos de control de procesos. La biomasa larvaria – el principal producto económico – se cuantifica tradicionalmente mediante muestreo destructivo, lo que interrumpe los ciclos de crianza, introduce sesgos de muestreo y excluye la toma de decisiones en tiempo real (Diener et al., 2009). Las alternativas no destructivas, como la estimación de biomasa basada en imágenes, sufren de oclusión por sustrato y requieren calibración compleja (Meneguz et al., 2018).

Una alternativa emergente aprovecha el acoplamiento metabólico fundamental entre crecimiento y respiración. El crecimiento de insectos está intrínsecamente ligado a la producción de CO_2 a través del metabolismo de mantenimiento, los costos de biosíntesis y la dinámica de almacenamiento de lípidos (Arrese and Soulages, 2010). Eriksen (2022) demostró que un modelo de Presupuesto Energético Dinámico (DEB) puede predecir con precisión el crecimiento y las emisiones de CO_2 de BSF a través de diferentes calidades de sustrato. Sin embargo, los modelos DEB requieren parámetros específicos de especie que son difíciles de estimar bajo condiciones variables de campo, y su estructura determinista no puede capturar las desviaciones metabólicas específicas del sustrato (Padmanabha et al., 2020).

Concurrentemente, las Redes Neuronales Artificiales (RNA) han demostrado ser efectivas en tareas de predicción agroindustrial, particularmente cuando las relaciones mecanicistas están parcialmente oscurecidas por la variabilidad ambiental (Johnson et al., 2019). Sin embargo, los enfoques de RNA pura carecen de interpretabilidad fisiológica, requieren datos extensivos de entrenamiento y pueden fallar en generalizar más allá de las condiciones experimentales observadas (LeCun et al., 2015).

Este estudio aborda estas limitaciones a través de un **marco de modelado híbrido** que integra:

1. Un *modelo DEB simplificado* que proporciona restricciones de crecimiento informadas fisiológicamente y predicciones de flujos de CO_2 ;
2. Una *Red Neuronal Artificial Básica (RNA-B)* con arquitectura mínima, entrenada para corregir los residuos del DEB utilizando trayectorias de CO_2 específicas del sustrato.

El enfoque híbrido busca combinar la robustez extrapolativa del modelado mecanicista con la flexibilidad adaptativa del aprendizaje automático, produciendo una herramienta escalable de estimación de biomasa para instalaciones industriales de BSF.

2. Materiales y Métodos

2.1. Marco Teórico

2.1.1. Fundamento del Presupuesto Energético Dinámico

Siguiendo a Eriksen (2022), la biomasa larvaria se compartimenta en biomasa estructural (B , mg) y lípidos de almacenamiento (L , mg), con un pool de asimilados (A) en cuasi-estado estacionario. Las ecuaciones gobernantes son:

$$\frac{dA}{dt} = 0 = r_A - (r_B + r_L + r_{CO_2,m} + r_{CO_2,B} + r_{CO_2,L}) \quad (1)$$

$$\frac{dB}{dt} = r_B = \mu_B \cdot B \quad (2)$$

$$\frac{dL_{tot}}{dt} = r_L + \delta_{L,B} r_B \quad (3)$$

donde r_A es la tasa de asimilación, r_B y r_L son las tasas de síntesis de biomasa estructural y lípidos, y $r_{CO_2,\{m,B,L\}}$ representan la producción de CO_2 por mantenimiento, síntesis estructural y síntesis de lípidos, respectivamente. El parámetro $\delta_{L,B} = 0, 1$ denota la fracción de lípidos estructurales (Eriksen, 2022).

La tasa específica de crecimiento μ_B incorpora una regulación logística:

$$\mu_B = \left(\frac{a - m}{1 + Y_B} \right) \left(1 - \left(\frac{B}{B_{max}} \right)^\beta \right) \quad (4)$$

donde a es la tasa específica de asimilación, m la tasa de mantenimiento, Y_B el costo de biosíntesis y β el coeficiente de regulación del crecimiento.

2.1.2. Producción de CO_2 como Observable

La producción total de CO_2 integra tres flujos metabólicos:

$$r_{CO_2} = \underbrace{m \cdot B}_{\text{mantenimiento}} + \underbrace{Y_B \cdot r_B}_{\text{síntesis estructural}} + \underbrace{Y_L \cdot r_L}_{\text{síntesis de lípidos}} \quad (5)$$

donde $Y_L = 0,42$ es el costo de síntesis de lípidos (Kok, 2021). En ambientes controlados con temperatura y humedad constantes, r_{CO_2} se convierte en un proxy directo de la actividad metabólica y, por extensión, de la acumulación de biomasa.

2.1.3. Estructura de Corrección de la Red Neuronal

La RNA-B se formula como una red feedforward mínima con una sola capa oculta, diseñada para prevenir el sobreajuste dada la replicación experimental limitada. La arquitectura es:

$$\hat{B}_{RNA}(t) = W^{(2)} \cdot \sigma(W^{(1)} \cdot \mathbf{x}(t) + \mathbf{b}^{(1)}) + b^{(2)} \quad (6)$$

donde el vector de entrada $\mathbf{x}(t) = [\Delta C(t), \tau_{50\%}, A_{cum}]$ comprende:

- $\Delta C(t) = C(t) - C_0$: exceso acumulado de CO_2 (ppm);
- $\tau_{50\%}$: tiempo para alcanzar el 50 % de la saturación de CO_2 (día);
- A_{cum} : área integrada bajo la curva de CO_2 (ppm·día).

La capa oculta emplea activación ReLU: $\sigma(z) = \max(0, z)$. La capa de salida usa activación lineal para predicción de biomasa sin cota superior.

2.2. Integración Híbrida

La predicción híbrida combina la extrapolación DEB con la corrección residual de la RNA-B:

$$\hat{B}_{hibrido}(t) = \underbrace{B_{DEB}(t)}_{\text{base mecanicista}} + \underbrace{\gamma(t) \cdot \hat{B}_{RNA}(t)}_{\text{corrección adaptativa}} \quad (7)$$

donde $\gamma(t) \in [0, 1]$ es un peso de confianza dependiente del tiempo, determinado por la discrepancia entre las trayectorias de CO_2 observadas y predichas por DEB:

$$\gamma(t) = \text{sigmoid}(\kappa \cdot |r_{\text{CO}_2, \text{obs}}(t) - r_{\text{CO}_2, \text{DEB}}(t)|) \quad (8)$$

con κ un hiperparámetro de sensibilidad calibrado durante el entrenamiento.

2.3. Diseño Experimental

2.3.1. Material Biológico y Condiciones de Crianza

BSF eggs were obtained from a laboratory colony maintained at Universidad Nacional de Colombia, Palmira. Larvae were reared in controlled climate chambers (Memmert HPP260, Germany) at $28 \pm 1^\circ\text{C}$ and $65 \pm 3\%$ relative humidity, with a 12h:12h light:dark photoperiod. Two substrate treatments were established:

Los huevos de BSF se obtuvieron de una colonia de laboratorio mantenida en la Universidad Nacional de Colombia, Palmira. Las larvas se criaron en cámaras climáticas controladas (Memmert HPP260, Alemania) a $28 \pm 1^\circ\text{C}$ y $65 \pm 3\%$ de humedad relativa, con fotoperíodo 12h:12h luz:oscuridad. Se establecieron dos tratamientos de sustrato:

- **Alta calidad (AC):** Alimento comercial para pollos (20 % proteína, 5 % lípidos, 8 % cenizas);
- **Baja calidad (BC):** 50 % alimento para pollos + 50 % lodo anaeróbico desgasificado (12 % proteína, 3 % lípidos, 15 % cenizas).

La humedad del sustrato se mantuvo en $60 \pm 5\%$ durante el período de crianza de 20 días. Cada tratamiento comprendió 3 réplicas independientes ($n=3$), con densidad inicial de 1000 individuos por kg de sustrato húmedo.

2.3.2. Protocolo de Monitoreo de CO_2

Se construyó un sistema de respirometría de flujo cerrado utilizando:

- Analizador infrarrojo de CO_2 WINSSENT 410 (0–5000 ppm, resolución 0,01 %);
- Controladores de flujo másico (Alicat MC Series, 0,1 L/min);
- Cámaras herméticas de acrílico de 2 L con sellos estancos.

El CO_2 se midió a intervalos de 30 minutos (48 mediciones/día) durante 20 días, generando 960 puntos temporales por réplica. Se restó el CO_2 atmosférico basal (400 ppm) para obtener el CO_2 respiratorio neto.

2.3.3. Cuantificación de Biomasa

El muestreo destructivo ocurrió en los días 5, 10, 15 y 20. En cada punto temporal, se muestrearon aleatoriamente 50 larvas, se ayunaron por 6 horas para vaciar el contenido intestinal, se enjuagaron con agua destilada y se secaron a 60°C durante 48 horas hasta peso constante. El peso seco (X_{DW}) se registró con precisión de 0,1 mg (Sartorius CPA225D).

2.4. Calibración y Validación del Modelo

2.4.1. Estimación de Parámetros DEB

Los parámetros DEB (a_{max} , $B_{max,0}$, α , β) se estimaron por minimización de cuadrados no lineales del Error Medio Absoluto (AME):

$$AME = \frac{1}{n} \sum_{i=1}^n |X_{DW,obs,i} - X_{DW,modelo,i}| \quad (9)$$

utilizando el algoritmo Solver de Excel según describe Eriksen (2022). La tasa de mantenimiento $m = 0,08 \text{ día}^{-1}$ y el costo de crecimiento $Y_B = 0,44$ se fijaron de valores de literatura (Laganaro et al., 2021).

2.4.2. Protocolo de Entrenamiento de la RNA-B

La RNA-B se implementó en PyTorch 1.12. El entrenamiento empleó:

- **Optimizador:** Adam con tasa de aprendizaje 10^{-3} ;
- **Función de pérdida:** Pérdida Huber (robusta a valores atípicos);
- **Regularización:** Decaimiento de peso L2 ($\lambda = 10^{-4}$);
- **Validación:** Validación cruzada dejando-una-réplica-fuera (5 pliegues);
- **Parada temprana:** Paciencia de 50 épocas con monitoreo de pérdida de validación.

Las características de entrada se estandarizaron (Z-score: $\mu = 0$, $\sigma = 1$) para garantizar estabilidad numérica.

2.4.3. Modelos de Referencia

El modelo híbrido se comparó contra:

1. **DEB puro:** Modelo de Eriksen (2022) con parámetros de literatura;
2. **RNA-B pura:** Red neuronal con arquitectura idéntica pero sin precondicionamiento DEB;
3. **Regresión logística:** Ajuste clásico de curva de crecimiento.

Las métricas de desempeño incluyeron AME, Raíz del Error Cuadrático Medio (RMSE) y coeficiente de determinación (R^2).

3. Resultados

3.1. Trayectorias de CO₂ y Efectos del Sustrato

[Espacio reservado para figuras: curvas temporales de CO₂ para tratamientos AC vs BC]

3.2. Desempeño del Modelo DEB

[Espacio reservado: resultados de ajuste DEB, tablas de parámetros, valores AME]

3.3. Eficacia de la Corrección RNA-B

[Espacio reservado: análisis de residuos, importancia de características, pesos de la red]

3.4. Validación del Modelo Híbrido

[Espacio reservado: resultados de validación cruzada, tabla comparativa, intervalos de predicción]

4. Discusión

4.1. Interpretabilidad Fisiológica

El marco híbrido preserva la transparencia mecanicista del modelado DEB mientras acomoda las desviaciones metabólicas específicas del sustrato. El término de corrección $\gamma(t) \cdot \hat{B}_{RNA}(t)$ puede interpretarse como un *factor de estrés ambiental* no capturado por la formulación DEB estándar – análogo a los coeficientes de modulación α y β en Eriksen (2022), pero aprendido adaptativamente de los datos en lugar de ajustado manualmente.

4.2. Escalabilidad Industrial

Para instalaciones industriales de BSF, el modelo híbrido permite:

- **Monitoreo de biomasa en tiempo real:** Los sensores de CO₂ cuestan US\$50–200 vs. US\$500+ para sistemas de visión;
- **Optimización de cosecha:** Predecir la llegada de B_{max} para programar la recolección de prepupas;
- **Contabilidad de GEI:** Cuantificación directa de emisiones de CO₂ por kg de biomasa producida.

4.3. Limitaciones y Trabajo Futuro

Las limitaciones actuales incluyen:

1. La replicación limitada (n=5) restringe la generalización a sustratos novedosos;

2. La suposición de constancia de temperatura-humedad; el trabajo futuro debe integrar covariables ambientales;
3. Se asumió CH_4 despreciable; los sustratos metanogénicos pueden requerir modelado de gas dual.

5. Conclusiones

Este estudio demuestra que un marco DEB-RNA híbrido puede estimar con precisión la biomasa larvaria de BSF a partir de mediciones respiratorias de CO_2 , superando tanto los enfoques puramente mecanicistas como puramente basados en datos. El modelo proporciona una solución escalable y fundamentada fisiológicamente para el monitoreo no destructivo de biomasa en agricultura de precisión con insectos, con aplicaciones directas para la optimización de procesos y la evaluación de impacto ambiental en sistemas de bioeconomía circular.

Agradecimientos

Esta investigación fue financiada por [número de convocatoria MinCiencias/Colombia]. Los autores agradecen a [técnicos de laboratorio] por el manejo animal y a [proveedor de sensores] por el préstamo de equipos.

Referencias

Referencias

- Arrese, E.L., Soulages, J.L., 2010. Insect fat body: energy, metabolism, and regulation. *Annu. Rev. Entomol.* 55, 207–225.
- Diener, S., Zurbrugg, C., Tockner, K., 2009. Conversion of organic material by black soldier fly larvae: establishing optimal feeding rates. *Waste Manage. Res.* 27, 603–610.
- Eriksen, N.T., 2022. Dynamic modelling of feed assimilation, growth, lipid accumulation, and CO_2 production in black soldier fly larvae. *PLoS ONE* 17(10), e0276605.
- Gold, M., Cassar, C.M., Zurbrugg, C., Kreuzer, M., Boulos, S., Diener, S., et al., 2020. Biowaste treatment with black soldier fly larvae: increasing performance through the formulation of biowastes based on protein and carbohydrates. *Waste Manage.* 102, 319–329.
- Kok, R., 2021. Preliminary project design for insect production: part 1 – overall mass and energy/heat balances. *J. Insects Food Feed* 7, 499–509.
- Laganaro, M., Bahrndorff, S., Eriksen, N.T., 2021. Growth and metabolic performance of black soldier fly larvae grown on low and high-quality substrates. *Waste Manage.* 121, 198–205.
- LeCun, Y., Bengio, Y., Hinton, G., 2015. Deep learning. *Nature* 521, 436–444.

- Li, W., Li, M., Zheng, L., Liu, Y., Zhang, Y., Yu, Z., et al., 2015. Simultaneous utilization of glucose and xylose for lipid accumulation in black soldier fly. *Biotechnol. Biofuels* 8, 11.
- Makkar, H.P.S., Tran, G., Heuzé, V., Ankers, P., 2014. State-of-the-art on use of insects as animal feed. *Anim. Feed Sci. Technol.* 197, 1–33.
- Meneguz, M., Schiavone, A., Gai, F., Dama, A., Lussiana, C., Renna, M., et al., 2018. Effect of rearing substrate on growth performance, waste reduction efficiency and chemical composition of black soldier fly larvae. *J. Sci. Food Agric.* 98, 5776–5784.
- Padmanabha, M., Kobelski, A., Hempel, A.-J., Streif, S., 2020. A comprehensive dynamic growth and development model of *Hermetia illucens* larvae. *PLoS ONE* 15, e0239084.
- Prasetya, A., Darmawan, R., Araujo, T.L.B., Petrus, H.T.B.M., Setiawan, F.A., 2021. A growth kinetics model for black soldier fly larvae. *Int. J. Technol.* 12, 207–216.
- Sripontan, Y., Chiu, C.-I., Tanansathaporn, S., Leasen, K., Manlong, K., 2020. Modeling the growth of black soldier fly *Hermetia illucens*: an approach to evaluate diet quality. *J. Econ. Entomol.* 113, 742–751.
- Johnson, K.B., et al., 2019. Deep learning in agriculture: a survey. *Comput. Electron. Agric.* 163, 104859.