



**Sistema Híbrido para Predicción de Emisiones de CO₂ y CH₄ en la
Bioconversión de Residuos con *Hermetia illucens***

John Jairo Leal Gómez

**Proyecto de Tesis Doctoral, requisito parcial para optar al título de Doctor en
Estudios Ambientales.**

Director(a):

Dr. Luis Octavio González Salcedo

Codirectores:

Dr. Luis Fernando Mejía Rodríguez

Dra. Sorany Milena Barrientos Grajales

Universidad Nacional de Colombia
Facultad de Ingeniería y Administración
Doctorado en Estudios Ambientales
Sede Palmira, 2025

Agradecimientos

Listado de símbolos y abreviaturas

Resumen

Título en español

Texto del resumen.

Palabras clave: Palabras clave

Abstract

Título en inglés

Abstract text.

Keywords: Keywords

Lista de figuras

Lista de tablas

3.1. Clasificación de residuos orgánicos y su aptitud para bioconversión con <i>Hermetia illucens</i> . .	10
---	----

Contenido

Agradecimientos	II
Listado de símbolos y abreviaturas	III
Resumen	IV
Abstract	V
Lista de figuras	VI
Lista de tablas	VII
Contenido	VIII
1. Introducción	1
1.1. Contexto de la Gestión de Residuos Agroindustriales	1
1.2. Planteamiento del Problema	3
1.3. Justificación	4
1.3.1. Limitaciones de los Modelos Bioenergéticos Deterministas	5
1.3.2. La Arquitectura Híbrida como Solución Metodológica	5
1.4. Objetivos de la Investigación	6
2. Objetivos de la Investigación	7
2.1. Objetivo General	7
2.2. Objetivos Específicos	7
2.3. Alcance y Limitaciones	7
2.3.1. Alcance de la Investigación	7
2.3.2. Limitaciones y Restricciones	8
3. Marco Teórico	9
3.1. Residuos orgánicos y bioconversión con <i>Hermetia illucens</i>	9
3.2. Modelación de emisiones y sistemas inteligentes	11
3.3. Gobernanza de datos, ética algorítmica y epistemología ambiental	12
3.3.1. De la opacidad algorítmica a la interpretabilidad basada en modelos	12
3.3.2. Soberanía de datos y justicia algorítmica en el Sur Global	13
3.3.3. Límites del reduccionismo tecnológico	13
Referencias Bibliográficas	13

Capítulo 1

Introducción

1.1. Contexto de la Gestión de Residuos Agroindustriales

El cambio climático, principalmente resultado de las actividades humanas, se ha convertido en uno de los retos más urgentes de nuestra era (Allan et al., 2023). Desde la época preindustrial, las concentraciones de gases de efecto invernadero (GEI) como el dióxido de carbono (CO_2), el metano (CH_4) y el óxido nitroso (N_2O) han alcanzado niveles sin precedentes. En 2024, estas concentraciones llegaron a 423.9 partes por millón (ppm) para el CO_2 , 1942 partes por billón (ppb) para el CH_4 y 338.0 ppb para el N_2O , según las mediciones globales más recientes (WMO, 2025). Si bien una concentración atmosférica de CO_2 cercana al 0.042 % puede parecer nominal en términos volumétricos, su relevancia no reside en la abundancia relativa, sino en las propiedades radiativas intrínsecas de la molécula, la cual absorbe y reemite eficazmente la radiación infrarroja térmica. En consecuencia, este incremento acelerado ha alterado el forzamiento radiativo y ha intensificado el calentamiento global, provocando eventos climáticos extremos, alteraciones significativas en los ecosistemas y una rápida pérdida de biodiversidad.

Dentro de las fuentes antropogénicas de GEI, la gestión inadecuada de residuos orgánicos se destaca como un factor crítico, ya que su descomposición anaeróbica genera grandes cantidades de CH_4 , un gas con un potencial de calentamiento global 28 veces superior al del CO_2 en un horizonte de 100 años. Aunque los océanos y ecosistemas terrestres han actuado históricamente como sumideros naturales, absorbiendo gran parte del CO_2 antropogénico, reportes recientes advierten sobre una reducción en la eficiencia de estos sumideros durante 2024, lo que podría señalar una peligrosa retroalimentación climática. Por tanto, ante los signos de saturación de los mecanismos naturales de absorción y el alto potencial de calentamiento del metano, es urgente desarrollar soluciones innovadoras y sostenibles para mitigar las emisiones actuales, particularmente aquellas vinculadas a la gestión de residuos orgánicos (Giner et al., 2025).

Las estrategias convencionales para la gestión de residuos orgánicos —como los rellenos sanitarios, la digestión anaerobia y el compostaje— enfrentan limitaciones significativas. Los rellenos sanitarios generan emisiones prolongadas y difícilmente controlables de metano durante años e incluso décadas; la digestión anaerobia, aunque permite capturar biogás, demanda infraestructura compleja y costosa; y el compostaje, a pesar de su mayor accesibilidad, conlleva emisiones de N_2O y requiere períodos prolongados para lograr la estabilización del material (Kong et al., 2012; Nordahl et al., 2023). En contextos agroindustriales de países en desarrollo —donde se concentra la mayor parte de los residuos orgánicos sin tratar—, estas alternativas suelen resultar inviables desde el punto de vista técnico o económico. Justamente esta brecha abre una ventana de oportunidad para tecnologías alternativas basadas en procesos biológicos que puedan ser controlados, escalables y adaptados a estas realidades.

Entre las alternativas emergentes, la bioconversión de residuos orgánicos mediante larvas de *Hermetia illu-*

cens (conocida como mosca soldado negra o BSF, por sus siglas en inglés) ha demostrado ser una tecnología prometedora y transformadora. A diferencia de los métodos convencionales, la BSF opera bajo un enfoque de economía circular: transforma residuos orgánicos en biomasa larval rica en proteínas y lípidos y en fertilizante orgánico de alta calidad (*frass*), todo mediante procesos biológicos susceptibles de diseño (Bermúdez & Sánchez, 2023; Surendra et al., 2016). Comparada con métodos tradicionales, la bioconversión con BSF presenta ventajas claras: requiere menor infraestructura, opera en tiempos más cortos (3–4 semanas), funciona sin generación de lixiviados contaminantes y genera productos valiosos. Sin embargo, existe una desconexión crítica entre la ciencia de laboratorio y la realidad operativa. Si bien existen estudios respirométricos controlados, las plantas de producción real siguen operando como una “caja negra”, careciendo de sistemas de monitoreo continuo que permitan gestionar la variabilidad diaria del sustrato y el clima. Esta falta de datos in-situ impide validar la sostenibilidad del proceso fuera del entorno idealizado del laboratorio (Jenkins et al., 2025).

Teniendo en cuenta estas limitaciones, se propone la integración de **tres componentes tecnológicos complementarios**: (1) sensores IoT de bajo costo, (2) modelos matemáticos (EDO) y (3) algoritmos de aprendizaje automático (AAA). Esta convergencia tecnológica no es aditiva, sino **estructuralmente necesaria** para superar las barreras de cada método por separado: mientras los sensores capturan la realidad física pero carecen de contexto (ceguera semántica), y los modelos matemáticos mecanicistas (caja blanca) aportan coherencia teórica y respeto por las leyes termodinámicas, pero pierden precisión predictiva ante la estocasticidad del comportamiento larval y la heterogeneidad del sustrato sólido, la inteligencia artificial permite cerrar la brecha adaptándose a la estocasticidad del sistema. Es crucial entender que ninguno de estos componentes por sí solo puede validar la sostenibilidad ambiental del proceso; solo su integración híbrida permite transformar datos crudos en evidencia verificable para la toma de decisiones.

El objetivo de esta tesis es desarrollar un sistema híbrido que integre sensores IoT, modelos matemáticos basados en EDO y algoritmos de aprendizaje automático para estimar en tiempo real las emisiones de CO₂ y CH₄ durante la bioconversión de residuos con BSF. El sistema debe: (1) caracterizar dinámicamente las emisiones durante los ciclos productivos; (2) validar la fiabilidad del sistema demostrando una correlación significativa ($R^2 > 0,85$) frente a métodos estándar (cromatografía), priorizando la detección de tendencias críticas; y (3) generar herramientas accesibles (dashboard web) que traduzcan datos complejos en información para la toma de decisiones operativas, permitiendo comparar el desempeño ambiental contra una línea base.

El sistema mide: (1) concentraciones de CO₂ y CH₄ mediante sensores NDIR; y (2) variables de proceso (temperatura, humedad, densidad larval estimada). **Nota sobre el alcance:** Si bien la medición directa de N₂O se excluye por costos en esta etapa, el sistema mitiga esta limitación integrando desde lo computacional en el modelo matemático. Este módulo monitorea condiciones precursoras (como la caída súbita de la tasa de respiración o saturación de humedad) para generar una alerta de “Riesgo de Desnitrificación”, permitiendo al operario intervenir antes de que se generen emisiones críticas de este gas.

La propuesta, sin embargo, no ignora las complejidades del entorno real. Reconoce la necesidad de gestionar la deriva de los sensores en condiciones de humedad extrema para evitar lecturas erróneas, así como la urgencia de diseñar soluciones robustas ante la falta de datos masivos y la conectividad rural inestable. Además, el uso de inteligencia artificial se somete a un escrutinio ético-ambiental, evaluando si el costo energético del procesamiento y los riesgos de sesgo justifican el beneficio operativo, un balance ineludible en el campo de los Estudios Ambientales.

Claridad de propósitos: alcance técnico, marco comparativo y responsabilidad contextual

Esta tesis tiene un alcance técnicamente delimitado pero socialmente situado: desarrollar un sistema híbrido para estimar en tiempo real las emisiones sin pretender sustituir el juicio técnico o normativo. El sistema

es, por diseño, una *herramienta descriptiva de soporte a la decisión*, cuyo propósito es proporcionar a productores información cuantitativa para correlacionar decisiones operativas (densidad, sustrato, aireación) con la huella de carbono resultante. El diseño prioriza la accesibilidad y la transparencia, permitiendo generar datos comparables con alternativas como la digestión anaerobia o los rellenos sanitarios.

Reconociendo que la tecnología no es neutral, esta investigación asume una responsabilidad epistemológica explícita. Los algoritmos reflejan los contextos donde se entrenan y rara vez capturan la variabilidad total de los sistemas locales. Por ello, se establecen tres compromisos: (1) **transparencia algorítmica**, documentando limitaciones y supuestos (IA Explicable); (2) **soberanía de datos**, permitiendo el acceso y validación por parte de los usuarios locales; y (3) **compatibilidad con saberes**, asegurando que la tecnología complemente el conocimiento empírico del manejo de residuos. El éxito del sistema no se mide únicamente por métricas de error estadístico, sino por su capacidad para integrarse de manera justa en sistemas agroindustriales reales, fortaleciendo la autonomía técnica del productor.

Aporte del sistema a la gestión ambiental

Desde la perspectiva de la gestión ambiental, este sistema representa un cambio de paradigma al transitar de tratamientos de residuos basados en la estimación empírica a procesos gobernados por la precisión de los datos. Su principal aporte radica en la capacidad de visibilizar el metabolismo del proceso en tiempo real, permitiendo identificar y mitigar picos de emisión de GEI que, en métodos convencionales, pasarían inadvertidos. Al integrar la detección temprana de condiciones anaeróbicas con modelos predictivos —actuando preventivamente sobre riesgos de metanogénesis y desnitrificación—, la herramienta no solo optimiza la huella de carbono del tratamiento, sino que otorga trazabilidad y transparencia al ciclo de valorización de residuos, elementos indispensables para validar estrategias de economía circular y cumplimiento normativo en escenarios de crisis climática.

1.2. Planteamiento del Problema

En el contexto Tecnológico y Biológico, la gestión de la fracción orgánica de los residuos sólidos municipales (FORSU) enfrenta limitaciones estructurales en sus rutas convencionales. Los rellenos sanitarios operan como reactores anaerobios no controlados de larga duración; el compostaje, aunque accesible, requiere extensos tiempos de estabilización y conlleva riesgos de emisiones de óxido nitroso (N_2O); y la digestión anaerobia, pese a su ventaja energética, demanda inversiones de capital, a menudo inviables para la escala agroindustrial media.

En este escenario, la bioconversión mediante larvas de *Hermetia illucens* (BSF) se ha consolidado como una alternativa de alta eficiencia. A diferencia de los métodos pasivos, este es un sistema biológico acelerado: durante su fase larval (aprox. 14 días), el insecto incrementa su masa corporal hasta 4000 veces mediante un metabolismo voraz y exotérmico que ocurre en simbiosis con una microbiota activa. Este proceso transforma la materia orgánica en biomasa (proteína) y fertilizante (*frass*) con baja huella hídrica, posicionándose como una herramienta clave para la economía circular (Bermúdez & Sánchez, 2023; Surendra et al., 2016).

Sin embargo, a pesar de estas ventajas biológicas, la ausencia de cuantificación dinámica y rigurosa de las emisiones de gases de efecto invernadero (GEI), particularmente CH_4 y CO_2 , genera una incertidumbre crítica. Actualmente, la tecnología opera mayoritariamente como una “caja negra”: se conocen los insumos y productos, pero se ignora la dinámica de los flujos gaseosos intermedios, basándose en factores de emisión estáticos o extrapolaciones de otros procesos (compostaje) que no reflejan la realidad metabólica de la BSF (Fuhrmann et al., 2025; Rossi et al., 2024).

Esta fragmentación del conocimiento tiene consecuencias técnicas, operativas y de gobernanza climática:

Primero, al no existir factores de emisión específicos para BSF en las metodologías del IPCC ni en el GHG Protocol, cualquier balance de carbono se basa en supuestos no verificados. Esto introduce sesgos sistemáticos que pueden subestimar significativamente las emisiones de CH_4 , especialmente bajo condiciones de manejo subóptimas. La consecuencia no es solo técnica, sino ética: se corre el riesgo de asignar beneficios climáticos no reales a una tecnología que, sin monitoreo, podría superar las emisiones del compostaje en escenarios de anaerobiosis no controlada (Greenwashing involuntario).

Segundo, la imposibilidad de detectar en tiempo real picos de CH_4 impide identificar fallas operativas críticas —como sobrepoblación larval, exceso de humedad o deficiente aireación— que generan microambientes anaeróbicos. Estas condiciones no solo aumentan las emisiones de GEI, sino que reducen la eficiencia de conversión, incrementan la mortalidad larval y degradan la calidad del *frass*, impactando directamente la viabilidad económica del sistema. Medir las emisiones es, por tanto, una herramienta de control de proceso.

Tercero, la carencia de sistemas de Medición, Reporte y Verificación (MRV) alineados con estándares internacionales constituye una barrera estructural para el acceso a mecanismos de financiación climática. Según el Banco Mundial, los mercados de carbono modernos exigen trazabilidad cuantitativa y verificable (Bank, 2023). Normativas como el *Verified Carbon Standard* (VCS) estipulan que la cuantificación debe ser real, medible y permanente” (Verra, 2024). Sin datos empíricos robustos, la industria de insectos no puede certificar sus reducciones a escala industrial (Smetana et al., 2019).

Esta brecha se ve agravada por la escasa integración de tecnologías de monitoreo con modelos predictivos capaces de resolver las limitaciones estructurales de los enfoques existentes. El modelo bioenergético de Eriksen (2022) aunque robusto para describir la relación promedio entre biomasa y respiración bajo condiciones controladas de laboratorio, opera bajo el supuesto de homogeneidad larval y condiciones macroscópicas estables. Sin embargo, estudios recientes han documentado que las larvas de *H. illucens* forman agregaciones dinámicas que se comportan como fluidos activos (Ko et al., 2021), generando heterogeneidad espacial en el sustrato que no es capturada por las ecuaciones diferenciales ordinarias deterministas (Tomberlin et al., 2025). Esta limitación bifurca el problema en dos frentes complementarios: (1) la estimación de la biomasa larval $B(t)$ a partir de variables operativas observables (densidad inicial, temperatura, humedad) —un problema inverso intrínsecamente no lineal que resolvemos mediante una red neuronal *feedforward*—; y (2) la estimación de las emisiones de CO_2 a partir de $B(t)$ incorporando las desviaciones sistemáticas observadas experimentalmente respecto al modelo base, tarea que abordamos mediante una Red Neuronal Informada por la Física (PINN) que minimiza simultáneamente el error de predicción y el residual de la ecuación diferencial de conservación de masa. Esta arquitectura híbrida supera las implementaciones actuales que operan con parámetros fijos y carecen de retroalimentación en tiempo real, permitiendo capturar la dinámica no lineal del proceso biológico sin sacrificar el rigor termodinámico (Kamilaris et al., 2017; Liu et al., 2023).

Frente a este escenario, esta tesis desarrolla un sistema híbrido que articula arquitecturas de aprendizaje profundo y Redes Neuronales Informadas por la Física (PINNs). Esta aproximación computacional transforma la cuantificación de emisiones en una herramienta de gestión predictiva, superando las limitaciones de la “caja negra”. Al estimar de forma continua la cinética de CO_2 y CH_4 , el sistema permite: (1) generar la evidencia empírica necesaria para establecer factores de emisión dinámicos; (2) predecir variables biocéntricas complejas —como la biomasa máxima— para detectar ineficiencias operativas; y (3) construir una trazabilidad verificable que facilita la integración de la industria en economías circulares con credenciales climáticas robustas.

1.3. Justificación

La necesidad de desarrollar un sistema híbrido de monitoreo no responde únicamente a una demanda de mercado, sino a una brecha fundamental en la capacidad de los modelos actuales para representar la realidad física del proceso. Esta brecha se ve agravada por la escasa integración de tecnologías de monitoreo con modelos predictivos capaces de resolver las limitaciones estructurales de los enfoques existentes.

1.3.1. Limitaciones de los Modelos Bioenergéticos Deterministas

El modelo bioenergético de referencia de Eriksen (2022), aunque robusto para describir la relación promedio entre biomasa y respiración bajo condiciones controladas de laboratorio, opera bajo el supuesto de homogeneidad larval y condiciones macroscópicas estables. Sin embargo, estudios recientes han documentado que las larvas de *H. illucens* forman agregaciones dinámicas que se comportan como fluidos activos (Ko et al., 2021), generando heterogeneidad espacial en el sustrato (gradientes térmicos) que no es capturada por las ecuaciones diferenciales ordinarias deterministas (Tomberlin et al., 2025). Esta heterogeneidad sugiere la existencia de microambientes con variabilidad en la disponibilidad de oxígeno — hipótesis que esta tesis validará experimentalmente mediante el análisis de residuos sistemáticos entre el modelo Eriksen y las mediciones de CO_2 en tiempo real.

1.3.2. La Arquitectura Híbrida como Solución Metodológica

Esta limitación física justifica la bifurcación del problema en dos frentes complementarios que esta tesis aborda mediante una arquitectura computacional híbrida:

1. **Sensor Virtual de Biomasa:** La estimación de la biomasa larval $B(t)$ a partir de variables operativas observables (densidad inicial, temperatura, humedad) constituye un problema inverso intrínsecamente no lineal. Esta investigación justifica el uso de una red neuronal *feedforward* para mapear estas relaciones complejas, actuando como un sensor virtual capaz de inferir el estado del sistema sin muestreos destructivos. La elección de $B(t)$ como variable de estado intermedia permite (a) interpretar el modelo mediante una variable biológicamente significativa, (b) reutilizar $B(t)$ para múltiples salidas (detección de prepupación, optimización de cosecha), y (c) reducir la dimensionalidad del problema mediante una representación compacta del estado del sistema.
2. **PINN Genuina para Predicción de Emisiones:** Para la estimación de las emisiones de CO_2 , implementamos una Red Neuronal Informada por la Física (PINN) *genuina* según la formulación original de Raissi et al. (2019). A diferencia de los filtros de Kalman que asumen desviaciones gaussianas aditivas, las agregaciones larvales inducen desviaciones sistemáticas y no lineales que requieren un componente de aprendizaje capaz de modelar funciones arbitrarias sin supuestos paramétricos restrictivos. La PINN resuelve directamente la ecuación diferencial del modelo Eriksen:

$$\frac{dB}{dt} = f_{\text{Eriksen}}(B; \theta)$$

donde la red neuronal $\mathcal{N}(t; \mathbf{w})$ tiene como salida la biomasa $B(t)$ y sus parámetros $\mathbf{w}$ se optimizan minimizando el residual físico como objetivo primario:

$$\mathcal{L}(\mathbf{w}) = \underbrace{\frac{1}{N} \sum_{i=1}^N \|\mathcal{N}(t_i; \mathbf{w}) - B_{\text{sensor}}(t_i)\|_2^2}_{\text{Ajuste a datos}} + \lambda \underbrace{\frac{1}{M} \sum_{j=1}^M \left\| \frac{\partial \mathcal{N}}{\partial t}(t_j; \mathbf{w}) - f_{\text{Eriksen}}(\mathcal{N}(t_j; \mathbf{w}); \theta) \right\|_2^2}_{\text{Residual de la EDO}}$$

La tasa de CO_2 se obtiene posteriormente mediante la relación bioenergética del modelo Eriksen: $\dot{V}_{\text{CO}_2} = Y_{\text{CO}_2} \cdot \frac{dB}{dt}$. Esta formulación garantiza que las predicciones obedezcan a la estructura de conservación de masa del sistema biológico, sin requerir grandes volúmenes de datos etiquetados.

En conclusión, la arquitectura propuesta supera las implementaciones actuales que operan con parámetros fijos y carecen de retroalimentación en tiempo real (Kamilaris et al., 2017; Liu et al., 2023), proporcionando una herramienta capaz de validar factores de emisión dinámicos y optimizar el proceso en escenarios industriales reales mediante la preservación explícita de las leyes de conservación en el espacio de búsqueda del aprendizaje automático.

1.4. Objetivos de la Investigación

Capítulo 2

Objetivos de la Investigación

2.1. Objetivo General

Desarrollar un sistema híbrido a escala de laboratorio —integrado por modelado mecanístico (EDO), sensores IoT de bajo costo y algoritmos de aprendizaje automático— para la estimación de la tasa de producción de CO_2 y la detección de eventos de emisión de CH_4 en la bioconversión de residuos con *Hermetia illucens*, con el fin de generar métricas de desempeño ambiental aplicables a la gestión de residuos agroindustriales.

2.2. Objetivos Específicos

1. **Instrumentación:** Configurar y calibrar un módulo de sensores NDIR de bajo costo para la medición de CO_2 y CH_4 , determinando su precisión y desviación (MAPE) frente a un instrumento de referencia bajo las condiciones de temperatura y humedad propias del cultivo de larvas.
2. **Modelado Matemático:** Adaptar y parametrizar un modelo de EDO basado en la bioenergética de *Hermetia illucens* para estimar la tasa de respiración (CO_2), evaluando su capacidad predictiva en ventanas temporales durante un ciclo de bioconversión de 15 días.
3. **Integración Híbrida:** Desarrollar un algoritmo de estimación de estados mediante redes neuronales que infiera la biomasa larval a partir de datos operativos, integrando esta variable como entrada dinámica al modelo mecanístico para mejorar la precisión de la estimación de CO_2 .
4. **Métricas Ambientales:** Validar la utilidad del sistema para la gestión ambiental mediante la detección de eventos de anaerobiosis (CH_4) y la cuantificación del carbono emitido, contrastando estos indicadores dinámicos frente a estimaciones estáticas tradicionales.

2.3. Alcance y Limitaciones

2.3.1. Alcance de la Investigación

El presente trabajo se circunscribe al desarrollo, implementación y validación computacional de un sistema híbrido de inteligencia artificial para la modelación de bioprocesos.

- **Dominio de Modelado:** La investigación abarca la fase de crecimiento larval de *Hermetia illucens* (aproximadamente del día 5 al día 14 post-eclosión), excluyendo las etapas de prepupa, pupa y reproducción, dado que la mayor actividad metabólica y emisiones de gases ocurren durante la fase de alimentación activa.
- **Variables Objetivo:** El sistema se enfoca en la predicción dinámica de tres variables de estado críticas: biomasa larval viva ($B(t)$), flujo de dióxido de carbono (dCO_2/dt) y flujo de metano (dCH_4/dt).
- **Metodología Híbrida:** El alcance metodológico comprende la integración de redes neuronales densas (*feedforward*) para la inferencia de estados no observables y Redes Neuronales Informadas por la Física (PINNs) para la regularización termodinámica, utilizando el modelo bioenergético de Eriksen (2022) como base teórica (baseline).
- **Validación:** La validación del modelo se realiza mediante datos experimentales de reactores tipo *batch* bajo condiciones controladas, evaluando el desempeño predictivo frente a sustratos orgánicos representativos de residuos municipales (FORSU) y dietas estándar de control.

2.3.2. Limitaciones y Restricciones

A pesar de la robustez del enfoque híbrido, se reconocen las siguientes limitaciones que definen las fronteras de validez del modelo propuesto:

- **Especificidad del Sustrato:** Si bien las PINNs mejoran la capacidad de generalización respecto a las redes puramente estadísticas, la precisión del modelo está acotada al dominio químico de los sustratos utilizados en el entrenamiento. El modelo no contempla la inhibición metabólica por contaminantes exógenos (e.g., metales pesados, pesticidas) ni matrices de residuos con relaciones C/N extremas no representadas en el conjunto de datos.
- **Resolución Espacial:** El modelo opera bajo una aproximación de parámetros concentrados (*lumped-parameter model*) o 0D-temporal. Aunque el término residual de la PINN captura implícitamente las ineficiencias causadas por la heterogeneidad espacial (fluidos activos), el modelo no resuelve explícitamente los gradientes tridimensionales de temperatura y oxígeno dentro del reactor, lo cual requeriría un acople con Dinámica de Fluidos Computacional (CFD) fuera del alcance de esta tesis.
- **Régimen Operativo:** Los algoritmos están diseñados y validados para sistemas de operación por lotes (*batch*). Su aplicación directa a sistemas de alimentación continua o reactores de flujo vertical podría requerir un reentrenamiento o ajustes en la arquitectura de la red para capturar la dinámica de estado estacionario.
- **Dependencia de Datos:** La eficacia del "sensor virtual" depende de la calidad de los datos de entrada (temperatura, humedad ambiental, densidad inicial). Errores instrumentales significativos o deriva en los sensores físicos de bajo costo podrían propagar incertidumbre a las predicciones del modelo híbrido.

Capítulo 3

Marco Teórico

El desarrollo de soluciones tecnológicas para la gestión sostenible de residuos orgánicos exige una comprensión integrada de los procesos biológicos, ambientales y computacionales involucrados. Este capítulo ofrece la base teórica que sustenta la propuesta de un sistema inteligente híbrido para la predicción de emisiones de gases de efecto invernadero (GEI) en la bioconversión con BSF. Se articulan dos ejes interdependientes: (i) la bioconversión como estrategia de valorización de residuos en contextos agroindustriales; (ii) los enfoques de modelado matemático y sistemas inteligentes para la estimación dinámica de emisiones.

3.1. Residuos orgánicos y bioconversión con *Hermetia illucens*

En contextos agroindustriales del sur global —como el Valle del Cauca—, los residuos orgánicos provenientes de cultivos como café, caña y frutas se generan de forma dispersa, en picos estacionales y con alta carga biodegradable, lo que incrementa el riesgo de emisiones de CH_4 cuando su gestión es inadecuada (Food and Agriculture Organization of the United Nations (FAO), 2021; Leddin, 2024). Frente a las limitaciones de las estrategias convencionales —rellenos sanitarios, digestión anaerobia y compostaje—, que suelen ser inviables técnica o económicamente en estos entornos (Kong et al., 2012; Nordahl et al., 2023), la bioconversión con BSF se ha adoptado crecientemente como una alternativa de economía circular.

La bioconversión de residuos orgánicos mediante larvas en estadios voraces (L3–L5) transforma desechos en biomasa rica en proteínas y lípidos, así como en *frass*, un fertilizante orgánico de alto valor agronómico (Bermúdez & Sánchez, 2023; Singh & Kumari, 2019; Surendra et al., 2016). Este proceso se sustenta en una sinergia entre la acción macroscópica de las larvas y la actividad microbiana del sustrato: las larvas fragmentan mecánicamente el material, aumentando su área superficial, mientras su microbioma intestinal —junto con microorganismos del medio— degrada enzimáticamente polímeros complejos en compuestos asimilables. Esta doble acción reduce entre el 50 % y el 80 % la masa del residuo (base húmeda) y altera drásticamente las propiedades fisicoquímicas del medio (pH, humedad, disponibilidad de nutrientes), generando microambientes dinámicos que condicionan si predominan rutas metabólicas aeróbicas o anaeróbicas. Durante este proceso, el dióxido de carbono (CO_2) se genera principalmente por la respiración aeróbica tanto de las larvas como de la microbiota asociada; estudios estiman que hasta un tercio del carbono ingerido se libera como CO_2 (Diener et al., 2009), una emisión altamente sensible a factores como la composición del sustrato, densidad larval, temperatura y oxigenación (Bekker et al., 2021; Eriksen, 2022; Rossi et al., 2024).

Aunque la bioconversión muestra un perfil de emisiones potencialmente más favorable que el compostaje tradicional —con reducciones reportadas en CH_4 y N_2O (Jenkins et al., 2025)—, su implementación a escala carece de sistemas rigurosos para cuantificar y predecir en tiempo real las emisiones gaseosas asociadas. Esta limitación impide su validación como solución climática verificable y obstaculiza su integración en mecanis-

mos de compensación de carbono o políticas de gestión sostenible de residuos. En particular, la dinámica de emisiones, especialmente la de CO_2 —que refleja directamente la actividad biológica en curso—, no ha sido suficientemente modelada mediante herramientas matemáticas capaces de ofrecer estimaciones continuas y predictivas bajo condiciones operativas variables. Así, persiste una brecha crítica entre el potencial ambiental demostrado en ensayos controlados y la capacidad de monitoreo, verificación y escalabilidad requerida para su reconocimiento en estrategias climáticas basadas en evidencia.

Aunque el metano (CH_4) es un gas de efecto invernadero con un potencial de calentamiento global significativamente mayor que el del dióxido de carbono (CO_2), su generación en sistemas de bioconversión con BSF es generalmente baja debido al carácter predominantemente aeróbico del proceso. No obstante, se incluye su monitoreo como variable de control para detectar condiciones transitoriamente anaeróbicas —por ejemplo, por sobresaturación del sustrato o deficiente aireación— que podrían comprometer la eficiencia del proceso y generar picos no deseados de emisiones. Sin embargo, el foco técnico de esta tesis recae en el CO_2 , ya que constituye el principal indicador cuantitativo y dinámico de la actividad biológica total (tanto larval como microbiana) durante la bioconversión. Además, presenta una señal más estable y continua, lo que facilita su integración en modelos de estimación en tiempo real, y permite una correlación directa con variables operativas clave, como el consumo de sustrato, la biomasa generada y las tasas respiratorias. Por estas razones, el CO_2 se adopta como la variable central para el desarrollo, calibración y validación del sistema híbrido propuesto.

La aptitud de los residuos para la bioconversión varía significativamente según su composición. Como se resume en la Tabla 3.1, subproductos agroindustriales como la pulpa de café o cáscaras de frutas son altamente adecuados, mientras que residuos lignocelulósicos o lodos orgánicos requieren pretratamiento o presentan riesgos sanitarios (Bruno et al., 2025; Elsayed et al., 2024). Esta heterogeneidad —común en el Valle del Cauca— subraya la necesidad de sistemas de monitoreo adaptables, capaces de caracterizar el proceso en función del sustrato y las condiciones locales.

La evidencia cuantitativa disponible es fragmentada: se reportan emisiones de CO_2 entre 7.76 y 11.88 g por gramo de larva seca (Rossi et al., 2024), o 96.5 g de CO_2 por kg de residuo tratado (Fuhrmann et al., 2025), pero sin protocolos estandarizados ni mediciones continuas. Esta incertidumbre impide comparar tecnologías, diseñar políticas públicas informadas o acceder a mecanismos de mercado basados en la mitigación climática.

Tabla 3.1: Clasificación de residuos orgánicos y su aptitud para bioconversión con *Hermetia illucens*

Tipo de residuo	Origen común	Aptitud para BSF
Residuos agrícolas	Restos de cosecha, podas, hojas secas	Moderada. Requieren pretratamiento por bajo contenido proteico.
Residuos alimentarios	Sobras de cocina, frutas, verduras, pan	Alta. Contenido balanceado de lípidos y carbohidratos.
Subproductos agroindustriales	Pulpa de café, cáscaras de frutas, bagazo de caña	Alta. Composición variable, pero generalmente adecuada.
Grasas y aceites residuales	Aceites usados, residuos grasos de cocina	Media. Requieren mezcla con otros residuos para evitar inhibición.
Lodos orgánicos	Lodos de depuradoras, biosólidos	Baja. Riesgo sanitario y composición inconsistente.

Hacia sistemas de monitoreo adaptable en contextos heterogéneos:

La heterogeneidad de residuos agroindustriales documentada en la Tabla 3.1 —desde pulpa de café (alta aptitud) hasta lodos orgánicos (baja aptitud)— refleja una realidad común en el Valle del Cauca: los productores raramente procesan un único tipo de residuo de forma consistente. En su lugar, enfrentan mezclas variables según la estacionalidad, disponibilidad local y dinámicas de producción (Bruno et al., 2025; Elsayed et al.,

2024). Adicionalmente, variables ambientales críticas —temperatura, humedad del sustrato, oxigenación— fluctúan durante el ciclo de bioconversión, particularmente en contextos rurales donde el control es limitado (Bekker et al., 2021; Rossi et al., 2024).

Esta variabilidad operativa implica que los métodos de medición estática o puntual —como muestreos puntuales con cromatografía de gases— son insuficientes para caracterizar emisiones de manera confiable. Se requieren sistemas de monitoreo que sean: (i) **continuos en tiempo real**, capaces de capturar dinámicas horarias y diarias; (ii) **adaptables a diferentes tipos de residuos**, disminuyendo la necesidad de recalibración manual frecuentemente; (iii) **interpretables**, permitiendo a productores locales comprender qué sucede en el sistema y tomar decisiones operativas informadas. Es precisamente esta necesidad la que motiva un enfoque integrado que combine modelación matemática dinámica, sensores de bajo costo y calibración automática mediante algoritmos de aprendizaje automático, tema de la siguiente sección.

3.2. Modelación de emisiones y sistemas inteligentes

La cuantificación dinámica de emisiones en procesos biológicos exige herramientas que articulen una base mecanística con capacidad de adaptación empírica. En este contexto, el modelado matemático basado en ecuaciones diferenciales ordinarias (EDO) ha impulsado avances significativos. Por ejemplo, el modelo de crecimiento larval propuesto por Eriksen (2022) integra balances energéticos y cinética logística para simular simultáneamente la acumulación de biomasa y la producción de CO₂, combinando los principios del enfoque *Dynamic Energy Budget* (DEB) con eventos biológicos clave del ciclo larval, como las mudas y la metamorfosis. De manera análoga, funciones cinéticas de tipo Monod y Haldane —originalmente desarrolladas para digestión anaerobia— han sido adaptadas con éxito para describir la degradación del sustrato y el crecimiento microbiano en sistemas de bioconversión con insectos (Ahlamine et al., 2024; Win et al., 2018).

Si bien los modelos mecanicistas actuales proporcionan una base teórica indispensable, su aplicación directa en entornos operativos dinámicos enfrenta limitaciones intrínsecas. La literatura (Bekker et al., 2021; Rossi et al., 2024) indica que estas formulaciones, validadas principalmente con dietas estandarizadas bajo condiciones controladas, a menudo simplifican la complejidad fisicoquímica de las mezclas de residuos reales. En escenarios de campo, donde la heterogeneidad del sustrato es la norma, el uso de parámetros cinéticos fijos restringe la capacidad del modelo para predecir con exactitud. Esta brecha operativa subraya la necesidad de enfoques híbridos, donde el aprendizaje automático capture la variabilidad no modelada —atribuible a la incertidumbre nutricional de la mezcla— y ajuste dinámicamente las proyecciones del modelo base a las condiciones cambiantes del proceso.

Paralelamente, los avances en sensores de bajo costo y plataformas IoT han facilitado el monitoreo continuo de variables críticas —CO₂, CH₄, temperatura, humedad— en entornos operativos reales (Duobiene et al., 2022; Raj & Srivastava, 2023; Yavari et al., 2023). Estos datos, procesados mediante algoritmos de aprendizaje automático (AAA), permiten identificar patrones complejos y no lineales que serían difíciles de capturar mediante reglas explícitas (Chen et al., 2021; Weichert et al., 2019).

En particular, la integración de modelos mecanísticos (EDO) con AAA, enfoque conocido en la literatura como **modelado de caja gris**, (**grey box modelling**) ha demostrado potencial en sistemas biotecnológicos complejos: mientras el modelo EDO proporciona una estructura interpretable y basada en principios físicos, el AAA permite calibración dinámica de parámetros a partir de datos en tiempo real, mejorando predicciones cuando las condiciones operativas se desvían del escenario de entrenamiento (Guillaume et al., 2023; Kobelski et al., 2024).

Sin embargo, esta integración enfrenta desafíos prácticos que definen la arquitectura del sistema: (i) la dependencia de datos masivos en los algoritmos de AAA puros, lo que genera riesgo de *overfitting* y problemas de «arranque en frío» (*cold start*) en instalaciones nuevas. Esta limitación se mitiga aquí utilizando el modelo mecanístico como un *prior* informativo robusto, garantizando funcionalidad desde el primer día sin necesidad

de históricos extensos; (ii) la validación cruzada y el ajuste de hiperparámetros, que requieren estrategias específicas para contextos de *Small Data*; (iii) el costo computacional de arquitecturas complejas (redes neuronales) frente a opciones más ligeras. Por ello, esta tesis adopta un enfoque escalonado: fundamentar la operación en el modelo mecanístico, refinar las predicciones mediante modelos interpretables (regresión) a medida que se generan datos, y evaluar redes neuronales multicapa solo cuando la base de datos acumulada garantice una mejora significativa sobre los métodos más simples.

En síntesis, el marco teórico desarrollado en este capítulo fundamenta un enfoque técnico híbrido que integra tres componentes interdependientes: (i) un modelo mecanístico basado en ecuaciones diferenciales ordinarias que captura la dinámica biológica del proceso de bioconversión; (ii) sensores IoT de bajo costo que permiten monitoreo continuo de emisiones de CO₂ y CH₄ en tiempo real; (iii) algoritmos de aprendizaje automático que facilitan calibración dinámica y predicción adaptativa bajo variaciones operativas. Esta integración es particularmente relevante para contextos agroindustriales del sur global, donde la falta de infraestructura costosa y la necesidad de soluciones escalables hacen que un sistema de bajo costo y mantenible sea más viable que tecnologías convencionales.

Operacionalmente, la “inteligencia” del sistema reside en su capacidad para: (1) generar predicciones con fundamento mecanístico (interpretables, no cajas negras); (2) actualizar predicciones automáticamente a partir de datos en tiempo real; (3) proporcionar información clara a productores locales para que tomen decisiones informadas sobre condiciones operativas (temperatura, humedad, manejo de residuos). No obstante, esta investigación reconoce explícitamente que la mera disponibilidad de datos técnicos no garantiza equidad o sostenibilidad. La verdadera gobernanza de un sistema como este requiere —más allá del alcance de esta tesis— decisiones sobre acceso a datos, beneficios compartidos, y co-diseño con usuarios finales. Estas dimensiones ético-políticas constituyen un campo de investigación complementario igualmente importante.

3.3. Gobernanza de datos, ética algorítmica y epistemología ambiental

La implementación de tecnologías digitales en la gestión de procesos biológicos no es un acto neutral; constituye la creación de un sistema socio-técnico donde convergen biología, código y decisión humana. Desde la perspectiva de los estudios de ciencia, tecnología y sociedad (CTS) y la epistemología ambiental, es imperativo trascender la visión instrumental de la tecnología para abordar las implicaciones éticas y cognitivas de “datificar” la naturaleza.

3.3.1. De la opacidad algorítmica a la interpretabilidad basada en modelos

Uno de los mayores riesgos en la aplicación de la inteligencia artificial (IA) al medio ambiente es la *opacidad algorítmica* (Burrell, 2016). En modelos de caja negra, las decisiones se vuelven inescrutables, generando relaciones de dependencia tecnológica donde el operario obedece sin comprender.

Esta tesis adopta una postura ética fundada en la *interpretabilidad por diseño*. Al integrar modelos mecanísticos basados en ecuaciones diferenciales ordinarias (EDO) —cuyos parámetros tienen significado biológico explícito— con algoritmos de aprendizaje ligeros, el sistema no solo predice eventos (el *qué*), sino que permite rastrear sus causas fisiológicas o operativas (el *porqué*), como el exceso de humedad o la acumulación de zonas anaeróbicas. Esta transparencia cognitiva devuelve la agencia al tomador de decisiones y se alinea con los principios de transparencia exigidos por marcos de reporte climático como el IPCC Tier 3 (Adadi & Berrada, 2018).

3.3.2. Soberanía de datos y justicia algorítmica en el Sur Global

La gobernanza de los datos ambientales plantea interrogantes críticos sobre propiedad, acceso y beneficio. La literatura sobre *Big Data* en agricultura alerta sobre el “extractivismo de datos”, donde la información generada en territorios rurales es capturada por plataformas externas sin retorno de valor local (Carolan, 2020).

Esta investigación se alinea con los principios de *soberanía de datos* y *diseño frugal*. La arquitectura propuesta es descentralizada y computacionalmente eficiente: el procesamiento crítico ocurre en el borde (*edge computing*), priorizando algoritmos optimizados que pueden ejecutarse en hardware de bajo costo sin depender de infraestructuras en la nube centralizadas y costosas. Esto no solo reduce la latencia y los costos operativos, sino que garantiza que los datos sensibles permanezcan bajo el control local del productor, operando incluso en condiciones de conectividad intermitente. Filosóficamente, el monitoreo ambiental no debe ser una herramienta de vigilancia, sino un instrumento de empoderamiento que permita a los productores agroindustriales validar sus prácticas ante mercados globales, sin alienar su conocimiento local.

3.3.3. Límites del reduccionismo tecnológico

Finalmente, se reconoce la tensión ontológica entre la complejidad del sistema biológico y su representación digital. Un sensor de CO₂ registra una señal fisicoquímica, pero no captura dimensiones cualitativas como la resiliencia del microbioma o el bienestar larval. Existe el riesgo de caer en el *solucionismo tecnológico*, asumiendo que lo no medido es irrelevante.

Por ello, este marco teórico establece que el sistema híbrido es una herramienta de *soporte*, no de *sustitución*. La comprensión más robusta del proceso emerge de la interacción dialógica entre la señal del sensor y la experiencia empírica del operador. El modelo matemático y la inteligencia artificial actúan como traductores que hacen visible lo invisible (los gases), pero la interpretación final debe permanecer anclada en el contexto ecológico, social y productivo del territorio.

Referencias Bibliográficas

- Adadi, A., & Berrada, M. (2018). Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI). *IEEE Access*, 6, 52138-52160. <https://doi.org/10.1109/ACCESS.2018.2870052>
- Ahlamine, I., Alla, A., & Khattabi, N. E. (2024). Mathematical analysis of an anaerobic digestion model for biogas production from solid waste. *Scientific Reports*, 14(1), 25934. <https://doi.org/10.1038/s41598-024-77430-6>
- Allan, R., Arias, P., Berger, S., & Canadell, J. (2023, 6 de julio). Summary for Policymakers. En *Climate Change 2021 – The Physical Science Basis* (1.^a ed., pp. 3-32). Cambridge University Press. <https://doi.org/10.1017/9781009157896.001>
- Bank, W. (2023). *State and Trends of Carbon Pricing 2023*. Washington, DC.
- Bekker, N. S., Heidelbach, S., Vestergaard, S. Z., Nielsen, M. E., Riisgaard-Jensen, M., Zeuner, E. J., Bahrndorff, S., & Eriksen, N. T. (2021). Impact of substrate moisture content on growth and metabolic performance of black soldier fly larvae. *Waste Management*, 127, 73-79. <https://doi.org/10.1016/j.wasman.2021.04.028>
- Bermúdez, I. M., & Sánchez, O. A. (2023). Comprehensive utilization of the Black Soldier Fly: Bioconversion, sustainability, and emerging challenges. *Scientia Agropecuaria*, 14(4), 571-590. <https://doi.org/10.17268/sci.agropecu.2023.047>
- Bruno, D., Orlando, M., Testa, E., Carnevale Miino, M., Pesaro, G., Miceli, M., Pollegioni, L., Barbera, V., Fasoli, E., Draghi, L., Baltrocchi, A. P. D., Ferronato, N., Seri, R., Maggi, E., Caccia, S., Casartelli, M., Molla, G., Galimberti, M. S., Torretta, V., ... Tettamanti, G. (2025). Valorization of Organic Waste through Black Soldier Fly: On the Way of a Real Circular Bioeconomy Process. *Waste Management*, 191, 123-134. <https://doi.org/10.1016/j.wasman.2024.10.030>
- Burrell, J. (2016). *How the machine 'thinks': Understanding opacity in machine learning algorithms*. <https://doi.org/10.1177/2053951715622512>
- Carolan, M. (2020). Automated agrifood futures: Robotics, labor and the distributive politics of digital agriculture. *The Journal of Peasant Studies*, 47(1), 184-207. <https://doi.org/10.1080/03066150.2019.1584189>
- Chen, Y., Zhu, X., Fang, K., Wu, Y., Deng, Y., He, X., Zou, Z., & Guo, T. (2021). An Optimization Model for Process Traceability in Case-Based Reasoning Based on Ontology and the Genetic Algorithm. *IEEE Sensors Journal*, 21(22), 25123-25132. <https://doi.org/10.1109/JSEN.2021.3065757>
- Diener, S., Zurbrugg, C., & Tockner, K. (2009). Conversion of Organic Material by Black Soldier Fly Larvae: Establishing Optimal Feeding Rates. *Waste Management & Research*, 27(6), 603-610. <https://doi.org/10.1177/0734242X09103838>
- Duobiene, S., Ratautas, K., Trusovas, R., Ragulis, P., Šlekas, G., Simniškis, R., & Račiukaitis, G. (2022). Development of Wireless Sensor Network for Environment Monitoring and Its Implementation Using SSAIL Technology. *Sensors*, 22(14), 5343. <https://doi.org/10.3390/s22145343>
- Elsayed, M., Wang, J., Wang, H., Zhou, Z., Osman, A. I., Almutairi, A. W., Faisal, S., & Abomohra, A. (2024). Conversion of protein-rich waste into biodiesel by *Hermetia illucens*: Enhanced energy recovery and reduced greenhouse gas emissions. *Sustainable Energy Technologies and Assessments*, 66, 103825. <https://doi.org/10.1016/j.seta.2024.103825>
- Eriksen, N. T. (2022). Dynamic Modelling of Feed Assimilation, Growth, Lipid Accumulation, and CO₂ Production in Black Soldier Fly Larvae. *PLoS One*, 17(10), e0276605. Consultado el 2 de marzo de 2025, desde <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0276605>
- Food and Agriculture Organization of the United Nations (FAO). (2021). *Agricultural Waste Management: Challenges and Opportunities*.
- Fuhrmann, A., Gold, M., Lau Heckmann, L., Pedersen, P., Shakhnovich, K., Chu, C., Haberkorn, I., Puniamoorthy, N., & Mathys, A. (2025). Comprehensive industry-relevant black soldier fly bioconversion characterisation by a novel chamber system. *Waste Management*, 193, 409-418. <https://doi.org/10.1016/j.wasman.2024.12.016>
- Giner, C., Bagherzadeh, M., Elasri, A., Yamamoto, K., Haverkamp, C., & Gonzalez, D. (2025, enero). *Beyond food loss and waste reduction targets* (inf. téc.).
- Guillaume, J., Mezdoor, S., Marion-Poll, F., Terrol, C., & Schmidely, P. (2023). Asymptotic Estimated Digestibility, a New Indicator of Black Soldier Fly (*Hermetia illucens*) Conversion Efficiency in Relation to Larval Density. *Journal of Insects as Food and Feed*, 9(7), 893-906. <https://doi.org/10.3920/JIFF2022.0103>
- Jenkins, S. N., Langa, S. P., Middleton, J. A., Martin, B. C., Wheat, L., & Gleeson, D. B. (2025). Processing poultry manure with black soldier fly technology lowers N₂O and CO₂ gas emissions from soil. <https://doi.org/10.1163/23524588-00001336>
- Kamilaris, A., Kartakoulis, A., & Prenafeta-Boldú, F. X. (2017). A Review on the Practice of Big Data Analysis in Agriculture. *Computers and Electronics in Agriculture*, 143, 23-37.
- Ko, H., Cassidy, G. J., Shishkov, O., Aydin, E., Hu, D. L., & Goldman, D. I. (2021). Air-Fluidized Aggregates of Black Soldier Fly Larvae. *Frontiers in Physics*, 9, 734447. <https://doi.org/10.3389/fphy.2021.734447>
- Kobelski, A., Hempel, A.-J., Padmanabha, M., Klüber, P., Wille, L.-C., & Streif, S. (2024). Model-Based Process Optimization of Black Soldier Fly Egg Production. *Frontiers in Bioengineering and Biotechnology*, 12, 1404776. <https://doi.org/10.3389/fbioe.2024.1404776>
- Kong, D., Shan, J., Iacoboni, M., & Maguin, S. R. (2012). Evaluating Greenhouse Gas Impacts of Organic Waste Management Options Using Life Cycle Assessment. *Waste Management & Research*, 30(8), 800-812. <https://doi.org/10.1177/0734242X12440479>
- Leddin, D. (2024). The Impact of Climate Change, Pollution and Biodiversity Loss on Digestive Health and Disease. *Gastro Hep Advances*. <https://doi.org/10.1016/j.gastha.2024.01.018>
- Liu, R., Park, K., Psallidas, F., Zhu, X., Mo, J., Sen, R., Interlandi, M., Karanasos, K., Tian, Y., & Camacho-Rodríguez, J. (2023). Optimizing Data Pipelines for Machine Learning in Feature Stores. *Proc. VLDB Endow.*, 16, 4230-4239. <https://doi.org/10.14778/3625054.3625060>
- Nordahl, S. L., Preble, C. V., Kirchstetter, T. W., & Scown, C. D. (2023). Greenhouse Gas and Air Pollutant Emissions from Composting. *Environmental Science & Technology*, 57(6), 2235-2247. <https://doi.org/10.1021/acs.est.2c05846>

- Raissi, M., Perdikaris, P., & Karniadakis, G. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686-707. <https://doi.org/10.1016/j.jcp.2018.10.045>
- Raj, K., & Srivastava, A. K. (2023). Real Time Estimation of GHG Emissions Using IoT Integrated Sensor Fusion. *2023 International Conference on Data Science & Informatics (ICDSI)*, 286-290. <https://doi.org/10.1109/ICDSI60108.2023.00061>
- Rossi, G., Ojha, S., Berg, W., Herppich, W. B., & Schlüter, O. K. (2024). Estimating the dynamics of greenhouse gas emission during black soldier fly larvae growth under controlled environmental conditions. *Journal of Cleaner Production*, 470, 143226. <https://doi.org/10.1016/j.jclepro.2024.143226>
- Singh, A., & Kumari, K. (2019). An inclusive approach for organic waste treatment and valorisation using Black Soldier Fly larvae: A review. *Journal of Environmental Management*, 251, 109569. <https://doi.org/10.1016/j.jenvman.2019.109569>
- Smetana, S., Schmitt, E., & Mathys, A. (2019). Sustainable use of *Hermetia illucens* insect biomass for feed and food: Attributional and consequential life cycle assessment. *Resources, Conservation and Recycling*, 144, 285-296. <https://doi.org/10.1016/j.resconrec.2019.01.042>
- Surendra, K. C., Olivier, R., Tomberlin, J. K., Jha, R., & Khanal, S. K. (2016). Bioconversion of Organic Wastes into Biodiesel and Animal Feed via Insect Farming. *Renewable Energy*, 98, 197-202. <https://doi.org/10.1016/j.renene.2016.03.022>
- Tomberlin, J. K., Klammssteiner, T., Lemke, N., Yadav, P., & Sandrock, C. (2025). BugBook: Black Soldier Fly as a Model to Assess Behaviour of Insects Mass Produced as Food and Feed. *Journal of Insects as Food and Feed*, 11(18), 341-360. <https://doi.org/10.1163/23524588-bja10225>
- Verra. (2024, 16 de abril). *VCS Standard v4.7*. Consultado el 26 de noviembre de 2025, desde <https://verra.org/wp-content/uploads/2024/04/VCS-Standard-v4.7-FINAL-4.15.24.pdf>
- Weichert, D., Link, P., Stoll, A., Rüping, S., Ihlenfeldt, S., & Wrobel, S. (2019). A Review of Machine Learning for the Optimization of Production Processes. *The International Journal of Advanced Manufacturing Technology*, 104, 1889-1902. <https://doi.org/10.1007/s00170-019-03988-5>
- Win, S. S., Ebner, J. H., Brownell, S. A., Pagano, S. S., Cruz-Diloné, P., & Trabold, T. A. (2018). Anaerobic digestion of black soldier fly larvae (BSFL) biomass as part of an integrated biorefinery. *Renewable Energy*, 127, 705-712. <https://doi.org/10.1016/j.renene.2018.04.093>
- WMO. (2025). *WMO Greenhouse Gas Bulletin No. 21: The State of Greenhouse Gases in the Atmosphere Based on Global Observations through 2024*. <https://wmo.int/publication-series/wmo-greenhouse-gas-bulletin-no-21>
- Yavari, A., Mirza, I. B., Bagha, H., Korala, H., Dia, H., Scifleet, P., Sargent, J., Tjung, C., & Shafiei, M. (2023). ArtEMon: Artificial Intelligence and Internet of Things Powered Greenhouse Gas Sensing for Real-Time Emissions Monitoring. *Sensors*, 23(18), 7971. <https://doi.org/10.3390/s23187971>