



Sistema Híbrido para Predicción de Emisiones de CO₂ y CH₄ en la Bioconversión de Residuos con *Hermetia illucens*

John Jairo Leal Gómez

Proyecto de Tesis Doctoral, requisito parcial para optar al título de Doctor en Estudios Ambientales.

Director(a):

Dr. Luis Octavio González Salcedo

Codirectores:

Dr. Luis Fernando Mejía Rodríguez
Dra. Sorany Milena Barrientos Grajales

Universidad Nacional de Colombia
Facultad de Ingeniería y Administración
Doctorado en Estudios Ambientales
Palmira, 2025

Agradecimientos

Listado de símbolos y abreviaturas

Resumen

Título en español

Texto del resumen.

Palabras clave: *Hermetia illucens*, bioconversión de residuos, emisiones de gases, dióxido de carbono, metano, proceso gaussiano, Dynamic Energy Budget

Abstract

Título en inglés

Abstract text.

Keywords: *Hermetia illucens*, waste bioconversion, gas emissions, carbon dioxide, methane, gaussian process, Dynamic Energy Budget

Lista de figuras

4.1. Arquitectura híbrida DEB–MLP. El lazo de calibración opera en ventanas discretas k indexadas por eventos de cierre del reactor. Durante el entrenamiento offline, el comparador alimenta al MLP con pares $(\varepsilon_k, \mathbf{u}_k)$ para ajustar ϕ	43
4.2. Series temporales de la tasa de emisión de CO_2 para una réplica representativa.	54

Lista de tablas

2.1. Presupuesto de incertidumbre para la concentración de CO ₂ corregida (1000 ppm, $T = 30^{\circ}\text{C}$, HR = 70 %).	18
2.2. Métricas de desempeño del sensor NDIR MH-410D para CO ₂ tras calibración y compensación cruzada ($n = 150$, temperatura $30^{\circ}\text{C} \pm 2^{\circ}\text{C}$, HR 60 %-80 %).	19
3.1. Variables de estado del modelo DEB escalado a reactor batch.	26
3.2. Parámetros del modelo DEB para <i>Hermetia illucens</i> a escala de reactor batch.	34
4.1. Comparación de arquitecturas evaluadas para la estimación de biomasa en el Capítulo ??.	45
4.2. Parámetros semilla del modelo DEB, fijos durante la calibración neuronal.	48
4.3. Restricciones de caja para los parámetros libres del modelo DEB.	49
4.4. Desempeño del estimador directo RNA-B en validación cruzada por réplica, contrastado con el MLP calibrador paramétrico.	51
4.5. Comparación epistemológica entre la RNA directa explorada y el MLP calibrador adoptado.	52
4.6. Métricas de desempeño predictivo del sistema híbrido DEB-MLP versus modelo lineal estático de referencia.	53
4.7. Matriz de confusión del detector de anaerobiosis basado en CH ₄ .	54

Contenido

Agradecimientos	II
Listado de símbolos y abreviaturas	III
Resumen	IV
Abstract	V
Lista de figuras	VI
Lista de tablas	VII
Contenido	VIII
1. Introducción General	1
1.1. Contexto: gestión de residuos agroindustriales y cambio climático	1
1.2. Antecedentes y marco conceptual	2
1.2.1. Residuos orgánicos y bioconversión con <i>Hermetia illucens</i>	2
1.2.2. Modelación de emisiones y sistemas inteligentes	3
1.2.3. Gobernanza de datos y ética algorítmica	4
1.2.4. Brechas tecnológicas y oportunidades de investigación	5
1.3. Planteamiento del problema	5
1.4. Pregunta de investigación	6
1.5. Hipótesis de investigación	7
1.5.1. Hipótesis general	7
1.5.2. Hipótesis específicas	7
1.6. Objetivos de la investigación	7
1.6.1. Objetivo general	7
1.6.2. Objetivos específicos	8
1.7. Alcance, delimitaciones y estructura del documento	8
1.7.1. Alcance	8
1.7.2. Delimitaciones	8
1.8. Ajustes metodológicos respecto al anteproyecto aprobado	9
1.9. Estructura del documento	9
2. Instrumentación IoT y Caracterización Metrológica	11
2.1. Descripción del Sistema Experimental	12
2.1.1. Reactor batch y condiciones de laboratorio	12
2.1.2. Biomasa larval y manejo del sustrato	12
2.2. Sensores y Arquitectura de Adquisición	13
2.2.1. Sensor NDIR para CO ₂ y CH ₄	13
2.2.2. Variables ambientales: temperatura y humedad relativa	13
2.2.3. Nodo IoT y arquitectura de comunicación	13

2.3.	Protocolo de Medición en Ventanas Cerradas	14
2.3.1.	Diseño del ciclo de muestreo	14
2.3.2.	Fundamento teórico de la conversión ppm–flujo másico	14
2.4.	Calibración y Caracterización Metrológica	16
2.4.1.	Curvas de calibración frente a patrones certificados	16
2.4.2.	Compensación cruzada e incertidumbre combinada	17
2.5.	Resultados de la Caracterización Instrumental	18
2.5.1.	Linealidad y exactitud del sensor NDIR (CO ₂)	19
2.5.2.	Efecto de la compensación cruzada	19
2.5.3.	Estabilidad temporal y deriva instrumental	19
2.5.4.	Desempeño del sensor de CH ₄ (MH-441D)	20
2.5.5.	Replicabilidad entre nodos IoT	20
2.5.6.	Síntesis y trazabilidad del dato	20
2.6.	Conclusiones del Capítulo	20
3.	Modelo Matemático para la Predicción de Emisiones de CO₂ en el Proceso de Bioconversión con <i>Hermetia illucens</i>	22
3.1.	Introducción	22
3.2.	Fundamentos del Modelo DEB para <i>Hermetia illucens</i>	23
3.2.1.	Estructura de compartimentos de carbono	23
3.2.2.	Flujos metabólicos y producción de CO ₂	24
3.3.	Variables de Estado y Dominio del Sistema	25
3.3.1.	Vector de estado y notación	25
3.3.2.	Variables ambientales y forzamiento externo	26
3.3.3.	Dominio físico y restricciones de no negatividad	27
3.3.4.	Escalamiento de individuo a reactor batch	27
3.4.	Formulación del Sistema de Ecuaciones Diferenciales	28
3.4.1.	Balance del sustrato orgánico	28
3.4.2.	Balance de asimilados en estado cuasi-estacionario	29
3.4.3.	Dinámica de la biomasa estructural	29
3.4.4.	Acumulación de lípidos de reserva	30
3.4.5.	Producción y acumulación de CO ₂	30
3.5.	Cinética de Asimilación y Modulación Ambiental	31
3.5.1.	Funcional respuesta tipo Holling II	31
3.5.2.	Dependencia térmica: modelo de Sharpe–Schoolfield	32
3.6.	Parámetros del Modelo y Restricciones Físicas	33
3.6.1.	Parámetros semilla y variables de calibración	33
3.6.2.	Restricciones de no negatividad y acotamiento	34
3.6.3.	Consistencia dimensional	34
3.6.4.	Cierre del balance de carbono	35
3.6.5.	Subconjunto de parámetros de primera sensibilidad para calibración neuronal	35
3.7.	Análisis Estructural y Consistencia del Balance de Carbono	36
3.7.1.	Homogeneidad dimensional de los flujos metabólicos	36
3.7.2.	Conservación de masa de carbono	37
3.7.3.	Comportamiento cualitativo del sistema	37
3.7.4.	Confrontación con los datos del Capítulo ??	38
3.8.	Conclusiones del Capítulo	38
4.	Sistema Híbrido: Integración Modelo–Datos y Estimación de Biomasa	41
4.1.	Introducción	41
4.2.	Arquitectura del Sistema Híbrido	42
4.2.1.	Flujo offline versus online	43
4.2.2.	Red neuronal physics-informed para biomasa (PI-RNA-B)	43
4.3.	Extractor de Pendientes y Ventanas de Observabilidad	45

4.3.1.	Protocolo de extracción de s_k	45
4.3.2.	Criterios de linealidad y rechazo de ventanas	46
4.4.	Calibrador Neuronal Paramétrico	46
4.4.1.	Arquitectura de la red	46
4.4.2.	Función de pérdida	47
4.4.3.	Entrenamiento two-stage	47
4.5.	Estrategia de Calibración del Modelo DEB	48
4.5.1.	Fase A: Semillas de parámetros desde Eriksen (2022)	48
4.5.2.	Fase B: Ajuste local con series NDIR	48
4.5.3.	Fase C: Corrección neuronal en tiempo real	49
4.6.	Evaluación Comparativa: Estimador Directo de Biomasa versus Calibrador Paramétrico	49
4.6.1.	Motivación y vínculo con el objetivo específico 3	49
4.6.2.	Diseño del estimador directo (RNA-B)	50
4.6.3.	Validación cruzada por réplica (LORO)	50
4.6.4.	Resultados del estimador directo	50
4.6.5.	Análisis de la ambigüedad del problema inverso	51
4.6.6.	Implicaciones para la arquitectura aprobada	51
4.7.	Validación Predictiva y Métricas de Desempeño	51
4.7.1.	Métricas de regresión de la pendiente de CO_2	52
4.7.2.	Análisis de residuos y detección de anaerobiosis	52
4.8.	Resultados de la Integración Modelo–Datos	53
4.8.1.	Desempeño predictivo del sistema híbrido	53
4.8.2.	Inventario dinámico de carbono y discrepancia acumulada	54
4.8.3.	Detección operativa de eventos de anaerobiosis	54
4.9.	Conclusiones del Capítulo	54
5.	Validación Predictiva y Diagnóstico Operativo	56
6.	Conclusiones Generales y Perspectivas	57
A.	Especificaciones técnicas del módulo de sensores	58
B.	Formulación matemática detallada del modelo	59
C.	Algoritmos de aprendizaje automático	60
D.	Datos experimentales completos	61
E.	Comparación teórica: BSF vs. compostaje vs. vertido	62
	Referencias Bibliográficas	62

Capítulo 1

Introducción General

1.1. Contexto: gestión de residuos agroindustriales y cambio climático

El cambio climático, principalmente resultado de las actividades humanas, se ha convertido en uno de los retos más urgentes de nuestra era Allan y Arias, 2023. Desde la época preindustrial, las concentraciones de gases de efecto invernadero (GEI) como el dióxido de carbono (CO_2), el metano (CH_4) y el óxido nitroso (N_2O) han alcanzado niveles sin precedentes. En 2024, estas concentraciones llegaron a 423.9 partes por millón (ppm) para el CO_2 , 1942 partes por billón (ppb) para el CH_4 y 338.0 ppb para el N_2O , según las mediciones globales más recientes WMO, 2025. Si bien una concentración atmosférica de CO_2 cercana al 0.042 % puede parecer nominal en términos volumétricos, su relevancia no reside en la abundancia relativa, sino en las propiedades radiativas intrínsecas de la molécula, la cual absorbe y reemite eficazmente la radiación infrarroja térmica. En consecuencia, este incremento acelerado ha alterado el forzamiento radiativo y ha intensificado el calentamiento global, provocando eventos climáticos extremos, alteraciones significativas en los ecosistemas y una rápida pérdida de biodiversidad.

Dentro de las fuentes antropogénicas de GEI, la gestión inadecuada de residuos orgánicos se destaca como un factor crítico, ya que su descomposición anaeróbica genera grandes cantidades de CH_4 , un gas con un potencial de calentamiento global 28 veces superior al del CO_2 en un horizonte de 100 años. Aunque los océanos y ecosistemas terrestres han actuado históricamente como sumideros naturales, absorbiendo gran parte del CO_2 antropogénico, reportes recientes advierten sobre una reducción en la eficiencia de estos sumideros durante 2024, lo que podría señalar una peligrosa retroalimentación climática. Por tanto, ante los signos de saturación de los mecanismos naturales de absorción y el alto potencial de calentamiento del metano, es urgente desarrollar soluciones innovadoras y sostenibles para mitigar las emisiones actuales, particularmente aquellas vinculadas a la gestión de residuos orgánicos Giner et al., 2025.

Las estrategias convencionales para la gestión de residuos orgánicos —como los rellenos sanitarios, la digestión anaerobia y el compostaje— enfrentan limitaciones significativas. Los rellenos sanitarios generan emisiones prolongadas y difícilmente controlables de metano durante años e incluso décadas; la digestión anaerobia, aunque permite capturar biogás, demanda infraestructura compleja y costosa; y el compostaje, a pesar de su mayor accesibilidad, conlleva emisiones de N_2O y requiere períodos prolongados para lograr la estabilización del material Kong et al., 2012; Nordahl et al., 2023. En contextos agroindustriales de países en desarrollo —donde se concentra la mayor parte de los residuos orgánicos sin tratar—, estas alternativas suelen resultar inviables desde el punto de vista técnico o económico. Justamente esta brecha abre una ventana de oportunidad para tecnologías alternativas basadas en procesos biológicos que puedan ser controlados, escalables y adaptados a estas realidades.

Entre las alternativas emergentes, la bioconversión de residuos orgánicos mediante larvas de *Hermetia illucens* (conocida como mosca soldado negra o BSF, por sus siglas en inglés) ha demostrado ser una tecnología prometedora y transformadora. A diferencia de los métodos convencionales, la BSF opera bajo un enfoque de economía circular: trans-

forma residuos orgánicos en biomasa larval rica en proteínas y lípidos y en fertilizante orgánico de alta calidad (frass), todo mediante procesos biológicos susceptibles de diseño Bermúdez-Serrano y Sánchez-Velázquez, 2023; Surendra et al., 2016. Comparada con métodos tradicionales, la bioconversión con BSF presenta ventajas claras: requiere menor infraestructura, opera en tiempos más cortos (3–4 semanas), funciona sin generación de lixiviados contaminantes y genera productos valiosos. Sin embargo, este potencial contrasta con un vacío de información crítica: la mayoría de las implementaciones operan como una “caja negra”, sin monitoreo ambiental riguroso y sin una cuantificación fiable de los flujos de carbono, lo que impide validar su sostenibilidad real frente al compostaje convencional Jenkins et al., 2025.

Teniendo en cuenta estas limitaciones, se propone la integración de tres componentes tecnológicos complementarios: (1) sensores IoT de bajo costo, (2) modelos matemáticos (EDO) y (3) algoritmos de aprendizaje automático. Esta convergencia tecnológica no es aditiva, sino estructuralmente necesaria para superar las barreras de cada método por separado: mientras los sensores capturan la realidad física pero carecen de contexto (“ceguera semántica”), y los modelos matemáticos aportan coherencia teórica pero fallan ante la variabilidad biológica no parametrizada (“rigidez”), la inteligencia artificial permite cerrar la brecha adaptándose a la estocasticidad del sistema. Es crucial entender que ninguno de estos componentes por sí solo puede validar la sostenibilidad ambiental del proceso; solo su integración híbrida permite transformar datos crudos en evidencia verificable para la toma de decisiones.

El objetivo de esta tesis es desarrollar un sistema híbrido que integre sensores IoT, modelos matemáticos basados en EDO y algoritmos de aprendizaje automático para estimar en tiempo real las emisiones de CO₂ y CH₄ durante la bioconversión de residuos con BSF. El sistema debe: (1) caracterizar dinámicamente las emisiones durante los ciclos productivos; (2) validar predicciones con tolerancia de error aceptable ($\ll 10\%$ MAPE) frente a métodos estándar (cromatografía); y (3) generar herramientas accesibles (dashboard web) que traduzcan datos complejos en información para la toma de decisiones operativas, permitiendo comparar el desempeño ambiental contra una línea base.

El sistema mide: (1) concentraciones de CO₂ y CH₄ mediante sensores NDIR; y (2) variables de proceso (temperatura, humedad, densidad larval estimada). Nota sobre el alcance: No se mide directamente N₂O en esta etapa por limitaciones de costos en sensores de bajo costo, aunque la arquitectura modular del sistema está diseñada para permitir su integración futura, reconociendo su importancia en el balance global de GEI.

La propuesta, sin embargo, no ignora las complejidades del entorno real. Reconoce la necesidad de gestionar la deriva de los sensores en condiciones de humedad extrema para evitar lecturas erróneas, así como la urgencia de diseñar soluciones robustas ante la falta de datos masivos y la conectividad rural inestable. Además, el uso de inteligencia artificial se somete a un escrutinio ético-ambiental, evaluando si el costo energético del procesamiento y los riesgos de sesgo justifican el beneficio operativo, un balance ineludible en el campo de los Estudios Ambientales.

1.2. Antecedentes y marco conceptual

1.2.1. Residuos orgánicos y bioconversión con *Hermetia illucens*

En contextos agroindustriales del sur global —como el Valle del Cauca—, los residuos orgánicos provenientes de cultivos como café, caña y frutas se generan de forma dispersa, en picos estacionales y con alta carga biodegradable, lo que incrementa el riesgo de emisiones de CH₄ cuando su gestión es inadecuada Food and Agriculture Organization of the United Nations (FAO), 2021; Leddin, 2024. Frente a las limitaciones de las estrategias convencionales —rellenos sanitarios, digestión anaerobia y compostaje—, que suelen ser inviables técnica o económicamente en estos entornos Kong et al., 2012; Nordahl et al., 2023, la bioconversión con BSF se ha adoptado crecientemente como una alternativa de economía circular.

La bioconversión de residuos orgánicos mediante larvas en estadios voraces (L3–L5) transforma desechos en biomasa rica en proteínas y lípidos, así como en frass, un fertilizante orgánico de alto valor agronómico Bermúdez-Serrano y Sánchez-Velázquez, 2023; Singh y Kumari, 2019; Surendra et al., 2016. Este proceso se sustenta en una sinergia entre la acción macroscópica de las larvas y la actividad microbiana del sustrato: las larvas fragmentan mecánicamente el

material, aumentando su área superficial, mientras su microbioma intestinal —junto con microorganismos del medio— degrada enzimáticamente polímeros complejos en compuestos asimilables. Esta doble acción reduce entre el 50 % y el 80 % la masa del residuo (base húmeda) y altera drásticamente las propiedades fisicoquímicas del medio (pH, humedad, disponibilidad de nutrientes), generando microambientes dinámicos que condicionan si predominan rutas metabólicas aeróbicas o anaeróbicas. Durante este proceso, el dióxido de carbono (CO_2) se genera principalmente por la respiración aeróbica tanto de las larvas como de la microbiota asociada; estudios estiman que hasta un tercio del carbono ingerido se libera como CO_2 Diener et al., 2009, una emisión altamente sensible a factores como la composición del sustrato, densidad larval, temperatura y oxigenación Bekker et al., 2021; Eriksen, 2022; Rossi et al., 2024.

Aunque la bioconversión muestra un perfil de emisiones potencialmente más favorable que el compostaje tradicional —con reducciones reportadas en CH_4 y N_2O Jenkins et al., 2025—, su implementación a escala carece de sistemas rigurosos para cuantificar y predecir en tiempo real las emisiones gaseosas asociadas. Esta limitación impide su validación como solución climática verificable y obstaculiza su integración en mecanismos de compensación de carbono o políticas de gestión sostenible de residuos. En particular, la dinámica de emisiones, especialmente la de CO_2 —que refleja directamente la actividad biológica en curso—, no ha sido suficientemente modelada mediante herramientas matemáticas capaces de ofrecer estimaciones continuas y predictivas bajo condiciones operativas variables. Así, persiste una brecha crítica entre el potencial ambiental demostrado en ensayos controlados y la capacidad de monitoreo, verificación y escalabilidad requerida para su reconocimiento en estrategias climáticas basadas en datos.

Aunque el metano (CH_4) es un gas de efecto invernadero con un potencial de calentamiento global significativamente mayor que el del dióxido de carbono (CO_2), su generación en sistemas de bioconversión con BSF es generalmente baja debido al carácter predominantemente aeróbico del proceso. No obstante, se incluye su monitoreo como variable de control para detectar condiciones transitoriamente anaeróbicas —por ejemplo, por sobresaturación del sustrato o deficiente aireación— que podrían comprometer la eficiencia del proceso y generar picos no deseados de emisiones. Sin embargo, el foco técnico de esta tesis recae en el CO_2 , ya que constituye el principal indicador cuantitativo y dinámico de la actividad biológica total (tanto larval como microbiana) durante la bioconversión. Además, presenta una señal más estable y continua, lo que facilita su integración en modelos de estimación en tiempo real, y permite una correlación directa con variables operativas clave, como el consumo de sustrato, la biomasa generada y las tasas respiratorias. Por estas razones, el CO_2 se adopta como la variable central para el desarrollo, calibración y validación del sistema híbrido propuesto.

La aptitud de los residuos para la bioconversión varía significativamente según su composición. Subproductos agroindustriales como la pulpa de café o cáscaras de frutas son altamente adecuados, mientras que residuos lignocelulósicos o lodos orgánicos requieren pretratamiento o presentan riesgos sanitarios Bruno et al., 2025; Elsayed et al., 2024. Esta heterogeneidad —común en el Valle del Cauca— subraya la necesidad de sistemas de monitoreo adaptables, capaces de caracterizar el proceso en función del sustrato y las condiciones locales.

La evidencia cuantitativa disponible es fragmentada: se reportan emisiones de CO_2 entre 7.76 y 11.88 g por gramo de larva seca Rossi et al., 2024, o 96.5 g de CO_2 por kg de residuo tratado Fuhrmann et al., 2025, pero sin protocolos estandarizados ni mediciones continuas. Esta incertidumbre impide comparar tecnologías, diseñar políticas públicas informadas o acceder a mecanismos de mercado basados en la mitigación climática.

1.2.2. Modelación de emisiones y sistemas inteligentes

La cuantificación dinámica de emisiones en procesos biológicos exige herramientas que articulen una base mecanicista con capacidad de adaptación empírica. En este contexto, el modelado matemático basado en ecuaciones diferenciales ordinarias (EDO) ha impulsado avances significativos. Por ejemplo, el modelo de crecimiento larval propuesto por Eriksen Eriksen, 2022 integra balances energéticos y cinética logística para simular simultáneamente la acumulación de biomasa y la producción de CO_2 , combinando los principios del enfoque Dynamic Energy Budget (DEB) con eventos biológicos clave del ciclo larval, como las mudas y la metamorfosis. De manera análoga, funciones cinéticas de tipo Monod y Haldane —originalmente desarrolladas para digestión anaerobia— han sido adaptadas con éxito para describir la degradación del sustrato y el crecimiento microbiano en sistemas de bioconversión con insectos Ahlamine et al., 2024; Win et al., 2018.

Si bien los modelos mecanicistas actuales proporcionan una base teórica indispensable, su aplicación directa en entornos operativos dinámicos puede presentar limitaciones de alcance. La literatura Bekker et al., 2021; Rossi et al., 2024 sugiere que, al validarse principalmente bajo condiciones controladas, las formulaciones clásicas a menudo requieren simplificaciones sobre las interacciones simultáneas de variables (temperatura, humedad, oxigenación). Asimismo, el uso de parámetros fijos podría restringir la capacidad del modelo para responder a la variabilidad estocástica del sustrato en campo. Esta diferencia entre las condiciones controladas y la operación real sugiere la conveniencia de explorar enfoques híbridos o basados en datos que complementen la teoría existente con información en tiempo real.

Paralelamente, los avances en sensores de bajo costo y plataformas IoT han facilitado el monitoreo continuo de variables críticas —CO₂, CH₄, temperatura, humedad— en entornos operativos reales Duobiene et al., 2022; Raj y Srivastava, 2023; Yavari et al., 2023. Estos datos, procesados mediante algoritmos de aprendizaje automático (AAA), permiten identificar patrones complejos y no lineales que serían difíciles de capturar mediante reglas explícitas Chen et al., 2021; Weichert et al., 2019.

En particular, la integración de modelos mecanicistas (EDO) con AAA, enfoque conocido en la literatura como *modulado de caja gris* (*grey box modelling*), ha demostrado potencial en sistemas biotecnológicos complejos: mientras el modelo EDO proporciona una estructura interpretable y basada en principios físicos, el AAA permite calibración dinámica de parámetros a partir de datos en tiempo real, mejorando predicciones cuando las condiciones operativas se desvían del escenario de entrenamiento Guillaume et al., 2023; Kobelski, Hempel, Padmanabha, Wille y Streif, 2024.

Sin embargo, esta integración enfrenta desafíos prácticos: (i) los algoritmos de AAA requieren suficientes datos históricos para entrenar sin riesgo de *overfitting*, pero ciclos de bioconversión típicos generan pocas muestras por evento; (ii) la validación cruzada y selección de hiperparámetros requieren cuidado especial en contextos con datos limitados; (iii) la elección entre arquitecturas simples (regresión lineal múltiple) versus complejas (redes neuronales) dependerá del volumen y calidad de datos disponibles. Por ello, esta tesis adopta un enfoque escalonado: comenzar con modelos interpretables, evaluar redes neuronales multicapa si se dispone de base de datos amplia, y validar todas las predicciones contra mediciones de referencia de campo.

1.2.3. Gobernanza de datos y ética algorítmica

La implementación de tecnologías digitales en la gestión de procesos biológicos no es un acto neutral; constituye la creación de un sistema socio-técnico donde convergen biología, código y decisión humana. Desde la perspectiva de los estudios de ciencia, tecnología y sociedad (CTS) y la epistemología ambiental, es imperativo trascender la visión instrumental de la tecnología para abordar las implicaciones éticas y cognitivas de “datificar” la naturaleza.

Uno de los mayores riesgos en la aplicación de la inteligencia artificial (IA) al medio ambiente es la opacidad algorítmica Burrell, 2016. En modelos de caja negra, las decisiones se vuelven inescrutables, generando relaciones de dependencia tecnológica donde el operario obedece sin comprender. Esta tesis adopta una postura ética fundada en la interpretabilidad por diseño. Al integrar modelos mecanicistas basados en ecuaciones diferenciales ordinarias (EDO) —cuyos parámetros tienen significado biológico explícito— con algoritmos de aprendizaje ligeros, el sistema no solo predice eventos (el qué), sino que permite rastrear sus causas fisiológicas o operativas (el porqué), como el exceso de humedad o la acumulación de zonas anaeróbicas. Esta transparencia cognitiva devuelve la agencia al tomador de decisiones y se alinea con los principios de transparencia exigidos por marcos de reporte climático como el IPCC Tier 3 Adadi y Berrada, 2018.

La gobernanza de los datos ambientales plantea interrogantes críticos sobre propiedad, acceso y beneficio. La literatura sobre Big Data en agricultura alerta sobre el “extractivismo de datos”, donde la información generada en territorios rurales es capturada por plataformas externas sin retorno de valor local Carolan, 2020. Esta investigación se alinea con los principios de soberanía de datos y diseño frugal. La arquitectura propuesta es descentralizada: el procesamiento crítico ocurre en el borde (*edge computing*), minimizando la dependencia de infraestructuras en la nube centralizadas y costosas. Esto no solo reduce costos, sino que garantiza que los datos sensibles permanezcan bajo el control del productor.

Finalmente, se reconoce la tensión ontológica entre la complejidad del sistema biológico y su representación digital. Un sensor de CO₂ registra una señal fisicoquímica, pero no captura dimensiones cualitativas como la resiliencia del microbioma o el bienestar larval. Existe el riesgo de caer en el solucionismo tecnológico, asumiendo que lo no medido es irrelevante. Por ello, este marco teórico establece que el sistema híbrido es una herramienta de soporte, no de sustitución. La comprensión más robusta del proceso emerge de la interacción dialógica entre la señal del sensor y la experiencia empírica del operador.

1.2.4. Brechas tecnológicas y oportunidades de investigación

A pesar de los avances, la implementación operativa de sistemas inteligentes en la bioconversión con BSF enfrenta barreras estructurales que limitan su escalabilidad y confiabilidad. La literatura identifica cinco brechas críticas que esta investigación busca abordar:

1. **Materialidad y Resiliencia del Hardware:** Escasa disponibilidad de sensores de bajo costo capaces de mantener la precisión (calibración estable) en las condiciones agresivas del proceso (HR > 80 %), lo que suele derivar en datos ruidosos o deriva instrumental Ahmed et al., 2020.
2. **Interoperabilidad:** Falta de estandarización en protocolos de comunicación que impide la integración fluida entre dispositivos IoT heterogéneos y plataformas de gestión ambiental Van et al., 2022.
3. **Limitaciones de los Modelos de Caja Negra:** Los algoritmos de aprendizaje automático puros, aunque potentes, carecen de restricciones físicas o biológicas explícitas. Esto los hace propensos al *overfitting* y reduce su capacidad de generalización ante condiciones no vistas (como cambios de sustrato), a menos que se hibriden con modelos mecanicistas (EDO) Weichert et al., 2019.
4. **Ausencia de Estándares MRV Dinámicos:** Inexistencia de metodologías validadas para la Medición, Reporte y Verificación (MRV) en tiempo real, lo que excluye a la BSF de los mercados de carbono regulados Herrin, 2021.
5. **Brecha de Implementación Rural:** Dificultades para escalar soluciones dependientes de la nube en contextos con baja infraestructura de conectividad, exigiendo arquitecturas de procesamiento en el borde.

Estas brechas delinean una oportunidad estratégica para el desarrollo de una arquitectura híbrida compuesta por: (i) una red de sensores robustecida para monitoreo ambiental; (ii) modelos EDO para capturar la dinámica biológica base; (iii) algoritmos de corrección por AAA para adaptarse a la variabilidad real; y (iv) una interfaz de soporte a la decisión. Esta integración apunta a transformar la bioconversión de una caja negra biológica a un proceso transparente, tecnológicamente viable y verificable climáticamente Kamilaris et al., 2017.

1.3. Planteamiento del problema

En el contexto tecnológico y biológico, la gestión de la fracción orgánica de los residuos sólidos municipales (FORSU) enfrenta limitaciones estructurales en sus rutas convencionales. Los rellenos sanitarios operan como reactores anaerobios no controlados de larga duración; el compostaje, aunque accesible, requiere extensos tiempos de estabilización y conlleva riesgos de emisiones de óxido nitroso (N₂O); y la digestión anaerobia, pese a su ventaja energética, demanda inversiones de capital, a menudo inviables para la escala agroindustrial.

En este escenario, la bioconversión mediante larvas de *Hermetia illucens* (BSF) se ha consolidado como una alternativa de alta eficiencia. A diferencia de los métodos pasivos, este es un sistema biológico acelerado: durante su fase larval (aprox. 14 días), el insecto incrementa su masa corporal hasta 4000 veces mediante un metabolismo voraz y exotérmico que ocurre en simbiosis con una microbiota activa. Este proceso transforma la materia orgánica en biomasa (proteína)

y fertilizante (frass) con baja huella hídrica, posicionándose como una herramienta clave para la economía circular Bermúdez-Serrano y Sánchez-Velázquez, 2023; Surendra et al., 2016.

Sin embargo, a pesar de estas ventajas biológicas, la ausencia de cuantificación dinámica y rigurosa de las emisiones de gases de efecto invernadero (GEI), particularmente CH_4 y CO_2 , genera una incertidumbre crítica. Actualmente, la tecnología opera mayoritariamente como una “caja negra”: se conocen los insumos y productos, pero se ignora la dinámica de los flujos gaseosos intermedios, basándose en factores de emisión estáticos o extrapolaciones de otros procesos (compostaje) que no reflejan la realidad metabólica de la BSF Fuhrmann et al., 2025; Rossi et al., 2024.

Esta fragmentación del conocimiento tiene consecuencias técnicas, operativas y de gobernanza climática:

Primero, al no existir factores de emisión específicos para BSF en las metodologías del IPCC ni en el GHG Protocol, cualquier balance de carbono se basa en supuestos no verificados. Esto introduce sesgos sistemáticos que pueden subestimar significativamente las emisiones de CH_4 , especialmente bajo condiciones de manejo subóptimas. La consecuencia no es solo técnica, sino ética: se corre el riesgo de asignar beneficios climáticos no reales a una tecnología que, sin monitoreo, podría superar las emisiones del compostaje en escenarios de anaerobiosis no controlada (greenwashing).

Segundo, la imposibilidad de detectar en tiempo real picos de CH_4 impide identificar fallas operativas críticas —como sobrepoblación larval, exceso de humedad o deficiente aireación— que generan microambientes anaeróbicos. Estas condiciones no solo aumentan las emisiones de GEI, sino que reducen la eficiencia de conversión, incrementan la mortalidad larval y degradan la calidad del frass, impactando directamente la viabilidad económica del sistema. Medir las emisiones es, por tanto, una herramienta de control de procesos.

Tercero, la carencia de sistemas de Medición, Reporte y Verificación (MRV) alineados con estándares internacionales constituye una barrera estructural para el acceso a mecanismos de financiación climática. Según el Banco Mundial, los mercados de carbono modernos exigen trazabilidad cuantitativa y verificable Bank, 2023. Normativas como el Verified Carbon Standard (VCS) estipulan que la cuantificación debe ser “real, medible y permanente” Verra, 2024. Sin datos empíricos robustos, la industria de insectos no puede certificar sus reducciones a escala industrial Smetana et al., 2019.

Esta brecha se ve agravada por la escasa integración de tecnologías de monitoreo con modelos predictivos. La mayoría de las implementaciones actuales carecen de retroalimentación en tiempo real, operando con parámetros fijos que ignoran la dinámica no lineal del proceso biológico Kamilaris et al., 2017; Liu et al., 2023.

Frente a este escenario, esta tesis propone un sistema híbrido que transforme la cuantificación de emisiones en una herramienta de gestión ambiental y operativa. Al estimar de forma continua y precisa las emisiones de CO_2 y CH_4 , el sistema permitirá: (1) generar la evidencia empírica necesaria para establecer factores de emisión específicos y alinear la BSF con marcos climáticos globales; (2) optimizar el proceso mediante la detección temprana de ineficiencias a partir de los gases medidos; y (3) construir una trazabilidad verificable que permita hacia el futuro la participación de los productores agroindustriales en economías circulares con credenciales climáticas robustas.

1.4. Pregunta de investigación

¿En qué medida la integración de un modelo matemático basado en ecuaciones diferenciales ordinarias, sensores IoT de bajo costo y algoritmos de aprendizaje automático permite desarrollar un sistema híbrido que no solo estime con precisión las emisiones de CO_2 y CH_4 , sino que constituya una herramienta de monitoreo dinámico para fundamentar la toma de decisiones operativas y generar métricas verificables del desempeño ambiental en la bioconversión de residuos agroindustriales con *Hermetia illucens*?

1.5. Hipótesis de investigación

1.5.1. Hipótesis general

Un sistema híbrido que integre modelamiento matemático basado en ecuaciones diferenciales ordinarias (EDO), sensores IoT de bajo costo y algoritmos de aprendizaje automático permite estimar las emisiones de CO₂ y CH₄ en tiempo real con un error absoluto medio porcentual (MAPE) inferior al 10 % respecto a mediciones de referencia. Esta capacidad de monitoreo continuo proporciona, a su vez, indicadores dinámicos sobre la eficiencia metabólica del proceso, permitiendo identificar ineficiencias operativas (como la anaerobiosis) y cuantificar el desempeño ambiental del sistema más allá de las estimaciones estáticas tradicionales.

1.5.2. Hipótesis específicas

H1: **Precisión instrumental de bajo costo.** Los sensores NDIR de bajo costo, sometidos a protocolos de calibración y preacondicionamiento de señal, permiten medir concentraciones de CO₂ y CH₄ en el entorno de bioconversión con una desviación (MAPE) ≤ 15 % respecto a equipos certificados de laboratorio.

H2: **Capacidad predictiva del modelo mecanicista.** El modelo de EDO, fundamentado en la bioenergética del crecimiento larval y parametrizado con datos locales, es capaz de predecir la tasa de producción de CO₂ durante el ciclo experimental de 15 días con un error porcentual absoluto medio (MAPE) ≤ 15 %. Esta validación, realizada en ventanas de observación de 30 minutos cada dos días, demuestra que el modelo captura correctamente la dinámica metabólica subyacente del sistema.

H3: **Refinamiento por aprendizaje automático.** La integración de una capa de corrección mediante algoritmos de aprendizaje automático reduce el error residual del modelo de EDO en al menos un 30 %, logrando que el sistema híbrido alcance un MAPE < 10 % ante perturbaciones no modeladas.

H4: **Valor para la gestión operativa.** La incorporación de medición directa de CH₄ en el esquema de monitoreo permite la detección inmediata de eventos transitorios de anaerobiosis (picos de emisión) que los modelos estáticos basados en factores de emisión promedio omiten. Esto proporciona indicadores dinámicos que habilitan acciones correctivas en tiempo real, reduciendo la incertidumbre operativa frente a las estimaciones puramente teóricas.

Las métricas de precisión (H1–H3) se evaluarán bajo condiciones experimentales de laboratorio (30°C $\pm$ 2°C, HR 60–70 %), mientras que la H4 se validará mediante análisis de escenarios operativos.

1.6. Objetivos de la investigación

1.6.1. Objetivo general

Desarrollar un sistema híbrido a escala de laboratorio —integrado por modelado mecanicístico (EDO), sensores IoT de bajo costo y algoritmos de aprendizaje automático— para la estimación de la tasa de producción de CO₂ y la detección de eventos de emisión de CH₄ en la bioconversión de residuos con *Hermetia illucens*, con el fin de generar métricas de desempeño ambiental aplicables a la gestión de residuos agroindustriales.

1.6.2. Objetivos específicos

1. **Instrumentación:** Configurar y calibrar un módulo de sensores NDIR de bajo costo para la medición de CO₂ y CH₄, determinando su precisión y desviación (MAPE) frente a un instrumento de referencia bajo las condiciones de temperatura y humedad propias del cultivo de *H. illucens*.
2. **Modelado matemático:** Adaptar y parametrizar un modelo de EDO basado en la bioenergética de *Hermetia illucens* para estimar la tasa de respiración (CO₂), evaluando su capacidad predictiva en ventanas temporales durante un ciclo de bioconversión de 15 días.
3. **Integración híbrida:** Desarrollar un algoritmo de estimación de estados mediante redes neuronales que infiera la biomasa larval a partir de datos operativos, integrando esta variable como entrada dinámica al modelo mecanicista para mejorar la precisión de la estimación de emisiones.
4. **Métricas ambientales:** Validar la utilidad del sistema para la gestión ambiental mediante la detección de eventos de anaerobiosis (CH₄) y la cuantificación del carbono emitido, contrastando estos indicadores dinámicos frente a estimaciones estáticas.

1.7. Alcance, delimitaciones y estructura del documento

1.7.1. Alcance

Esta tesis desarrolla y valida un sistema híbrido a escala de laboratorio (mesocosmos) para la estimación dinámica de emisiones de CO₂ en la bioconversión con *Hermetia illucens*. El alcance técnico comprende: (i) la instrumentación de un nodo IoT con sensores NDIR de bajo costo para CO₂ y CH₄; (ii) la formulación de un modelo mecanicista basado en EDO siguiendo el marco Dynamic Energy Budget (DEB); (iii) la integración de un calibrador neuronal parámetro (MLP) que refine las predicciones del modelo DEB; y (iv) la validación del sistema mediante métricas de regresión, detección de anaerobiosis e inventario dinámico de carbono.

El sistema no pretende sustituir el juicio técnico del operador, sino actuar como herramienta de soporte a la decisión. Su propósito es proporcionar a productores información cuantitativa para correlacionar decisiones operativas (densidad, sustrato, aireación) con la huella de carbono resultante.

1.7.2. Delimitaciones

- **Variables de GEI:** No se mide directamente N₂O en esta etapa por limitaciones de costo en sensores de bajo costo, aunque la arquitectura modular del sistema está diseñada para permitir su integración futura, reconociendo su importancia en el balance global de GEI.
- **Horizonte temporal experimental:** La validación experimental se restringe a la fase de crecimiento larval temprano (días 0–7 del ciclo) con dos dietas: sustrato de pollo estándar y mezcla de residuos agroindustriales (pulpa de café, cáscaras de plátano y naranja). Los estadios tardíos (L5/prepupa) y la fase de metamorfosis quedan fuera del alcance experimental.
- **Condiciones ambientales:** El protocolo experimental opera en régimen isoterma ($30 \pm 2^\circ\text{C}$) con humedad relativa controlada (60–80 %). La modulación térmica de Sharpe–Schoolfield se valida en este rango; la variación térmica intencional queda como trabajo futuro.
- **Escala espacial:** Los reactores batch tienen volumen útil de 0.7–0.9 L con 700 larvas y 250 g de sustrato. Los resultados son extrapolables a escala piloto con reservas metodológicas, pero no a escala industrial sin validación adicional.

- **Arquitectura de ML:** El sistema explora la estimación directa de biomasa mediante RNA (objetivo específico 3, dimensión exploratoria) y la arquitectura híbrida DEB–MLP calibrador paramétrico. La RNA directa se implementa y valida como baseline; el MLP calibrador es la arquitectura aprobada para la operación del sistema.

1.8. Ajustes metodológicos respecto al anteproyecto aprobado

El objetivo específico 3 del proyecto doctoral aprobado planteó originalmente: “Desarrollar un algoritmo de estimación de estados mediante redes neuronales que infiera la biomasa larval a partir de datos operativos, integrando esta variable como entrada dinámica al modelo mecanicista (DEB) para mejorar la precisión de la estimación de CO_2 ”.

Durante la fase de implementación, esta vía fue explorada rigurosamente mediante una arquitectura de red neuronal directa (RNA-B) entrenada con mediciones destructivas de biomasa como supervisión. Los resultados de validación cruzada por réplica (LORO, $k = 6$ folds) revelaron un fallo sistemático: la RNA-B alcanzó un MAPE de entrenamiento del 7,8 % pero divergió a > 40 % en validación, emitiendo predicciones no físicas (crecimiento negativo en ventanas donde el metabolismo larval obliga $dB/dt \geq 0$).

Este resultado negativo no constituye una incapacidad del algoritmo, sino una propiedad estructural del problema inverso. El operador forward del modelo DEB, $\mathcal{F} : (S, E, B, L) \mapsto \dot{m}_{CO_2}$, no es inyectivo en ventanas cortas de observación ($\tau \leq 5$ min): múltiples trayectorias del espacio de estados biológicos pueden producir idénticas tasas respiratorias instantáneas. Con un corpus de entrenamiento destructivo limitado ($N \approx 30$ observaciones por campaña), la red neuronal carece de información suficiente para desambiguar estas trayectorias metabólicamente equivalentes, incurriendo en sobreajuste estructural a las réplicas de entrenamiento y pérdida de generalización inter-réplica.

Frente a esta evidencia, se adoptó una decisión metodológica deliberada, discutida y validada por la dirección de tesis: preservar el componente de redes neuronales exigido por el objetivo específico 3, pero reconfigurar su función epistemológica. En lugar de intentar invertir $\mathcal{F}^{-1}$ directamente desde el espacio de observables —vía estadísticamente mal condicionada—, se implementó un **calibrador neuronal paramétrico** (MLP) que opera como corrector de escala sobre el subconjunto de parámetros de primera sensibilidad del DEB: $\{\tau_h, \rho_{conv}, T_{opt}\}$. El MLP nunca recibe biomasa como supervisión; su señal de error es el residuo de CO_2 $\varepsilon_k = s_k - J_k^{DEB}$, delegando la dinámica biológica al modelo mecanicista forward y reduciendo el espacio de corrección a una dimensión manejable ($\mathbb{R}^3$) donde la identificabilidad biofísica está garantizada.

En consecuencia, el objetivo específico 3 se cumple en su **dimensión exploratoria**: se probó, documentó y descartó formalmente la vía de estimación directa de biomasa mediante RNA pura, aportando evidencia empírica sobre los límites de las redes neuronales de caja negra en sistemas biológicos con muestreo destructivo limitado. Simultáneamente, se cumple en su **dimensión operativa**: la red neuronal integrada (MLP corrector) mejora la precisión del sistema híbrido hasta $MAPE = 8,3$ % y $R^2 = 0,78$, superando ampliamente la línea base estática y preservando la interpretabilidad fisiológica de cada parámetro. Por tanto, se considera cumplido el objetivo específico 3 en su totalidad: se desarrolló un algoritmo de estimación de estados mediante redes neuronales (el MLP calibrador), que infiere indirectamente el estado del sistema a través de la corrección paramétrica y mejora la precisión del modelo DEB para la estimación de CO_2 . La biomasa estructural $B(t)$ se recupera indirectamente como salida del DEB re-simulado con parámetros corregidos, no como predicción directa de la red.

La Sección 4.6 documenta la evaluación comparativa formal entre la RNA-B (explorada y descartada) y el MLP calibrador (adoptado), garantizando la trazabilidad completa del ajuste metodológico.

1.9. Estructura del documento

El documento se organiza en seis capítulos principales más anexos técnicos:

Capítulo 1 Introducción General. Situación del problema, contexto de residuos agroindustriales y cambio climático, bioconversión con BSF, planteamiento del problema, pregunta de investigación, hipótesis, objetivos y alcance.

Capítulo 2 Instrumentación IoT y Caracterización Metrológica. Diseño experimental, sensores NDIR, arquitectura del nodo IoT, protocolo de ventanas cerradas, calibración frente a patrones certificados, compensación cruzada por temperatura y humedad, presupuesto de incertidumbre GUM y resultados de caracterización instrumental.

Capítulo 3 Modelo Matemático para la Predicción de Emisiones. Fundamentos del modelo DEB para *H. illucens*, variables de estado, formulación del sistema de EDO, cinética de asimilación (Holling II), modulación térmica (Sharpe–Schoolfield), parámetros semilla y restricciones físicas, análisis estructural y consistencia del balance de carbono.

Capítulo 4 Sistema Híbrido: Integración Modelo–Datos. Arquitectura del sistema híbrido DEB–MLP, extractor de pendientes en ventanas cerradas, calibrador neuronal paramétrico, estrategia de calibración por fases (semillas Eriksen, ajuste local NDIR, corrección neuronal), evaluación comparativa RNA-B vs. MLP, validación predictiva y resultados de integración modelo–datos.

Capítulo 5 Validación Predictiva y Diagnóstico Operativo. Inventario dinámico de carbono, clasificador de umbral para detección de anaerobiosis, métricas MRV comparables con la literatura, plataforma técnica de soporte a la decisión y semáforo operativo.

Capítulo 6 Conclusiones Generales y Perspectivas. Síntesis de aportes, limitaciones del estudio, trabajos futuros y recomendaciones para la escalabilidad del sistema.

Los anexos técnicos complementan el cuerpo del documento con especificaciones de hardware, formulaciones matemáticas detalladas, algoritmos de aprendizaje automático, datos experimentales completos y comparaciones teóricas con tecnologías alternativas.

Capítulo 2

Instrumentación IoT y Caracterización Metrológica

labelchap:instrumentacion

La bioconversión de residuos orgánicos mediante *Hermetia illucens* opera, en la mayoría de las implementaciones industriales y académicas, como un proceso de “caja negra”: se controlan los insumos (sustrato, densidad larval, humedad) y se cuantifican los productos (biomasa, frass), pero los flujos gaseosos intermedios permanecen sin caracterizar dinámicamente (Fuhrmann et al., 2025; Jenkins et al., 2025). Esta opacidad metrológica impide establecer factores de emisión específicos, validar balances de carbono en tiempo real y detectar condiciones operativas subóptimas —como la anaerobiosis transitoria— que degradan tanto el desempeño ambiental como la eficiencia zootécnica del sistema (Bekker et al., 2021; Rossi et al., 2024).

Frente a esta brecha, la instrumentación basada en sensores de infrarrojo no dispersivo (NDIR) y arquitecturas IoT de bajo costo ha emergido como una alternativa viable para el monitoreo continuo de CO₂ y CH₄ en entornos agroindustriales (Duobiene et al., 2022; Raj & Srivastava, 2023; Yavari et al., 2023). Sin embargo, la transferencia directa de hardware diseñado para ambientes controlados (invernaderos, almacenes) a reactores de bioconversión expone limitaciones críticas: deriva instrumental por condensación, saturación de señal en presencia de amoníaco y compuestos orgánicos volátiles, y una incertidumbre que frecuentemente excede los umbrales exigidos por protocolos de Medición, Reporte y Verificación (MRV) (Ahmed et al., 2020; Herrin, 2021). Por tanto, la viabilidad de estos sensores no depende únicamente de sus especificaciones de fabricante, sino de una caracterización metrológica local que incluya curvas de calibración frente a patrones certificados, compensación cruzada por variables ambientales y una estimación rigurosa de la incertidumbre combinada (Van et al., 2022).

En este contexto, el presente capítulo aborda el diseño experimental y la caracterización del módulo de adquisición que alimentará el sistema híbrido descrito en los capítulos posteriores. Se estructura en cinco bloques. Primero, se describe el reactor batch y las condiciones de laboratorio en las que se ejecutaron los ciclos de bioconversión (Sección 2.1). Segundo, se detallan los sensores NDIR seleccionados, las variables ambientales auxiliares y la arquitectura del nodo IoT con computación en el borde (Sección 2.2). Tercero, se presenta el protocolo de medición en ventanas cerradas —estandarizado para estimar tasas de emisión en sistemas de residuos sólidos— incluyendo la conversión de concentración (ppm) a flujo másico (g min⁻¹) (Sección 2.3). Cuarto, se exponen las curvas de calibración, los modelos de compensación cruzada y el presupuesto de incertidumbre metrológica (Sección 2.4). Finalmente, se sintetizan los resultados de la caracterización instrumental y se establece la trazabilidad del dato crudo que servirá de entrada al modelo bioenergético del Capítulo 3 y al estimador híbrido del Capítulo 4.

El objetivo metrológico central es garantizar que la señal de los sensores NDIR presente una correlación de Pearson $R > 0,85$ y un error porcentual absoluto medio (MAPE) inferior al 15 % respecto a un instrumento de referencia, bajo las condiciones de temperatura y humedad relativas propias del cultivo de *H. illucens* (30 °C ± 2 °C, HR 60 %-80 %).

El cumplimiento de este umbral constituye la hipótesis H1 y habilita la integración posterior con el modelo matemático sin propagación excesiva de errores instrumentales.

2.1. Descripción del Sistema Experimental

El diseño experimental se estructuró como un ensayo de laboratorio controlado en un reactor batch cerrados, orientado a cuantificar las emisiones de CO₂ y CH₄ durante el ciclo larval de *Hermetia illucens* bajo condiciones ambientales estandarizadas. La elección de un sistema batch responde a la necesidad de mantener trazabilidad de masa (sustrato, biomasa, gases) en ventanas temporales discretas, facilitando la correlación posterior con el modelo bioenergético del Capítulo 3 (Eriksen, 2022; Padmanabha et al., 2020). A continuación se detallan las especificaciones del reactor, las condiciones de laboratorio y el manejo de la biomasa y el sustrato.

2.1.1. Reactor batch y condiciones de laboratorio

Los ensayos se ejecutaron en un contenedor de polipropileno alimentario tipo *tupper* o envase de conservación doméstica, con dimensiones aproximadas de 12 × 12 × 5 cm, lo cual brinda una capacidad útil estimada de 0,7 L a 0,9 L. El sistema se operó como reactor batch cerrado mediante tapa de plástico con sellado por presión. Se insertaron sondas de sensores NDIR para CO₂ (modelo Winsen MH-410D, rango 0–5000 ppm, resolución ± 50 ppm) y CH₄ (modelo Winsen MH-441D, rango 0–10 % en volumen, resolución 0,01 %), así como una sonda de temperatura/humedad relativa (??). El *headspace* o volumen de cabeza libre —esto es, el espacio de aire comprendido entre la superficie del sustrato y la tapa del contenedor— se estandarizó en aproximadamente 0,3 L a 0,4 L, asumiendo una carga de sustrato de 250 g que ocupa aproximadamente 2 cm de altura, con el fin de mantener comparable la acumulación gaseosa durante las ventanas cerradas de medición. Como los tiempos de medición fueron cortos, se registró la temperatura del entorno y se constató que era aproximadamente constante, manteniendo un valor de 30 °C ± 2 °C y una humedad relativa (HR) del 60 %–80 %, rangos reportados como óptimos para la maximización de la tasa metabólica larval (Nayak et al., 2024; Salam et al., 2022).

El protocolo de medición se estructuró en eventos discretos espaciados cada 2 días. En cada evento, se cerraba herméticamente el reactor y se registraba la acumulación gaseosa mediante los sensores NDIR hasta alcanzar la saturación de los instrumentos. Una vez saturados los sensores, se abría el reactor para restaurar las condiciones ambientales y continuar el ciclo de bioconversión. Este procedimiento se repitió 6–7 veces a lo largo de un periodo experimental de 12–15 d, tras el cual las larvas alcanzaron el estadio de pre-pupa..

2.1.2. Biomasa larval y manejo del sustrato

Las larvas de *Hermetia illucens* se obtuvieron de una colonia estabilizada en la Sede Palmira (Universidad Nacional de Colombia), sincronizadas por edad (5 d post-eclosión, estadio L3 inicial) y pesadas en grupo para determinar la biomasa inicial húmeda. La densidad de siembra se fijó en aproximadamente 700 larvas por reactor, distribuidas sobre una carga de 250 g de sustrato.

El sustrato consistió en dos tratamientos experimentales: (i) residuos de procesamiento avícola (pollinaza) y (ii) una mezcla homogeneizada de residuos agroindustriales (pulpa de café, *Coffea arabica*, y cáscaras de frutas tropicales, plátano y papaya, en proporción 70:30 base húmeda), seleccionada por su alta aptitud para la bioconversión y disponibilidad estacional en el Valle del Cauca (Bruno et al., 2025). En ambos tratamientos, la masa de sustrato se ajustó a 250 g por reactor. La humedad inicial del sustrato se reguló a 65 % ± 5 % mediante adición controlada de agua destilada, valor dentro del intervalo 60 %–80 % que Bekker et al. (2021) identifican como crítico para el mantenimiento de la tasa de asimilación y el crecimiento exponencial larval. El pH se registró entre 5.5 y 6.5, sin corrección química, dado que la acidificación natural por metabolismo microbiano no alcanzó niveles inhibitorios durante el ciclo.

Se establecieron seis réplicas ($n = 6$) por condición experimental, más dos controles (sustrato sin larvas), distribuidos en bloques completos al azar para controlar efectos de posición. No se ejecutó volteo mecánico del sustrato, salvo en las réplicas destinadas al estudio de perturbación (Capítulo 5), para preservar la formación de gradientes naturales de oxigenación que permiten evaluar la validez del modelo DEB bajo heterogeneidad real. Al final del ciclo (12–15 d), se procedió a la separación mecánica de larvas del sustrato residual (frass), pesaje individual de una submuestra ($n = 30$ por réplica) y determinación de materia seca (60°C, 48 h) para expresar la biomasa en base seca.

2.2. Sensores y Arquitectura de Adquisición

La capa de percepción del sistema está compuesta por un nodo IoT de bajo costo que integra sensores NDIR para CO₂ y CH₄, un sensor ambiental digital (temperatura y humedad relativa) y un microcontrolador con capacidad de procesamiento en el borde. Esta arquitectura responde al principio de “soberanía de datos” y diseño frugal: el procesamiento crítico ocurre localmente, minimizando la dependencia de conectividad continua y preservando la trazabilidad del dato crudo (Duobiene et al., 2022; Van et al., 2022). A continuación se describen los componentes hardware, sus especificaciones metrológicas y la lógica de telemetría.

2.2.1. Sensor NDIR para CO₂ y CH₄

El dióxido de carbono se midió mediante un sensor NDIR (modelo MH-410D, Winsen), basado en el principio de absorción selectiva de radiación infrarroja a 4,26 μm , longitud de onda correspondiente a la banda de vibración asimétrica de la molécula de CO₂. Este dispositivo ofrece un rango de detección de 0–5000 ppm y resolución de ± 50 ppm, alimentado a 5 V DC.

Para el metano se empleó un sensor NDIR (modelo MH-441D, Winsen), con rango de detección de 0–10 % en volumen y resolución de 0,01 %. Ambos sensores operan con alimentación independiente mediante baterías y se comunican con el microcontrolador central a través del protocolo UART TTL a 3,3 V.

2.2.2. Variables ambientales: temperatura y humedad relativa

La temperatura del aire de cabeza libre y la humedad relativa (HR) se registraron mediante un sensor digital SHT30 (Sensirion, Suiza), comunicado por bus I2C al microcontrolador central. Las especificaciones metrológicas del dispositivo son: para temperatura, precisión de $\pm 0,3$ °C en el rango operativo -40 °C a 125 °C con resolución de $0,1$ °C; para humedad relativa, rango de 0 a 100 % RH, precisión de ± 3 % RH y resolución de $0,1$ % RH.

Estas variables actúan como forzantes ambientales que modulan la cinética metabólica larval (Eriksen, 2022) y condicionan la formación de microambientes anaeróbicos: valores de HR > 80 % favorecen la saturación de poros y la generación de CH₄, mientras que valores < 50 % reducen la tasa de asimilación (Bekker et al., 2021; Salam et al., 2022). Por ello, las lecturas de HR se utilizaron no solo como variables de compensación cruzada para los sensores NDIR, sino como predictores operativos del riesgo de anaerobiosis.

2.2.3. Nodo IoT y arquitectura de comunicación

El microcontrolador central del nodo es un ESP32-WROOM-32 (Espressif Systems), seleccionado por su bajo consumo energético, conectividad Wi-Fi integrada y capacidad de procesamiento en el borde (dual-core 240 MHz). Este dispositivo ejecuta tres tareas concurrentes durante los eventos de medición: (i) adquisición multiparamétrica de los sensores NDIR y del SHT30 mediante UART TTL a 3,3 V e I2C, respectivamente; (ii) filtrado digital de ruido mediante media móvil exponencial (EMA, $\alpha = 0,3$); y (iii) telemetría asíncrona mediante protocolo MQTT sobre red

Wi-Fi hacia un broker desplegado en un computador central de la red local, donde se almacena la información de forma persistente.

La arquitectura de comunicación sigue una topología de dos capas. La capa local (edge) almacena los datos en memoria Flash interna del ESP32 como respaldo temporal, garantizando continuidad del registro ante fallos transitorios de la red Wi-Fi. La capa de agregación (gateway) ejecuta un broker MQTT ligero (Mosquitto) en el computador central, que recibe las tramas codificadas con sello de tiempo (timestamp), identificador de réplica y checksum CRC16. Este diseño permite operación autónoma durante los eventos de medición y sincronización de datos hacia el almacenamiento central una vez restablecida la conectividad.

El firmware del nodo se desarrolló en Arduino Framework con las siguientes rutinas de robustez: (a) watchdog timer de hardware que reinicia el sistema ante bloqueos mayores a 30 s; (b) validación de rangos físicos (sanitización) que descarta lecturas de CO₂ fuera del rango 0–5000 ppm o HR > 100 % como errores de sensor; y (c) sincronización horaria por NTP al inicio de cada sesión de medición para mantener trazabilidad temporal. La elección de componentes modulares permite el reemplazo individual de sensores sin descartar la unidad de procesamiento, reduciendo la generación de residuos electrónicos en el entorno de bioconversión.

2.3. Protocolo de Medición en Ventanas Cerradas

La cuantificación de flujos gaseosos en sistemas de bioconversión con sustrato sólido exige un compromiso entre trazabilidad de masa y mínima perturbación del sistema. El protocolo de ventanas cerradas (*closed static chambers*) se adopta como solución de campo ante la imposibilidad de usar cámaras de flujo continuo sin alterar la oxigenación larval (Parodi et al., 2020; Rossi et al., 2024). En esta sección se describe el ciclo de muestreo y se deriva formalmente la conversión de concentración (ppm) a flujo másico instantáneo (g/min), puente metrológico entre el sensor NDIR y el balance de carbono del modelo DEB.

2.3.1. Diseño del ciclo de muestreo

El protocolo se estructuró en eventos discretos espaciados cada 2 días. En cada evento se cerraba herméticamente el reactor (tapa de plástico con sellado por presión) y se iniciaba el registro continuo de acumulación gaseosa hasta la saturación del instrumento (5000 ppm para CO₂ o 10 % para CH₄). Las lecturas se tomaron cada 10 s en un microcontrolador ESP32, descartando los primeros 2 min para homogeneización del *headspace*. La duración efectiva de cada ventana varió biológicamente: estadios tempranos (L3–L4) requirieron tiempos prolongados, mientras que L5 acortó el intervalo por respiración elevada. Esta variabilidad captura la dinámica real sin truncar artificialmente picos de emisión.

El reactor consistió en un recipiente rígido de 0,8 L con 700 larvas aproximadamente y 250 g de sustrato húmedo, dejando un volumen de cabeza libre $V_{\text{head}} = 0,35 \text{ L} (\pm 0,05 \text{ L})$. El número de eventos válidos por réplica osciló entre 6 y 7 a lo largo de un ciclo de 12–15 d.

2.3.2. Fundamento teórico de la conversión ppm–flujo másico

La señal cruda $C(t)$ (ppm) se convierte en flujo másico mediante tres principios físico-químicos acoplados: ecuación de estado del gas ideal, ley de Dalton de presiones parciales y balance de masa transitorio en un volumen de control de paredes rígidas.

Hipótesis de gas ideal y densidad molar

En las condiciones del ensayo ($P_{\text{atm}} \approx 101,3 \text{ kPa}$, $T_{\text{air}} \approx 303 \text{ K}$) la mezcla gaseosa (aire + trazas de CO_2) se comporta como gas ideal con error despreciable ($\ll 0,3 \%$) (Atkins & de Paula, 2014). La densidad molar del CO_2 es:

$$\rho_{\text{CO}_2} = \frac{P_{\text{atm}} \cdot M_{\text{CO}_2}}{R \cdot T_{\text{air}}} \quad (2.1)$$

donde $M_{\text{CO}_2} = 44,01 \text{ g/mol}$ y $R = 8,314 \text{ kPa} \cdot \text{L}/(\text{mol} \cdot \text{K})$. En Palmira resulta $\rho_{\text{CO}_2} \approx 1,80 \text{ g/L}$.

Fracción volumétrica y masa acumulada

El sensor NDIR reporta concentración volumétrica C_{CO_2} en ppm, definida por la IPCC como la razón molar respecto al total de la mezcla multiplicada por 10^6 (IPCC, 2006):

$$C_{\text{CO}_2}(t) = \frac{n_{\text{CO}_2}(t)}{n_{\text{total}}} \times 10^6 \implies y_{\text{CO}_2}(t) = C_{\text{CO}_2}(t) \times 10^{-6} \quad (2.2)$$

donde y_{CO_2} es la fracción molar, igual a la fracción volumétrica para gases ideales. La masa acumulada en el *headspace* es:

$$m_{\text{CO}_2}(t) = y_{\text{CO}_2}(t) \cdot \rho_{\text{CO}_2} \cdot V_{\text{head}} = \frac{M_{\text{CO}_2} \cdot P_{\text{atm}} \cdot V_{\text{head}}}{R \cdot T_{\text{air}}} \cdot y_{\text{CO}_2}(t) \quad (2.3)$$

Balance de masa transitorio y flujo másico

El reactor batch cerrado es un volumen de control sin entrada de masa gaseosa durante la medición. La única fuente de CO_2 es la respiración biológica del sistema larva-sustrato. Derivando la ecuación (2.3) respecto al tiempo (con P_{atm} , V_{head} y T_{air} constantes en la ventana corta de medición):

$$\dot{m}_{\text{CO}_2}(t) = \frac{dm_{\text{CO}_2}}{dt} = \underbrace{\frac{M_{\text{CO}_2} \cdot P_{\text{atm}} \cdot V_{\text{head}}}{R \cdot T_{\text{air}}} \times 10^{-6}}_{\kappa} \cdot \frac{dC_{\text{CO}_2}}{dt} \quad (2.4)$$

El factor κ ($\text{g} \cdot \text{min}/\text{ppm}$) actúa como coeficiente de proporcionalidad entre la pendiente de concentración y el flujo másico instantáneo. En la práctica, la derivada se aproxima por regresión lineal sobre la serie $C(t)$ durante la ventana de acumulación, descartando los puntos iniciales de equilibración ($t < 2 \text{ min}$). La pendiente $\Delta C/\Delta t$ (ppm/min) se sustituye en la ecuación (2.4) para obtener el flujo promedio de la ventana.

La linealización es válida si la tasa de producción biológica varía lentamente respecto al tiempo de integración (hipótesis de *quasi-estacionariedad*). En este reactor, las ventanas de saturación duran entre 10 min y 60 min, intervalo en que el metabolismo larval no experimenta cambios abruptos de escala fisiológica (Eriksen, 2022). El coeficiente de determinación $R^2 > 0,95$ garantiza que el error de linealización es inferior al 2 %.

Corrección por fugas

El sellado por presión no es hermético perfecto. La fuga sigue una cinética de primer orden proporcional al gradiente de concentración (Hutchinson & Mosier, 1994):

$$\left. \frac{dC_{\text{int}}}{dt} \right|_{\text{fuga}} = -\lambda(C_{\text{int}} - C_{\text{ext}}) \quad (2.5)$$

con $C_{\text{ext}} \approx 400$ ppm. La constante $\lambda \approx 0,003 \text{ min}^{-1}$ se determinó experimentalmente mediante ensayos de decaimiento con inyección de CO_2 patrón en reactores sin sustrato. El flujo corregido resulta:

$$\dot{m}_{\text{corr}} = \dot{m}_{\text{obs}} + \lambda \cdot m_{\text{CO}_2}(t) \quad (2.6)$$

Esta corrección fue menor al 5 % del flujo total en todas las réplicas; se conserva en la formulación para garantizar trazabilidad metrológica.

Propagación de incertidumbre

La incertidumbre del flujo másico se propaga conforme al GUM (JCGM 100:2008) (JCGM, 2008) a partir de fuentes tipo A (repetibilidad de la pendiente $\Delta C/\Delta t$) y tipo B (resolución del sensor MH-410D: 50 ppm; precisión de V_{head} : $\pm 0,05$ L; variabilidad de T_{air} : ± 2 °C; presión: $\pm 0,5$ kPa). La incertidumbre expandida $U = k \cdot u_c$ con $k = 2$ (≈ 95 % de confianza) resulta del orden de ± 12 % para $\dot{m}_{\text{CO}_2}$, valor aceptable para un sistema de bajo costo en contexto agroindustrial (Biagi et al., 2024; Parodi et al., 2020).

El mismo procedimiento se aplica al CH_4 con $M_{\text{CH}_4} = 16,04$ g/mol. Sin embargo, dado que sus concentraciones fueron frecuentemente inferiores al umbral de detección operativo del MH-441D en condiciones predominantemente aeróbicas, los flujos de CH_4 se reportaron como <LOQ salvo en eventos de anaerobiosis detectados (Capítulo 5).

2.4. Calibración y Caracterización Metrológica

La validez del sistema híbrido descrito en los capítulos posteriores depende de manera crítica de la calidad del dato crudo generado por los sensores NDIR de bajo costo. Como se anticipó en la Sección 2.3, estos dispositivos exhiben deriva instrumental ante fluctuaciones de temperatura y humedad, así como una respuesta no lineal en los extremos del rango dinámico (Biagi et al., 2024; Herrin, 2021). Por ello, una caracterización metrológica rigurosa —incluyendo curvas de calibración frente a patrones certificados, compensación cruzada por variables ambientales y un presupuesto de incertidumbre conforme a la guía GUM— constituye un requisito previo indispensable para satisfacer la hipótesis H1 (MAPE < 15 %, $R > 0,85$) (Parodi et al., 2020; Rossi et al., 2024). En esta sección se detalla el protocolo de calibración, los modelos de ajuste y la estimación de la incertidumbre combinada para las concentraciones de CO_2 y CH_4 .

2.4.1. Curvas de calibración frente a patrones certificados

La calibración del sensor NDIR MH-410D para CO_2 se ejecutó mediante inyección secuencial de mezclas gaseosas certificadas (certificado NIST-traceable, incertidumbre ± 2 % del valor nominal) en una cámara de calibración de 10 L

a temperatura controlada ($25\text{ }^{\circ}\text{C} \pm 1\text{ }^{\circ}\text{C}$) y HR $50\% \pm 5\%$. Se seleccionaron cinco puntos de calibración distribuidos logarítmicamente sobre el rango operativo esperado: 0, 500, 1000, 2000 y 5000 ppm de CO_2 en matriz de nitrógeno balanceado. En cada punto se registraron 30 lecturas consecutivas del sensor (frecuencia 1 Hz), descartando las primeras 5 para permitir el equilibrio térmico de la cavidad óptica.

La relación entre la lectura cruda del sensor S_{raw} (ppm) y la concentración patrón C_{ref} se modeló mediante regresión lineal ponderada por la inversa de la varianza de repetibilidad en cada punto:

$$C_{\text{cal}} = a \cdot S_{\text{raw}} + b \quad (2.7)$$

Los coeficientes ajustados resultaron $a = 0,982 \pm 0,012$ y $b = 42\text{ ppm} \pm 18\text{ ppm}$, con coeficiente de determinación $R^2 = 0,9987$ y error cuadrático medio de calibración (RMSEC) de 68 ppm. El sesgo sistemático positivo de 42 ppm (offset) se atribuye a la presencia residual de CO_2 en la línea de inyección y fue corregido algebraicamente en el firmware del nodo IoT. La no-linealidad residual, cuantificada como desviación máxima respecto a la recta de ajuste, fue del 1,2 % del fondo de escala, valor inferior al 3 % especificado por el fabricante.

Para el sensor NDIR MH-441D de CH_4 , dado que su principio de detección es idéntico (absorción infrarroja a $3,31\text{ }\mu\text{m}$), se aplicó el mismo modelo lineal:

$$C_{\text{CH}_4, \text{cal}} = a' \cdot S'_{\text{raw}} + b' \quad (2.8)$$

Los patrones certificados de CH_4 en aire sintético se prepararon a concentraciones 0, 500, 1000 y 2000 ppm (subrango del intervalo completo 0–10 %, acorde a las bajas emisiones esperadas en condiciones predominantemente aeróbicas). Los coeficientes ajustados fueron $a' = 0,976 \pm 0,018$ y $b' = 12\text{ ppm} \pm 9\text{ ppm}$, con $R^2 = 0,995$ y RMSEC de 45 ppm. La incertidumbre ligeramente mayor respecto al canal de CO_2 se atribuye a la menor selectividad espectral del MH-441D ante interferencias de vapor de agua en la banda de $3,31\text{ }\mu\text{m}$. Por esta razón, el canal de CH_4 se reserva como indicador de eventos de anaerobiosis (detección de picos) y no como cuantificador principal de flujos máscicos, función que se asigna al modelo DEB validado con CO_2 (Capítulo 3).

2.4.2. Compensación cruzada e incertidumbre combinada

La deriva del sensor NDIR por temperatura y humedad relativa se caracterizó mediante un diseño factorial completo 3×3 : tres niveles de temperatura ($25\text{ }^{\circ}\text{C}$, $30\text{ }^{\circ}\text{C}$, $35\text{ }^{\circ}\text{C}$) y tres de HR (50 %, 70 %, 90 %), con inyección de patrón CO_2 a 1000 ppm en cada condición. Los resultados confirmaron una dependencia significativa ($p < 0,001$, ANOVA bifactorial): la sensibilidad del sensor decrece aproximadamente $0,3\text{ }^{\circ}\text{C}^{-1}$ al aumentar la temperatura, mientras que la HR $> 80\%$ introduce una dispersión adicional del $\pm 5\%$ por condensación transitoria sobre la ventana óptica (Biagi et al., 2024; Herrin, 2021).

Para compensar estos efectos, se implementó un modelo de corrección multivariante de primer orden:

$$C_{\text{corr}} = C_{\text{cal}} \cdot [1 + \alpha(T - T_{\text{ref}}) + \beta(\text{HR} - \text{HR}_{\text{ref}})] \quad (2.9)$$

con $T_{\text{ref}} = 25\text{ }^{\circ}\text{C}$, $\text{HR}_{\text{ref}} = 50\%$, y coeficientes empíricos $\alpha = -3,2 \times 10^{-3}\text{ K}^{-1}$ y $\beta = 1,8 \times 10^{-3}$. Este modelo, validado con un conjunto de prueba independiente ($n = 20$), redujo el MAPE del 18,4 % (sensor crudo) al 11,2 % (compensado), cumpliendo con holgura el umbral de la hipótesis H1.

Presupuesto de incertidumbre. La incertidumbre de la concentración corregida C_{corr} se descompuso en contribuciones tipo A (evaluación estadística) y tipo B (evaluación por otros medios), siguiendo los principios de la *Guide to*

the Expression of Uncertainty in Measurement (GUM). Las fuentes identificadas y sus incertidumbres estándar $u(x_i)$ se resumen en la cuadro 2.1.

Tabla 2.1: Presupuesto de incertidumbre para la concentración de CO₂ corregida (1000 ppm, $T = 30\text{ }^{\circ}\text{C}$, HR = 70 %).

Fuente	Tipo	$u(x_i)$	Coef. sensibilidad c_i
Repetibilidad del sensor (tipo A)	A	12 ppm	1,0
Resolución del NDIR (50 ppm)	B	14,4 ppm	1,0
Incetidumbre del patrón certificado	B	20 ppm	1,0
Deriva por temperatura ($\pm 2\text{ }^{\circ}\text{C}$)	B	6,4 ppm	1,0
Deriva por HR ($\pm 5\text{ }\%$)	B	9,0 ppm	1,0
Corrección de linealidad residual	B	12 ppm	1,0
Incetidumbre combinada u_c		26,3 ppm	
Incetidumbre expandida U ($k = 2$)		52,6 ppm (5,3 %)	

La incertidumbre combinada u_c se calculó como la raíz cuadrada de la suma de los cuadrados (RSS), asumiendo independencia de las fuentes:

$$u_c(C_{\text{corr}}) = \sqrt{\sum_{i=1}^N c_i^2 \cdot u^2(x_i)} \quad (2.10)$$

La incertidumbre expandida $U = k \cdot u_c$, con factor de cobertura $k = 2$ (nivel de confianza aproximado del 95 %), resultó de 52,6 ppm para una concentración nominal de 1000 ppm, equivalente al 5,3 % del valor medido. Este valor se encuentra dentro del umbral del 15 % exigido por H1 y se considera aceptable para un sensor de bajo costo en un entorno agroindustrial no controlado (Biagi et al., 2024).

Para la conversión a flujo másico descrita en la Sección 2.4, la incertidumbre de $\dot{m}_{\text{CO}_2}$ se propagó a partir de $u_c(C_{\text{corr}})$, la incertidumbre del volumen de cabeza libre ($\pm 0,05\text{ L}$, tipo B) y la de la pendiente $\Delta C / \Delta t$ (error estándar de la regresión lineal, tipo A). El resultado final fue una incertidumbre expandida del $\pm 12\text{ }\%$ para el flujo másico de CO₂, valor que se incorpora como banda de error en las figuras de validación del Capítulo 4.

En síntesis, la caracterización metrológica demuestra que el módulo de sensores NDIR, sometido a calibración con patrones certificados y compensación cruzada por temperatura/humedad, alcanza una precisión suficiente para alimentar el modelo bioenergético sin introducir sesgos sistemáticos mayores al 5 %. La trazabilidad del dato queda establecida desde la lectura cruda hasta el flujo másico corregido, habilitando la integración con el estimador híbrido DEB-MLP de los capítulos siguientes.

2.5. Resultados de la Caracterización Instrumental

La validación del módulo de adquisición se fundamenta en tres ejes de desempeño metrológico: (i) linealidad y exactitud frente a patrones certificados, (ii) estabilidad temporal bajo condiciones de operación continuada, y (iii) capacidad de replicabilidad entre unidades. A continuación se presentan los resultados obtenidos durante la caracterización del sensor NDIR MH-410D para CO₂ y del MH-441D para CH₄, integrados en el nodo IoT descrito en la Sección 2.3 y sometidos al protocolo de calibración detallado en la Sección 2.5. Los indicadores de desempeño se reportan en términos del coeficiente de correlación de Pearson (R), el error porcentual absoluto medio (MAPE) y la incertidumbre expandida (U , $k = 2$), conforme a los criterios establecidos en la hipótesis H1.

2.5.1. Linealidad y exactitud del sensor NDIR (CO₂)

La curva de calibración ajustada según la ecuación (2.7) exhibió una relación lineal prácticamente perfecta en el rango 0–5000 ppm, con coeficiente de determinación $R^2 = 0,9987$ y pendiente $a = 0,982 \pm 0,012$ (ver ??). La comparación directa entre las lecturas compensadas del sensor NDIR ($n = 150$ observaciones agrupadas por nivel de patrón) y las concentraciones certificadas arrojó una correlación de Pearson $R = 0,997$ ($p < 0,001$), superando holgadamente el umbral de $R > 0,85$ especificado en H1. El MAPE calculado sobre el conjunto completo de validación fue del 11,2 %, valor inferior al límite del 15 % y comparable con resultados reportados para sensores NDIR de bajo costo en ambientes controlados de invernadero (Biagi et al., 2024; Yavari et al., 2023).

El sesgo sistemático (offset de 42 ppm) se mantuvo constante durante toda la campaña de calibración, sin deriva detectable en el tiempo ($p = 0,34$, prueba t de Student para pendiente nula), lo que indica estabilidad del emisor infrarrojo y del detector piroeléctrico bajo uso intermitente. La no-linealidad residual, cuantificada como desviación máxima de los puntos experimentales respecto a la recta de mínimos cuadrados, fue del 1,2 % del fondo de escala, atribuible a la respuesta asintótica del detector en la región superior (> 4000 ppm), zona que, en la práctica operativa del reactor de bioconversión, raramente se alcanza salvo en eventos de falla de aireación.

Tabla 2.2: Métricas de desempeño del sensor NDIR MH-410D para CO₂ tras calibración y compensación cruzada ($n = 150$, temperatura $30^\circ\text{C} \pm 2^\circ\text{C}$, HR 60 %–80 %).

Métrica	Valor obtenido	Umbral H1
Correlación de Pearson (R)	0,997	$> 0,85$
MAPE (%)	11,2	< 15
Incertidumbre expandida U ($k = 2$)	$\pm 5,3$ %	$< \pm 15$ %
Sesgo sistemático (offset)	42 ppm	Corregido en firmware
No-linealidad residual	1,2 % f.e.	< 3 % (espec. fabricante)

2.5.2. Efecto de la compensación cruzada

La aplicación del modelo de corrección multivariante (ecuación (2.9)) redujo drásticamente la dispersión de las lecturas en condiciones de alta humedad. En ensayos de validación independiente ($n = 60$ observaciones, temperatura $30^\circ\text{C} \pm 2^\circ\text{C}$, HR variable entre 50 % y 90 %), el MAPE del sensor crudo fue del 18,4 %, mientras que tras compensación descendió al 11,2 %. La mejora fue más pronunciada en HR > 80 %, donde la condensación transitoria sobre la ventana óptica generaba lecturas erráticas superiores a 200 ppm de desviación respecto al patrón. Tras la corrección, el 95 % de las observaciones en este régimen quedaron dentro de ± 100 ppm del valor certificado, validando la robustez del modelo empírico para el entorno agresivo del reactor de bioconversión (Biagi et al., 2024; Herrin, 2021).

2.5.3. Estabilidad temporal y deriva instrumental

Se ejecutó un ensayo de estabilidad de 14 d (duración típica de un ciclo larval) inyectando diariamente un patrón único de CO₂ a 1000 ppm y registrando la respuesta del sensor cada 6 h. El análisis de tendencia temporal mediante regresión lineal sobre los residuos de calibración no reveló deriva significativa ($\beta_{\text{tiempo}} = -0,8$ ppm/day, $p = 0,42$), confirmando que la vida útil efectiva del elemento sensible supera el horizonte temporal de un ciclo de bioconversión completo. La desviación estándar de repetibilidad a corto plazo (30 lecturas consecutivas en 30 s) fue de 12 ppm, valor que se incorporó como componente tipo A en el presupuesto de incertidumbre de la cuadro 2.1.

2.5.4. Desempeño del sensor de CH₄ (MH-441D)

Dado que las concentraciones de metano en el reactor de bioconversión operado bajo condiciones predominantemente aeróbicas fueron consistentemente inferiores al umbral operativo de cuantificación del MH-441D en campo (aproximadamente 100 ppm, determinado por la dispersión del ruido de fondo por interferencia de vapor de agua), la validación de este canal se realizó mediante inyección controlada de patrones certificados en la cámara de calibración. La relación lineal (ecuación (2.8)) se confirmó con $R^2 = 0,995$ en el subrango 100–2000 ppm. Sin embargo, la sensibilidad cruzada con vapores de agua y compuestos orgánicos volátiles (VOCs) emitidos por el sustrato en descomposición introdujo un ruido de fondo equivalente a 100 ppm de CH₄, impidiendo la cuantificación fiable de flujos máscicos bajos en las condiciones reales del reactor.

Por ello, el canal de CH₄ se operó en modo binario: una lectura que excediera 300 ppm (tres veces el ruido de fondo estimado) durante dos ventanas de muestreo consecutivas se clasificó como “evento de anaerobiosis”, activando la alerta operativa descrita en el Capítulo 5. Esta estrategia, aunque sacrifica la cuantificación continua, preserva la sensibilidad diagnóstica del sistema y se alinea con el rol residual asignado al CH₄ en la arquitectura híbrida: indicador de falla operativa, no variable de estado del modelo DEB (Parodi et al., 2020; Rossi et al., 2024).

2.5.5. Replicabilidad entre nodos IoT

Se desplegaron tres unidades idénticas del nodo ESP32+MH-410D en paralelo durante un ciclo de bioconversión completo ($n = 6$ réplicas por nodo). El análisis de concordancia mediante el coeficiente de correlación intraclass (ICC, modelo de medidas absolutas) arrojó un valor de 0,94 (95 % CI: 0,89–0,97) para las concentraciones de CO₂, indicando excelente replicabilidad entre unidades. El MAPE inter-nodo fue del 7,3 %, inferior al MAPE sensor-referencia, lo que valida la reproducibilidad del montaje electrónico y del protocolo de calibración aplicado.

2.5.6. Síntesis y trazabilidad del dato

En conjunto, los resultados de la caracterización instrumental confirman que el módulo de sensores NDIR de bajo costo, una vez sometido a calibración local con patrones certificados y compensación cruzada por temperatura/humedad, satisface los criterios de la hipótesis H1: correlación $R = 0,997 > 0,85$ y MAPE = 11,2 % < 15 % (cuadro 2.2). La incertidumbre expandida del 5,3 % para concentraciones de CO₂ y del 12 % para flujos máscicos (tras propagación de la derivada temporal) se consideran aceptables para un sistema de monitoreo continuo en un entorno agroindustrial tropical, donde las alternativas de referencia (cromatografía de gases) resultan inaccesibles por costo e infraestructura (Biagi et al., 2024; Raj & Srivastava, 2023).

La trazabilidad del dato queda establecida mediante la cadena: lectura cruda → corrección de offset → compensación cruzada (T , HR) → conversión a flujo máscico con incertidumbre propagada. Este flujo, documentado en el firmware del nodo y en los metadatos de la base de datos, garantiza que cada punto de la serie temporal que alimentará el Capítulo 3 (modelo DEB) y el Capítulo 4 (estimador híbrido DEB–MLP) cuente con una estimación cuantificada de su fiabilidad, habilitando el análisis de sensibilidad del sistema híbrido ante el error instrumental.

2.6. Conclusiones del Capítulo

En este capítulo se estableció la base instrumental y metrológica sobre la cual descansa el sistema híbrido de predicción de emisiones. Se diseñó, implementó y caracterizó un módulo de adquisición basado en sensores NDIR de bajo costo (MH-410D para CO₂ y MH-441D para CH₄), integrado en un nodo IoT con procesamiento en el borde mediante ESP32. El protocolo de ventanas cerradas, con duración biológicamente variable (10 min a 60 min) hasta la saturación del instrumento y posterior restauración de condiciones ambientales, permitió cuantificar tasas de emisión sin perturbar la

oxigenación del reactor ni inducir hipoxia larval, mientras que la derivación formal de conversión ppm→g/min habilitó la expresión de flujos másicos compatibles con el balance de carbono del modelo bioenergético.

La calibración frente a patrones certificados y la compensación cruzada por temperatura y humedad relativa redujeron el MAPE del sensor NDIR del 18,4 % (crudo) al 11,2 % (corregido), con una correlación de Pearson $R = 0,997$ respecto al patrón y una incertidumbre expandida del 5,3 % para concentraciones de CO₂. Estos valores satisfacen holgadamente los umbrales de la hipótesis H1 ($R > 0,85$, MAPE < 15 %) y validan la viabilidad de sensores de bajo costo para monitoreo continuo en entornos agroindustriales tropicales, donde la infraestructura de referencia tradicional resulta inaccesible (Biagi et al., 2024; Raj & Srivastava, 2023).

Se identificaron, asimismo, las limitaciones estructurales del hardware que condicionan el alcance del sistema. El canal de CH₄, afectado por sensibilidad cruzada con vapor de agua y compuestos orgánicos volátiles (VOCs) emitidos por el sustrato, no alcanzó resolución suficiente para cuantificar flujos másicos continuos en las condiciones reales del reactor; por ello, se operó como clasificador binario de eventos de anaerobiosis (umbral 300 ppm), función que, si bien sacrifica la cuantificación, preserva la utilidad diagnóstica operativa prevista para el Capítulo 5. La deriva en condiciones de HR > 90 % y la no-linealidad residual por encima de 4000 ppm quedan documentadas como fuentes de incertidumbre a monitorear durante la validación experimental de los capítulos siguientes (Herrin, 2021; Rossi et al., 2024).

La trazabilidad del dato crudo quedó garantizada mediante la cadena documentada: lectura cruda → corrección de offset → compensación cruzada (T , HR) → conversión a flujo másico con incertidumbre propagada. Esta trazabilidad habilita la integración del Capítulo 2 con el modelo DEB del Capítulo 3 —donde los flujos $\dot{m}_{\text{CO}_2}(t)$ alimentarán la validación de las ecuaciones de estado— y con el estimador híbrido DEB–MLP del Capítulo 4, donde la incertidumbre instrumental se incorporará como varianza de observación en la capa de corrección neuronal (Eriksen, 2022; Padmanabha et al., 2020).

En síntesis, el capítulo entrega un flujo de datos crudos validados, con error cuantificado y trazable, que constituye la entrada indispensable para cerrar el ciclo del sistema híbrido: sensores → modelo → estimador → métricas ambientales.

Capítulo 3

Modelo Matemático para la Predicción de Emisiones de CO₂ en el Proceso de Bioconversión con *Hermetia illucens*

Resumen del capítulo. Se desarrolla la generalización del modelo Dynamic Energy Budget de Eriksen (2022) desde la escala individual a la escala de reactor batch. Se formulan las ecuaciones de estado para sustrato, asimilados, biomasa, lípidos y CO₂, se demuestra la consistencia dimensional y la conservación de masa de carbono, y se analiza el comportamiento cualitativo del sistema bajo modulación térmica. **Palabras clave:** Dynamic Energy Budget, *Hermetia illucens*, balance de carbono, ecuaciones diferenciales, cinética Holling II, Sharpe–Schoolfield.

3.1. Introducción

El Capítulo ?? estableció la base instrumental y metrológica que garantiza la trazabilidad del dato crudo proveniente de los reactores batch de bioconversión. Mediante sensores NDIR de bajo costo, calibración frente a patrones certificados y compensación cruzada por temperatura y humedad relativa, se obtuvo una serie temporal de flujos máscicos de CO₂ —expresada como $\dot{m}_{\text{CO}_2}(t)$ en g min^{-1} — con una incertidumbre expandida del $\pm 12\%$ y un MAPE del 11,2 % respecto al instrumento de referencia (Sección 2.5). Estos datos validados satisfacen la hipótesis H1 ($R > 0,85$, MAPE $< 15\%$) y constituyen la entrada empírica indispensable para cerrar el ciclo del sistema híbrido: sensores → modelo → estimador → métricas ambientales.

No obstante, la señal $\dot{m}_{\text{CO}_2}(t)$, por sí sola, permanece como un *proxy* físico cuya interpretación bioenergética no es inmediata. Un flujo de CO₂ de, por ejemplo, $0,45 \text{ g min}^{-1}$ en el día 7 del ciclo larval puede reflejar una tasa de asimilación elevada con metabolismo aeróbico eficiente, o bien una fracción creciente de respiración microbiana asociada a zonas anaeróbicas transitorias —condición que el sensor de CH₄ (Capítulo 5) detectaría como evento de anaerobiosis. La necesidad de *desagregar* el flujo gaseoso en sus componentes fisiológicos —mantenimiento somático, síntesis de biomasa estructural, acumulación de lípidos de reserva y respiración microbiana asociada— exige un modelo mecanicista que articule la cinética de asimilación del sustrato con la termodinámica del crecimiento larval.

En este contexto, el presente capítulo desarrolla la generalización del modelo Dynamic Energy Budget (DEB) propuesto por Eriksen (2022) desde la escala individual larval hasta la escala de reactor batch. El objetivo central es formular un sistema de ecuaciones diferenciales ordinarias (EDO) que prediga la tasa de producción de CO₂ como resultado emergente de los flujos metabólicos de carbono: ingesta, asimilación, distribución entre compartimentos de reserva y estructura, y costos energéticos de mantenimiento y síntesis. El modelo DEB se parametriza con valores semilla reportados en la literatura (Eriksen, 2022; Padmanabha et al., 2020), dejando un subconjunto reducido de parámetros de

primera sensibilidad —por ejemplo, el factor de conversión de asimilados a biomasa y los coeficientes de modulación térmica— para su ajuste local en el Capítulo 4 mediante confrontación con las series de sensores NDIR.

La estructura del capítulo se organiza en siete secciones. La Sección 3.2 presenta los fundamentos del modelo DEB para *Hermetia illucens*, incluyendo la arquitectura de compartimentos de carbono y los flujos metabólicos que generan CO_2 . La Sección 3.3 define las variables de estado, sus dominios físicos y las condiciones iniciales derivadas del protocolo experimental del Capítulo ???. La Sección 3.4 formula el sistema de EDO que gobierna la dinámica del sustrato, los asimilados, la biomasa estructural, los lípidos de reserva y la acumulación de CO_2 . La Sección 3.5 introduce la cinética de asimilación tipo Holling II y la modulación térmica mediante el modelo de Sharpe–Schoolfield. La Sección 3.6 detalla los parámetros del modelo, sus unidades, rangos semilla y las restricciones físicas que garantizan la disipación positiva y la conservación de masa. La Sección 3.7 analiza la consistencia dimensional, el balance de carbono y el comportamiento cualitativo del sistema; las demostraciones formales de existencia, unicidad y estabilidad de las soluciones se remiten al Anexo ?? para no interrumpir el hilo argumental del capítulo. Finalmente, la Sección 3.8 sintetiza los hallazgos y establece el puente hacia la integración híbrida con el estimador de biomasa del Capítulo 4.

Es importante precisar el alcance del capítulo. El metano (CH_4) no se incorpora como variable de estado en las EDO; dado que el proceso opera predominantemente en régimen aeróbico, el CH_4 se trata como residual diagnóstico de eventos de anaerobiosis transitoria, cuya detección y cuantificación se abordan en el Capítulo 5. Asimismo, el modelo asume homogeneidad espacial en el reactor batch (supuesto de sistema *lumped*), de modo que los gradientes de oxigenación y temperatura dentro del lecho de sustrato se promedian en una única variable ambiental efectiva. Esta simplificación, aunque conservadora, es consistente con la escala de los reactores de 0,7–0,9 L utilizados en la caracterización instrumental y permite mantener el sistema en un número manejable de ecuaciones sin pérdida sustancial de capacidad predictiva a escala piloto (Padmanabha et al., 2020; Rossi et al., 2024).

En síntesis, este capítulo transforma los datos crudos validados del Capítulo ?? en una narrativa bioenergética cuantitativa: interpreta *qué* procesos biológicos producen el CO_2 medido, *cuánto* carbono se destina a cada compartimento y *bajo qué* condiciones ambientales la predicción mecanicista es fiable. El resultado es un modelo DEB escalado a reactor batch, listo para ser calibrado y validado contra sensores en el Capítulo 4.

3.2. Fundamentos del Modelo DEB para *Hermetia illucens*

El Dynamic Energy Budget (DEB) constituye un marco teórico unificador para describir el metabolismo de organismos heterótrofos mediante balances de masa y energía a lo largo de su ciclo de vida (Eriksen, 2022). A diferencia de modelos empíricos de crecimiento —que ajustan curvas logísticas o de Gompertz sin desagregar los flujos subyacentes—, el DEB explicita cómo la materia ingerida se distribuye entre mantenimiento, crecimiento somático, reserva reproductiva y disipación metabólica, expresando cada flujo en unidades de carbono por unidad de tiempo.

En el contexto de la bioconversión con *Hermetia illucens*, el modelo DEB adquiere una función predictiva dual: no solo estima la acumulación de biomasa larval, sino que cuantifica la tasa de respiración —y por ende la emisión de CO_2 — como resultado inevitable de los costos de mantenimiento y síntesis. Esta sección resume los principios del DEB escalado a larvas de BSF y su adaptación al reactor batch descrito en el Capítulo ??.

3.2.1. Estructura de compartimentos de carbono

Siguiendo la parametrización de Eriksen (2022), se define un sistema de cinco compartimentos de carbono interconectados. Las variables E , B y L se expresan primero como contenidos específicos por larva (gC/larva) y luego se escalan al reactor completo; S y C_{CO_2} son variables extensivas del reactor (gC):

1. **Sustrato orgánico disponible (S):** masa total de carbono orgánico en el reactor susceptible de ser ingerida por las larvas, expresada en gC . Incluye los polímeros degradables (carbohidratos, proteínas, lípidos) pero excluye

la fracción lignocelulósica recalcitrante, que en el sustrato de pulpa de café y cáscaras de frutas (Sección ??) representa menos del 15 % de la masa total (Bruno et al., 2025).

2. **Reserva de asimilados (E):** carbono absorbido por el intestino larval y almacenado temporalmente antes de su destino a metabolismo energético o biosíntesis. Eriksen la identifica como el “banco” de carbono que amortigua la variabilidad entre ingesta y demanda metabólica. Su unidad base es gC/larva; el contenido total del reactor es $E_{\text{tot}} = N_{\text{larvas}} \cdot E$.
3. **Biomasa estructural (B):** carbono incorporado en tejidos somáticos (músculo, cutícula, sistema nervioso, tracto digestivo). Esta variable se correlaciona directamente con la biomasa húmeda medida destructivamente cada 48 h en el protocolo del Capítulo ??, mediante un factor de conversión ρ_{conv} (gC/g biomasa húmeda) que se calibrará localmente. Unidad base: gC/larva.
4. **Lípidos de reserva (L):** fracción de carbono destinada al almacenamiento energético de largo plazo, predominante en estadios tardíos (L5–prepupa). Grausa et al. (2023) documentan que esta fracción puede alcanzar hasta el 35 % de la biomasa seca en sustratos ricos en carbohidratos, y constituye un sumidero de carbono paralelo a la estructura. Unidad base: gC/larva.
5. **Dióxido de carbono acumulado (C_{CO_2}):** carbono total emitido como CO₂ por respiración larval y microbiana, expresado en gC. En el reactor batch cerrado, esta variable se vincula directamente con la concentración medida por el sensor NDIR mediante la ecuación de conversión derivada en la Sección ??.

La elección del carbono como *currency* metabólica —en lugar de la energía en joules— responde a dos criterios prácticos. Primero, los sensores NDIR miden directamente la concentración de CO₂, que es un *proxy* lineal del carbono respirado si se desprecia la fracción disuelta en el sustrato (menor al 2 % en condiciones de pH 5.5–6.5, según el equilibrio CO₂/HCO₃[−] a 30°C). Segundo, los balances de masa de carbono permiten validación cruzada con el método de *mass balance* estándar en estudios de BSF (Parodi et al., 2020; Rossi et al., 2024).

3.2.2. Flujos metabólicos y producción de CO₂

El metabolismo larval se descompone en cinco flujos principales. Salvo indicación explícita, las tasas $\dot{I}$, $\dot{A}$, $\dot{M}$, $\dot{G}_B$, $\dot{G}_L$ y $\dot{D}$ se expresan como flujos específicos por larva (gC/larva/d), de modo que el balance total del reactor se obtiene multiplicando por N_{larvas} :

Ingesta ($\dot{I}$) Velocidad a la que el carbono del sustrato pasa al tracto digestivo. Está limitada por la densidad larval, la humedad del sustrato y la disponibilidad física de alimento. Diener et al. (2009) reportan tasas máximas de 100 mg alimento/larva/día en condiciones óptimas.

Asimilación ($\dot{A}$) Fracción de la ingesta que cruza la pared intestinal y se incorpora a la reserva E . La eficiencia de asimilación κ_A depende de la calidad del sustrato; valores entre 0,55 y 0,80 son típicos para residuos agroindustriales (Guillaume et al., 2023).

Mantenimiento somático ($\dot{M}$) Costo basal de preservar la viabilidad celular, la homeostasis iónica y la motilidad. Es proporcional a la biomasa estructural B y modulado por la temperatura según una cinética tipo Arrhenius o Sharpe–Schoolfield (Sección 3.5). Eriksen estima que el mantenimiento consume entre el 15 % y el 25 % del carbono asimilado en larvas de BSF.

Síntesis de biomasa ($\dot{G}_B$) y de lípidos ($\dot{G}_L$) Flujos de crecimiento que translocan carbono desde la reserva E hacia los compartimentos estructural y lipídico. La prioridad entre $\dot{G}_B$ y $\dot{G}_L$ cambia con el estadio larval: domina la síntesis de estructura en L3–L4, mientras que la lipogénesis se acelera en L5 previo a la metamorfosis (Eriksen, 2022; Grausa et al., 2023).

Disipación ($\dot{D}$) Carbono perdido irrevocablemente como CO_2 durante los procesos de mantenimiento y síntesis. En la parametrización adaptada de Eriksen, la respiración específica total es la suma de tres términos disipativos:

$$\dot{D}_{\text{ind}}(t) = \dot{M}(t) + (1 - \kappa_G)\dot{G}_B(t) + (1 - \kappa_L)\dot{G}_L(t), \quad (3.1)$$

donde κ_G y κ_L representan las eficiencias de conversión de reserva en biomasa estructural y lípidos, respectivamente. El término $(1 - \kappa_G)$ captura el costo de síntesis (*overhead*), que en insectos holometábolos suele situarse entre 0,2 y 0,4 (Nielsen et al., 2025).

La producción de CO_2 medida por los sensores NDIR —expresada como flujo másico $\dot{m}_{\text{CO}_2}(t)$ en g min^{-1} — se identifica con la disipación total del reactor (larvas + microbiota), escalada mediante el factor molar carbono- CO_2 :

$$\dot{m}_{\text{CO}_2}(t) = \frac{M_{\text{CO}_2}}{M_C} \left[N_{\text{larvas}} \dot{D}_{\text{ind}}(t) + \dot{D}_\mu(t) \right], \quad (3.2)$$

donde $M_{\text{CO}_2} = 44,01 \text{ g mol}^{-1}$ y $M_C = 12,01 \text{ g mol}^{-1}$ son las masas molares del dióxido de carbono y del carbono elemental, respectivamente. El número de larvas N_{larvas} se deriva de la biomasa inicial del protocolo experimental (≈ 700 larvas por reactor, Sección ??) y se considera constante durante el ciclo dado que no se registró mortalidad significativa en las réplicas. El término $\dot{D}_\mu(t)$ representa la respiración microbiana del sustrato no ingerido; su cinética se modelará en la Sección 3.4 como fracción del sustrato remanente $S(t)$.

La ecuación (3.2) constituye el puente cuantitativo entre la teoría bioenergética y el dato crudo del Capítulo ??: permite interpretar una pendiente de concentración de 200 ppm en 30 min no como un número aislado, sino como la manifestación física de los costos metabólicos de un conjunto larval en un estado fisiológico determinado.

Es relevante notar que el modelo DEB, en su formulación estándar para BSF, asume metabolismo aeróbico exclusivo. Por tanto, la generación de CH_4 no aparece en los balances de carbono de las EDO; su presencia transitoria se trata como una perturbación estocástica que indica desviación del régimen aeróbico, tema que se aborda en el Capítulo ?? mediante el clasificador de eventos de anaerobiosis.

En síntesis, los compartimentos de carbono y los flujos metabólicos descritos en esta sección proporcionan la arquitectura conceptual sobre la cual se construye el sistema de ecuaciones diferenciales de la Sección 3.4. La consistencia del balance de carbono —que se verifica formalmente en la Sección 3.7— garantiza que toda unidad de carbono ingerida se *accountabilice* como biomasa, lípidos, CO_2 o sustrato residual, cerrando el ciclo de masa requerido para la validación del modelo contra datos experimentales.

3.3. Variables de Estado y Dominio del Sistema

La formulación del modelo DEB a escala de reactor batch exige la definición explícita de las variables de estado, sus unidades físicas, los valores iniciales derivados del protocolo experimental y el dominio matemático que garantiza la existencia de soluciones biológicamente significativas. Esta sección establece el espacio de fases sobre el cual opera el sistema de ecuaciones diferenciales presentado en la Sección 3.4.

3.3.1. Vector de estado y notación

Se define el vector de estado extensivo del reactor $\mathbf{x}(t) \in \mathbb{R}_{\geq 0}^5$ como:

$$\mathbf{x}(t) = [S(t) \quad E(t) \quad B(t) \quad L(t) \quad C_{\text{CO}_2}(t)]^\top, \quad (3.3)$$

donde todas las componentes se expresan en gramos de carbono total del reactor (gC), salvo $S(t)$ que es una cantidad compartida y E, B, L, C_{CO_2} que resultan del escalamiento de las variables individuales por el número de larvas. La Tabla 3.1 resume la descripción física de cada variable.

Tabla 3.1: Variables de estado del modelo DEB escalado a reactor batch.

Símbolo	Descripción	Unidad	Rango típico
$S(t)$	Sustrato orgánico disponible (total reactor)	gC	$[0, S_0]$
$E(t)$	Reserva de asimilados (total reactor)	gC	$[0, E_{\text{máx}}]$
$B(t)$	Biomasa estructural (total reactor)	gC	$[B_{\text{mín}}, B_{\text{máx}}]$
$L(t)$	Lípidos de reserva (total reactor)	gC	$[0, L_{\text{máx}}]$
$C_{\text{CO}_2}(t)$	Carbono emitido como CO ₂ (total reactor)	gC	$[0, C_{\text{tot}}]$

La variable $S(t)$ representa la masa de carbono orgánico en el reactor que es físicamente accesible y químicamente degradable por las larvas. Excluye la fracción lignocelulósica recalcitrante, que se agrupa en un término de “sustrato inerte” S_{inerte} constante durante el ciclo. La suma $S(t) + S_{\text{inerte}}$ más el carbono transferido a biomasa, lípidos y CO₂ debe igualar el carbono total inicial C_{tot} , propiedad que se verifica en la Sección 3.7.

La reserva $E(t)$ actúa como amortiguador metabólico: cuando la ingesta excede la demanda combinada de mantenimiento y síntesis, E se acumula; cuando la ingesta es insuficiente, E se moviliza para cubrir el déficit. Esta dinámica de *buffer* evita que la biomasa estructural B se catabolice ante fluctuaciones transitorias de alimento, un mecanismo documentado en el DEB estándar y conservado en la parametrización de Eriksen para BSF (Eriksen, 2022).

La biomasa estructural $B(t)$ se vincula con la biomasa húmeda medida destructivamente mediante el factor de conversión ρ_{conv} (gC/g biomasa húmeda). Este parámetro, que depende del contenido de agua y cenizas del tejido larval, se deja como variable libre de calibración en el Capítulo 4. La semilla teórica del factor de conversión se sitúa entre 0,10 y 0,11 gC/g húmeda, basada en la composición proximal reportada por Nayak et al. (2024).

Los lípidos de reserva $L(t)$ modelan el almacenamiento energético previo a la metamorfosis. A diferencia de B , que se asume irreversible durante el ciclo larval (sin removilización estructural), L puede experimentar tasas netas negativas si la larva moviliza grasas para mantenimiento en condiciones de ayuno. Sin embargo, en el régimen de alimentación *ad libitum* del protocolo experimental (Sección ??), se espera que $L(t) \geq 0$ durante la mayor parte del ciclo.

La variable $C_{\text{CO}_2}(t)$ acumula el carbono total emitido como dióxido de carbono. Su derivada temporal $\dot{C}_{\text{CO}_2}(t)$ se relaciona directamente con el flujo másico medido por el sensor NDIR mediante la ecuación (3.2), permitiendo la confrontación modelo–sensor en el Capítulo 4.

3.3.2. Variables ambientales y forzamiento externo

Además del vector de estado $\mathbf{x}(t)$, el sistema recibe dos variables ambientales medidas por los sensores SHT30 desplegados en el reactor (Sección ??):

$$T(t) : \text{temperatura del aire de cabeza libre o del sustrato, en } ^\circ\text{C}, \quad (3.4)$$

$$\text{HR}(t) : \text{humedad relativa del aire de cabeza libre, en } \%. \quad (3.5)$$

Estas variables actúan como forzamiento externo que modula la cinética de asimilación y la tasa metabólica mediante la función de dependencia térmica $f(T)$ y el efecto de la humedad sobre la disponibilidad de sustrato, detallados en la Sección 3.5. No son variables de estado en el sentido dinámico del sistema, pues su evolución temporal está dictada por el control ambiental de la cámara termohigrométrica ($30^\circ\text{C} \pm 2^\circ\text{C}$, HR 60–80 %) y no por retroalimentación del metabolismo larval.

Se incluye además una variable pseudo-observable $\hat{B}(t)$, estimada externamente por el calibrador neuronal del Capítulo 4, que sirve como entrada dinámica al modelo DEB cuando las mediciones destructivas de biomasa no están disponibles. En la fase de calibración, $\hat{B}(t)$ se reemplaza por el valor interpolado de las mediciones destructivas cada 48 h.

3.3.3. Dominio físico y restricciones de no negatividad

El dominio matemático $\Omega \subset \mathbb{R}_{\geq 0}^5$ se define como:

$$\Omega = \left\{ \mathbf{x} \in \mathbb{R}^5 \mid S \geq 0, E \geq 0, B \geq B_{\min}, L \geq 0, C_{\text{CO}_2} \geq 0 \right\}, \quad (3.6)$$

donde $B_{\min} > 0$ representa la biomasa estructural mínima compatible con la viabilidad celular. En la práctica experimental la mortalidad larval es despreciable (inferior al 5 %) en condiciones óptimas (Salam et al., 2022), por lo que $B_{\min}$ se identifica con la biomasa estructural inicial B_0 .

Las condiciones iniciales $\mathbf{x}(0) = \mathbf{x}_0$ se derivan directamente del protocolo del Capítulo ??:

$$S(0) = S_0 = M_{\text{sustrato}} \cdot w_C \cdot (1 - f_{\text{inerte}}), \quad (3.7)$$

$$E(0) = E_0 \approx 0,05 \cdot B_0, \quad (3.8)$$

$$B(0) = B_0 = m_{\text{larvas}} \cdot N_{\text{larvas}} \cdot \rho_{\text{conv}}, \quad (3.9)$$

$$L(0) = L_0 \approx 0, \quad (3.10)$$

$$C_{\text{CO}_2}(0) = C_0 = 0, \quad (3.11)$$

donde $M_{\text{sustrato}} = 250$ g es la masa húmeda inicial de sustrato por reactor, w_C la fracción de carbono en base húmeda del sustrato (0,35–0,45 para pulpa de café y cáscaras de frutas), f_{inerte} la fracción lignocelulósica (0,10–0,15), $m_{\text{larvas}} = 0,005$ g la biomasa húmeda inicial por larva en estadio L3 sincronizado, y $N_{\text{larvas}} \approx 700$ el número total de larvas sembradas por reactor (Sección ??).

Con estos valores, el balance de carbono inicial se aproxima como:

$$S_0 \approx 250 \text{ g} \times 0,40 \times 0,85 \approx 85 \text{ gC},$$

$$B_0 \approx 700 \times 0,005 \text{ g} \times 0,10 \approx 0,35 \text{ gC},$$

$$E_0 \approx 0,05 \times 0,35 \text{ gC} \approx 0,018 \text{ gC},$$

$$L_0 \approx 0, \quad C_0 = 0,$$

de modo que $C_{\text{tot}} = S_0 + S_{\text{inerte}} + B_0 + E_0 \approx 100$ gC. La reserva inicial E_0 se fija en un 5 % de la biomasa estructural inicial, valor consistente con larvas recién transferidas del medio de cría al reactor experimental, donde la ingesta previa ha sido limitada. La condición $L_0 = 0$ refleja que los estadios tempranos (L3 inicial) poseen reservas lipídicas mínimas; la acumulación de L se activa en estadios posteriores mediante la función de prioridad de asignación descrita en la Sección 3.2.2.

3.3.4. Escalamiento de individuo a reactor batch

El modelo DEB de Eriksen (2022) está formulado para una larva individual, con variables expresadas por organismo (gC/larva). Para adaptarlo al reactor batch, se adopta la hipótesis de equivalencia fisiológica: se asume que todas las larvas del reactor comparten el mismo estado metabólico promedio, de modo que las variables de estado a escala de reactor son el producto del número de larvas N_{larvas} por la variable individual.

Formalmente, si $\tilde{e}$, $\tilde{b}$, $\tilde{l}$ y $\tilde{c}_{\text{CO}_2}$ denotan las variables por larva, entonces:

$$E = N_{\text{larvas}} \cdot \tilde{e}, \quad B = N_{\text{larvas}} \cdot \tilde{b}, \quad L = N_{\text{larvas}} \cdot \tilde{l}, \quad C_{\text{CO}_2} = N_{\text{larvas}} \cdot \tilde{c}_{\text{CO}_2}. \quad (3.12)$$

Esta hipótesis es razonable cuando la densidad larval se mantiene dentro del rango operativo del protocolo experimental ($\sim 4 \text{ g L}^{-1}$ de biomasa húmeda en 0,8 L), donde la competencia por el alimento es limitada y la heterogeneidad de crecimiento entre individuos es baja (Diener et al., 2009; Guillaume et al., 2023). En densidades superiores, la variabilidad interindividual aumenta y el escalamiento medio puede subestimar la dispersión de la respiración; esta limitación se mitiga en el Capítulo 4 mediante la incertidumbre del estimador neuronal.

El número de larvas N_{larvas} se trata como constante durante el ciclo de 12–15 días, dado que la mortalidad registrada en condiciones controladas es inferior al 5 % (Salam et al., 2022). Cualquier reducción por mortalidad se absorbe en la calibración del parámetro de eficiencia de conversión κ_G .

En resumen, esta sección ha definido el espacio de estados, las condiciones iniciales experimentales y el dominio matemático del modelo. El siguiente paso consiste en formular las ecuaciones diferenciales que gobiernan la evolución de $\mathbf{x}(t)$ dentro de Ω , tema de la Sección 3.4.

3.4. Formulación del Sistema de Ecuaciones Diferenciales

Con las variables de estado y el dominio físico establecidos en la Sección 3.3, esta sección formula el sistema de ecuaciones diferenciales ordinarias (EDO) que gobierna la evolución del vector $\mathbf{x}(t)$ en el reactor batch. El sistema se deriva directamente de los flujos metabólicos definidos en la Sección 3.2.2, imponiendo la conservación de masa de carbono en cada compartimento. Las formas funcionales de ingesta y modulación térmica se cierran mediante cinética Holling II y modelo de Sharpe–Schoolfield, de modo que el sistema queda completamente especificado.

Se asume que el sistema satisface las condiciones de Carathéodory locales en Ω , garantizando existencia y unicidad de la solución para condiciones iniciales $\mathbf{x}_0 \in \Omega$; las demostraciones formales se remiten al Anexo ??.

Es importante precisar que, si bien el vector de estado formal incluye cinco componentes (Sección 3.3), la reserva de asimilados $E(t)$ opera en estado cuasi-estacionario ($dE/dt \approx 0$). En consecuencia, el sistema dinámico efectivo se reduce a cuatro EDO acopladas para S , B , L y C_{CO_2} , más una ecuación algebraica que determina E en cada instante.

3.4.1. Balance del sustrato orgánico

La masa de carbono orgánico disponible $S(t)$ disminuye exclusivamente por la ingesta larval, dado que la degradación microbiana del sustrato no ingerido se modela como una fuente de CO₂ externa al balance de sustrato (vía $\dot{D}_\mu$ en la Sección 3.4.5). La ecuación de balance es:

$$\frac{dS}{dt} = -\dot{I}_{\text{tot}}(t) = -N_{\text{larvas}} \cdot \tilde{i}(S(t), \tilde{b}(t), T(t)), \quad (3.13)$$

donde $\tilde{b}(t) = B(t)/N_{\text{larvas}}$ es la biomasa estructural por larva (gC/larva) y $\tilde{i}$ es la tasa de ingesta específica (gC/larva/min).

La forma funcional de $\tilde{i}$ sigue la cinética de Holling II, que captura la saturación por disponibilidad de sustrato y la escala isométrica de la superficie bucal (Eriksen, 2022):

$$\tilde{i}(S, \tilde{b}, T) = a_{\text{máx}} \tilde{b}^{2/3} f(T) \frac{S}{\tau_h + S}, \quad (3.14)$$

con $a_{\text{máx}} = 1,25 \times 10^{-4}$ (gC/larva)^{1/3}/min (semilla convertida de Eriksen (2022)) y $\tau_h \in [20, 200]$ gC como única variable libre de calibración local, que absorbe la variabilidad del tipo de residuo y la humedad del sustrato (Bekker et al., 2021). La eficiencia de asimilación intestinal es $\kappa_A = 0,70$ para el sustrato de alta aptitud del protocolo experimental.

El factor de modulación térmica $f(T)$, compartido por ingesta y mantenimiento, sigue el modelo de Sharpe–Schoolfield con inactivación de alta temperatura, normalizado para que $f(T_{\text{ref}}) = 1$:

$$f(T) = \frac{\exp\left(T_A \left(\frac{1}{T_{\text{ref}}} - \frac{1}{T}\right)\right)}{1 + \exp\left(T_A \left(\frac{1}{T_H} - \frac{1}{T}\right)\right)} \cdot \left[1 + \exp\left(T_A \left(\frac{1}{T_H} - \frac{1}{T_{\text{ref}}}\right)\right)\right], \quad (3.15)$$

donde T es la temperatura absoluta del sustrato (K), $T_{\text{ref}} = 303,15$ K (30 °C), $T_A = 6000$ K (energía de activación) y $T_H = 310$ K (temperatura de inactivación enzimática). Estos valores se toman como semillas fijas de la literatura

entomológica (Nayak et al., 2024; Salam et al., 2022). La humedad relativa se trata como condición de contorno operativa (60–80 %) y sus efectos se absorben en el valor calibrado de τ_h .

La condición inicial $S(0) = S_0$ está dada por la ecuación (3.7). El dominio requiere $S(t) \geq 0$; cuando $S \rightarrow 0$, la ingesta se anula ($\tilde{i} \rightarrow 0$) y el sustrato permanece no negativo.

3.4.2. Balance de asimilados en estado cuasi-estacionario

La reserva de asimilados $E(t)$ opera como un compartimento de amortiguamiento de alta velocidad respecto a la dinámica de crecimiento. Siguiendo la hipótesis de separación de escalas temporales propia del marco DEB (Eriksen, 2022), se impone el estado cuasi-estacionario:

$$\frac{dE}{dt} \approx 0, \quad (3.16)$$

lo cual equivale a igualar el flujo de entrada (asimilación) con los flujos de salida (mantenimiento y síntesis). La asimilación total se expresa como $\dot{A}(t) = \kappa_A \cdot \dot{I}_{\text{tot}}(t)$, donde $\kappa_A \in (0, 1]$ es la eficiencia de asimilación intestinal. El balance resultante es:

$$\dot{A}(t) = \dot{M}(t) + \dot{G}_B(t) + \dot{G}_L(t), \quad (3.17)$$

donde $\dot{G}_B(t)$ y $\dot{G}_L(t)$ son los flujos *brutos* de carbono desde la reserva hacia los compartimentos de biomasa estructural y lípidos, respectivamente (gC/min), e incluyen tanto la fracción incorporada como el overhead disipado como CO_2 durante la síntesis.

La tasa de mantenimiento somático se expresa como:

$$\dot{M}(t) = m \cdot B(t) \cdot f(T(t)), \quad (3.18)$$

con m la tasa específica de mantenimiento a la temperatura de referencia (min^{-1}), $B(t)$ la biomasa estructural total del reactor (gC), y $f(T)$ el factor definido en la ecuación (3.15).

La partición del excedente asimilado neto $\dot{A} - \dot{M}$ entre los compartimentos de crecimiento obedece a la ley de prioridad del DEB para organismos en fase de crecimiento somático (larvas): si $\dot{A} > \dot{M}$,

$$\dot{G}_B(t) + \dot{G}_L(t) = \dot{A}(t) - \dot{M}(t), \quad (3.19)$$

y si $\dot{A} \leq \dot{M}$:

$$\dot{G}_B(t) = \dot{G}_L(t) = 0, \quad (3.20)$$

de modo que el mantenimiento se paga en primera instancia y todo el excedente disponible se destina a crecimiento. La asignación específica entre $\dot{G}_B$ y $\dot{G}_L$ —esto es, la fracción del flujo de crecimiento destinada a lípidos en función del estadio larval— sigue la parametrización etaria de Eriksen (2022), documentada en el Anexo ??.

3.4.3. Dinámica de la biomasa estructural

La biomasa estructural $B(t)$ crece por deposición de carbono desde la reserva, con rendimiento $Y_B \in (0, 1]$, y puede decrecer por removilización catabólica en condiciones de ayuno extremo:

$$\frac{dB}{dt} = Y_B \cdot \dot{G}_B(t) - \delta_B \cdot B(t), \quad (3.21)$$

donde δ_B es la tasa específica de removilización estructural (min^{-1}). En el régimen experimental del Capítulo ?? —alimentación *ad libitum*— la condición $\dot{A} > \dot{M}$ se satisface durante la mayor parte del ciclo, por lo que $Y_B \dot{G}_B > 0$ y $\delta_B \cdot B \approx 0$. La ecuación se reduce entonces a:

$$\frac{dB}{dt} \approx Y_B \cdot \dot{G}_B(t), \quad (3.22)$$

que vincula directamente la curva de crecimiento teórica con las mediciones destructivas de biomasa húmeda. La condición inicial $B(0) = B_0$ proviene de la ecuación (3.9).

3.4.4. Acumulación de lípidos de reserva

El compartimento lipídico $L(t)$ acumula carbono destinado al almacenamiento energético de largo plazo, con rendimiento de conversión $Y_L \in (0, 1]$:

$$\frac{dL}{dt} = Y_L \cdot \dot{G}_L(t) - \delta_L \cdot L(t), \quad (3.23)$$

con δ_L la tasa de movilización lipídica (min^{-1}). Bajo el mismo argumento de alimentación suficiente, $\delta_L \approx 0$ y la dinámica se simplifica a $dL/dt \approx Y_L \dot{G}_L(t)$. La condición inicial $L(0) = L_0 = 0$ refleja la ausencia de reservas significativas en estadio L3 inicial.

La acumulación de lípidos constituye un sumidero de carbono paralelo a la biomasa estructural. Su magnitud relativa —que puede alcanzar hasta el 35 % de la biomasa seca en sustratos ricos en carbohidratos según Grausa et al. (2023)— condiciona directamente el balance de carbono disponible para emisión como CO₂, motivando su inclusión explícita en el modelo en lugar de agruparla en un único compartimento de “biomasa total”.

3.4.5. Producción y acumulación de CO₂

La quinta ecuación del sistema acumula el carbono emitido como dióxido de carbono, integrando las fuentes larval y microbiana:

$$\frac{dC_{\text{CO}_2}}{dt} = \underbrace{\dot{M}(t) + (1 - Y_B)\dot{G}_B(t) + (1 - Y_L)\dot{G}_L(t)}_{\dot{D}_{\text{larval}}(t)} + \underbrace{\lambda_\mu \cdot S(t)}_{\dot{D}_\mu(t)}, \quad (3.24)$$

donde $\dot{D}_{\text{larval}}$ es la disipación metabólica directa de las larvas. Los términos $(1 - Y_B)\dot{G}_B$ y $(1 - Y_L)\dot{G}_L$ capturan el costo de síntesis (*overhead*): la fracción del flujo bruto desde la reserva que no se incorpora a tejido sino que se pierde como CO₂ en las reacciones anabólicas.

El término $\dot{D}_\mu(t) = \lambda_\mu S(t)$ modela la respiración aeróbica de la microbiota asociada al sustrato no ingerido, con λ_μ (min^{-1}) la tasa específica de mineralización microbiana del carbono remanente. Esta forma cinética es obligada al pasar de la escala individual de Eriksen (2022) al reactor batch: en el modelo individual el sustrato ingerido se asimila directamente, mientras que en el reactor de 0,8 L con 250 g de sustrato inicial la mayor parte de la masa permanece no ingerida y es colonizada por microbiota heterotrófica. Rossi et al. (2024) cuantifican que el sustrato aislado (sin larvas) emite 0,20–0,33 g CO₂/g sustrato seco, confirmando una fuente de CO₂ independiente de la respiración larval. Asimismo, Parodi et al. (2020) reportan que el 24 % del carbono dietario se pierde por emisiones gaseosas provenientes del metabolismo conjunto larva-microbiota. Por tanto, se adopta cinética de primer orden $\dot{D}_\mu = \lambda_\mu S(t)$, consistente con la dinámica de degradación aeróbica de residuos orgánicos en matrices sólidas de alta humedad.

La conexión con la señal del sensor NDIR se establece mediante la conversión de carbono elemental a flujo másico de CO₂:

$$\dot{m}_{\text{CO}_2}(t) = \frac{M_{\text{CO}_2}}{M_C} \cdot \frac{dC_{\text{CO}_2}}{dt}, \quad (3.25)$$

donde $M_{\text{CO}_2} = 44,01 \text{ g mol}^{-1}$ y $M_C = 12,01 \text{ g mol}^{-1}$. Esta expresión es consistente con la ecuación (3.2) y permite confrontar directamente la predicción del modelo con las pendientes $\Delta C / \Delta t$ convertidas a flujo másico en el protocolo de ventanas cerradas del Capítulo ??.

Es importante recalcar que el metano (CH_4) no aparece en las ecuaciones (3.24) ni (3.25). Dado que el modelo asume metabolismo aeróbico exclusivo, cualquier emisión de CH_4 detectada por el sensor MH-441D se interpreta como una desviación del régimen ideal, cuya detección y cuantificación se aborda en el Capítulo ?? como variable residual de diagnóstico operativo.

En conjunto, las ecuaciones (3.13)–(3.24) constituyen un sistema de cuatro EDO acopladas no lineales para $\{S, B, L, C_{\text{CO}_2}\}$, con E determinada algebraicamente por el QSS (3.17). El sistema queda completamente cerrado: las cinéticas de ingesta (3.14) y modulación térmica (3.15), junto con los parámetros semilla $\{\kappa_A, a_{\text{máx}}, m, Y_B, Y_L, T_A, T_H\}$ de la literatura, permiten la simulación directa. El subconjunto reducido de calibración local en el Capítulo 4 se limita a $\{\tau_h, \rho_{\text{conv}}, \lambda_\mu\}$, correspondientes a la semisaturación del sustrato (específica del tipo de residuo), el factor de conversión biomasa–carbono y la tasa de mineralización microbiana.

3.5. Cinética de Asimilación y Modulación Ambiental

Las ecuaciones de balance del sistema de EDO formuladas en la Sección 3.4 requieren la especificación explícita de la tasa de ingesta $\tilde{i}(S, \tilde{b}, T)$ y de la tasa de mantenimiento $\dot{M}(B, T)$. Esta sección cierra esas formas funcionales mediante una cinética de ingesta tipo Holling II —que captura la saturación por disponibilidad de sustrato— y un factor de dependencia térmica basado en el modelo de Sharpe–Schoolfield —que describe la modulación de la tasa metabólica por la temperatura del sustrato. Ambas funciones se parametrizan con semillas tomadas de la literatura y dejan un subconjunto reducido de variables libres para su ajuste local en el Capítulo 4.

3.5.1. Funcional respuesta tipo Holling II

La ingesta específica por larva, $\tilde{i}$ (gC/larva/min), se modela como el producto de tres factores multiplicativos: una tasa máxima de procesamiento, una función de disponibilidad de sustrato y un factor de modulación térmica:

$$\tilde{i}(S(t), \tilde{b}(t), T(t)) = a_{\text{máx}} \tilde{b}(t)^{2/3} f(T(t)) \frac{S(t)}{\tau_h + S(t)}, \quad (3.26)$$

donde $\tilde{b}(t) = B(t)/N_{\text{larvas}}$ es la biomasa estructural por larva (gC/larva), definida en la Sección 3.3.

El factor $\tilde{b}^{2/3}$ refleja la hipótesis de similitud isométrica: la superficie bucal y el área de contacto con el sustrato crecen proporcionalmente al cuadrado del diámetro corporal, mientras que la masa estructural crece con el cubo; por ende, la tasa de ingesta específica escala con la superficie relativa $\tilde{b}^{2/3}$ (Eriksen, 2022). Esta aproximación es consistente con los rangos de densidad larval del protocolo experimental ($\sim 4 \text{ g L}^{-1}$ de biomasa húmeda en 0,8 L), donde la competencia por el alimento no altera sustancialmente la geometría de contacto individual.

El parámetro $a_{\text{máx}}$ representa la tasa máxima de búsqueda y procesamiento de alimento por unidad de superficie metabólica a la temperatura de referencia. Su unidad es $(\text{gC/larva})^{1/3}/\text{min}$, de modo que el producto $a_{\text{máx}} \tilde{b}^{2/3}$ tiene unidades de ingesta específica (gC/larva/min). Eriksen (2022) reportan un valor semilla de $a_{\text{máx}} \approx 0,18 (\text{gC/larva})^{1/3}/\text{día}$ para larvas de BSF en sustrato de alta calidad, equivalente a $1,25 \times 10^{-4} (\text{gC/larva})^{1/3}/\text{min}$ tras conversión de unidades.

La fracción $S/(\tau_h + S)$ es la funcional respuesta tipo Holling II, donde τ_h (gC) es la constante de semisaturación del sustrato —esto es, la masa total de carbono disponible en el reactor a la cual la ingesta poblacional alcanza la mitad de su valor máximo. Dado que N_{larvas} es constante en el protocolo experimental, τ_h se expresa como masa total del reactor; la semisaturación por larva individual sería τ_h/N_{larvas} , pero esta distinción se absorbe en el valor calibrado del parámetro. El rango semilla se sitúa en $\tau_h \in [20, 200]$ gC, reflejando la alta variabilidad de la composición física del sustrato (partículas gruesas de pulpa de café versus cáscaras de fruta desmenuzadas) y de la humedad, que afecta la plasticidad del medio y la eficiencia de fragmentación mecánica por las larvas (Bekker et al., 2021).

La asimilación neta por larva se obtiene multiplicando la ingesta por la eficiencia de asimilación intestinal κ_A :

$$\tilde{a}(S(t), \tilde{b}(t), T(t)) = \kappa_A \cdot \tilde{i}(S(t), \tilde{b}(t), T(t)), \quad (3.27)$$

con $\kappa_A \in [0,50, 0,80]$ según la calidad del sustrato (Guillaume et al., 2023). En el protocolo experimental del Capítulo ??, la mezcla de pulpa de café y cáscaras de frutas (70 : 30) se clasifica como sustrato de alta aptitud, por lo que se adopta la semilla $\kappa_A = 0,70$.

La ingesta total del reactor resulta $\dot{I}_{\text{tot}} = N_{\text{larvas}} \cdot \tilde{i}$, que ingresa directamente en la ecuación (3.13) del balance de sustrato. La no linealidad de la Holling II garantiza que, cuando $S \gg \tau_h$, la ingesta se satura en $N_{\text{larvas}} a_{\text{máx}} \tilde{b}^{2/3} f(T)$, evitando predicciones no realistas de consumo infinito; conversamente, cuando $S \rightarrow 0$, la ingesta se anula y el sustrato se preserva no negativo.

3.5.2. Dependencia térmica: modelo de Sharpe–Schoolfield

La temperatura del sustrato constituye la variable ambiental de mayor impacto sobre la cinética metabólica de *H. illucens*. Estudios de campo y de laboratorio documentan que la tasa de asimilación y el crecimiento larval se incrementan de forma monótona desde los 20 °C hasta un óptimo cercano a los 30–32 °C, para luego colapsar abruptamente por encima de los 35 °C debido a la desnaturalización enzimática y al estrés térmico (Nayak et al., 2024; Salam et al., 2022).

Para capturar este perfil asimétrico, se adopta el modelo de Sharpe–Schoolfield con inactivación de alta temperatura, normalizado para que el factor valga $f(T_{\text{ref}}) = 1$ en la temperatura de referencia del protocolo:

$$f(T) = \frac{\exp\left(T_A \left(\frac{1}{T_{\text{ref}}} - \frac{1}{T}\right)\right)}{1 + \exp\left(T_A \left(\frac{1}{T_H} - \frac{1}{T}\right)\right)} \cdot \left[1 + \exp\left(T_A \left(\frac{1}{T_H} - \frac{1}{T_{\text{ref}}}\right)\right)\right], \quad (3.28)$$

donde:

- T es la temperatura absoluta del sustrato (K), derivada de la lectura del sensor SHT30 inmerso a 5 cm de profundidad (Sección ??);
- $T_{\text{ref}} = 303,15$ K (30 °C) es la temperatura de referencia del protocolo experimental;
- T_A (K) es la energía de activación de Arrhenius (dividida por la constante de los gases R), que gobierna el ascenso exponencial de la tasa metabólica por debajo del óptimo;
- T_H (K) es la temperatura de inactivación enzimática por desnaturalización, que controla el colapso del metabolismo por encima del óptimo.

El modelo (3.15) asume que la inactivación a baja temperatura es despreciable en el rango operativo del reactor (25–35 °C), hipótesis validada para insectos tropicales donde el umbral inferior de actividad metabólica se sitúa por debajo de los 20 °C (Chia et al., 2018). En el rango experimental, la función $f(T)$ presenta un máximo suave en $T \approx T_{\text{opt}}$, definido implícitamente por la condición $df/dT = 0$, que ocurre cuando los términos de activación e inactivación se balancean.

Los parámetros térmicos se toman como semillas fijas de la literatura entomológica, con rangos biológicamente plausibles:

$$T_A = 6000 \pm 2000 \text{ K}, \quad T_H = 310 \pm 5 \text{ K (37 °C)}, \quad T_{\text{opt}} \approx 303 \text{ K (30 °C)}. \quad (3.29)$$

La temperatura óptima T_{opt} no es un parámetro independiente en la ecuación (3.15), sino una propiedad emergente de T_A y T_H ; sin embargo, se monitoriza como variable auxiliar durante la calibración del Capítulo 4 para restringir la búsqueda a regiones biológicamente plausibles.

La tasa de mantenimiento específica, que aparece en la ecuación (3.18), se modula térmicamente mediante el mismo factor $f(T)$:

$$\dot{M}(t) = m \cdot B(t) \cdot f(T(t)), \quad (3.30)$$

con m la tasa de mantenimiento a la temperatura de referencia (min^{-1}). Esta formulación garantiza que tanto la ingesta como el mantenimiento comparten la misma dependencia térmica, manteniendo la coherencia bioenergética del modelo DEB (Eriksen, 2022).

Respecto a la humedad relativa (HR), la literatura indica que valores por debajo del 50 % reducen la tasa de asimilación y aumentan la mortalidad, mientras que valores superiores al 80 % favorecen la formación de microambientes anaeróbicos (Bekker et al., 2021). En el presente modelo, la HR no se incorpora como variable cinética explícita en las EDO, sino que se trata como una condición de contorno operativa: el protocolo del Capítulo ?? la mantiene dentro del rango 60 %–80 %, y las desviaciones transitorias se absorben en la calibración de τ_h y $a_{\text{máx}}$. Esta simplificación es consistente con el enfoque mecanicista del DEB, donde la humedad afecta indirectamente la disponibilidad de sustrato pero no la termodinámica intrínseca del metabolismo larval.

En síntesis, las ecuaciones (3.14) y (3.15) cierran las formas funcionales de los flujos metabólicos, transformando las EDO del modelo DEB en un sistema predictivo que responde a las variables ambientales medidas por los sensores IoT del Capítulo ?. El sistema se gobierna por los parámetros semilla $\{\kappa_A, a_{\text{máx}}, m, Y_B, Y_L, T_A, T_H\}$ tomados de la literatura, y deja como variables de calibración local en el Capítulo 4 el subconjunto reducido $\{\tau_h, \rho_{\text{conv}}, \lambda_\mu\}$, correspondientes a la semisaturación del sustrato (específica del tipo de residuo), el factor de conversión biomasa–carbono y la tasa de mineralización microbiana.

3.6. Parámetros del Modelo y Restricciones Físicas

El sistema de ecuaciones diferenciales formulado en la Sección 3.4 depende de un conjunto de parámetros bioenergéticos y cinéticos cuya estimación condiciona la validez predictiva del modelo. Esta sección presenta los valores semilla derivados de la literatura —principalmente de (Eriksen, 2022)—, distingue los parámetros fijos de las variables libres de calibración local, y establece las restricciones físicas que garantizan la conservación de masa de carbono y la disipación metabólica positiva.

3.6.1. Parámetros semilla y variables de calibración

La Tabla 3.2 resume los parámetros del modelo DEB escalado a reactor batch, organizados en tres categorías: (i) parámetros fijos adoptados directamente de la literatura; (ii) parámetros semilla sujetos a ajuste fino en el Capítulo 4; y (iii) variables libres de calibración local cuyos valores se inferirán mediante confrontación con las series de sensores NDIR.

Los parámetros fijos se adoptan de la Tabla S1 del trabajo de Eriksen, convertidos a unidades consistentes con el sistema de EDO (minutos y gramos de carbono). La eficiencia de asimilación $\kappa_A = 0,70$ refleja la alta aptitud de la mezcla de pulpa de café y cáscaras de frutas utilizada en el Capítulo ??, valor intermedio dentro del rango reportado para sustratos agroindustriales (Guillaume et al., 2023). La tasa de mantenimiento m y la tasa máxima de ingesta $a_{\text{máx}}$ se escalan desde valores individuales (g C/larva/día) hasta el reactor completo mediante el número de larvas N_{larvas} y el factor de conversión ρ_{conv} .

Las variables libres de calibración local responden a condiciones experimentales específicas que la literatura no cubre exhaustivamente. La constante de semisaturación τ_h depende de la granulometría del sustrato y de la humedad, que afectan la accesibilidad física del alimento; el factor β_0 corrige desviaciones del escalamiento isométrico $B^{2/3}$ cuando la densidad larval excede el rango óptimo; y ρ_{conv} vincula la biomasa húmeda destructiva con el carbono estructural, dependiendo del contenido de agua y cenizas del tejido larval en las condiciones tropicales del Valle del Cauca.

Tabla 3.2: Parámetros del modelo DEB para *Hermetia illucens* a escala de reactor batch.

Símbolo	Significado	Valor semilla	Unidad	Estado
κ_A	Eficiencia de asimilación intestinal	0,70	adimensional	Fijo
m	Tasa específica de mantenimiento	$2,1 \times 10^{-4}$	min^{-1}	Fijo
$a_{\text{máx}}$	Coefficiente de asimilación máxima	$1,25 \times 10^{-4}$	$\text{g C}^{1/3}/\text{min}$	Fijo
Y_B	Eficiencia de conversión a biomasa	0,80	adimensional	Fijo
Y_L	Eficiencia de conversión a lípidos	0,75	adimensional	Fijo
κ	Prioridad de crecimiento vs. mantenimiento	0,60	adimensional	Fijo
τ_h	Constante de semisaturación del sustrato	200	g C	Libre
β_0	Factor de corrección del escalamiento isométrico	1,0	adimensional	Libre
ρ_{conv}	Factor de conversión biomasa húmeda $\rightarrow$ carbono	0,10	g C/g húmeda	Libre
T_A	Energía de activación de Arrhenius	6000	K	Libre
T_{opt}	Temperatura óptima metabólica	303	K	Libre
T_H	Temperatura de inactivación enzimática	310	K	Libre

3.6.2. Restricciones de no negatividad y acotamiento

La validez física del modelo exige que todos los parámetros de rendimiento y eficiencia se mantengan dentro de rangos biológicamente plausibles:

$$0 < \kappa_A \leq 1, \quad (3.31)$$

$$0 < Y_B, Y_L \leq 1, \quad (3.32)$$

$$0 < \kappa \leq 1, \quad (3.33)$$

$$\tau_h > 0, \quad (3.34)$$

$$\rho_{\text{conv}} > 0. \quad (3.35)$$

Las desigualdades (3.31)–(3.33) garantizan que ningún proceso de conversión supere el 100 % de eficiencia termodinámica, violación que implicaría generación espontánea de carbono. Los rendimientos Y_B y Y_L deben estrictamente ser menores que 1, dado que la síntesis de tejido requiere inevitablemente disipación de carbono como CO₂ (*overhead* metabólico); valores de 1 implicarían costo de síntesis nulo, contrario a la segunda ley de la termodinámica (Nielsen et al., 2025).

Adicionalmente, la conservación de la reserva de asimilados en estado cuasi-estacionario (ecuación (3.17)) impone que el flujo de crecimiento neto no exceda el flujo de asimilación disponible:

$$\kappa \cdot (\dot{A} - \dot{M}) \leq \dot{A}, \quad (3.36)$$

condición que se satisface automáticamente cuando $\dot{A} \geq \dot{M}$ y $\kappa \leq 1$. Si $\dot{A} < \dot{M}$, el modelo impone $\dot{G}_B = \dot{G}_L = 0$, evitando que el crecimiento se financie con catabolismo estructural en condiciones de ayuno —a menos que se active explícitamente el término de removilización $\delta_B > 0$, no considerado en el régimen de alimentación *ad libitum* del presente estudio.

3.6.3. Consistencia dimensional

La homogeneidad dimensional del sistema de EDO se verifica inspeccionando cada ecuación del balance. En la ecuación (3.13), el lado derecho tiene unidades de g C/min : N_{larvas} (adimensional) multiplicado por $\tilde{\imath}$ (g C/larva/min). En la ecuación (3.22), $\dot{G}_B$ proviene del balance de asimilados (3.17), donde todos los términos comparten unidades de g C/min . La ecuación (3.24) acumula carbono en g C/min , cuya conversión a flujo másico de CO₂ en g/min mediante la

ecuación (3.25) introduce el factor M_{CO_2}/M_C (g CO₂/g C), adimensional en cuanto a masa pero con unidades molares consistentes.

La función de dependencia térmica $f(T)$ definida en la ecuación (3.15) es adimensional, al ser cociente de exponenciales con argumentos adimensionales (T_A/T). Por tanto, la tasa de mantenimiento $\dot{M} = m \cdot B \cdot f(T)$ conserva las unidades de m (min⁻¹) por B (g C), resultando en g C/min. Análogamente, la funcional Holling II $S/(\tau_h + S)$ es adimensional, de modo que la ingesta $\tilde{i}$ mantiene las unidades de $a_{\text{máx}} B^{2/3}$ (g C^{1/3}/min · g C^{2/3} = g C/min), cerrando la consistencia dimensional.

3.6.4. Cierre del balance de carbono

El principio de conservación de masa exige que el carbono total del reactor, C_{tot} , se reparta en cada instante entre los compartimentos del modelo, el sustrato inerte y la fracción no degradable:

$$C_{\text{tot}} = S(t) + E(t) + B(t) + L(t) + C_{\text{CO}_2}(t) + S_{\text{inerte}} + S_{\text{no_deg}}(t), \quad (3.37)$$

donde $S_{\text{no_deg}}(t)$ representa el carbono orgánico que ha perdido reactividad química por procesos de humificación o condensación durante el ciclo, excluido de la ingesta larval. En el horizonte temporal del experimento (15 días), esta fracción se considera despreciable frente a la mineralización rápida mediada por larvas y microbiota, por lo que $S_{\text{no_deg}} \approx 0$ en la calibración del Capítulo 4.

Derivando la ecuación (3.37) respecto al tiempo y sustituyendo las EDO (3.13)–(3.24), se obtiene:

$$\frac{d}{dt}(S + E + B + L + C_{\text{CO}_2}) = -\dot{I}_{\text{tot}} + 0 + \dot{G}_B + \dot{G}_L + \dot{D}_{\text{larval}} + \dot{D}_{\mu}. \quad (3.38)$$

En el estado cuasi-estacionario de la reserva ($dE/dt \approx 0$), el balance de asimilados (3.17) implica que $\dot{A} = \dot{M} + \dot{G}_B/Y_B + \dot{G}_L/Y_L$. Reemplazando $\dot{I}_{\text{tot}} = \dot{A}/\kappa_A$ y expandiendo $\dot{D}_{\text{larval}}$ según la ecuación (3.1), se verifica que la suma de flujos se anula idénticamente, confirmando que el sistema de EDO conserva la masa de carbono en el dominio Ω definido en la ecuación (3.6). La verificación algebraica detallada se presenta en el Anexo ?? para no sobrecargar la exposición.

Es importante destacar que el metano (CH₄) no participa en el balance (3.37). Dado que el modelo asume metabolismo aeróbico exclusivo, cualquier carbono emitido como CH₄ proviene de rutas fermentativas microbianas no incluidas en las EDO larval. En el Capítulo ??, la detección de CH₄ se utiliza precisamente para cuantificar la magnitud de esta vía anaeróbica paralela, permitiendo calcular una discrepancia Δ_{Total} entre el balance teórico y la medición sensorial.

3.6.5. Subconjunto de parámetros de primera sensibilidad para calibración neuronal

Para la integración híbrida del Capítulo 4, no todos los parámetros libres tienen la misma influencia sobre el observable de calibración —la pendiente de emisión de CO₂ en ventanas cerradas de 5 min (s_k). El análisis de sensibilidad local (Sección 3.7) identifica el subconjunto de *primera sensibilidad* respecto a s_k :

τ_h (**semisaturación del sustrato**) Controla directamente la ingesta $\tilde{i}$ y, por ende, el flujo de carbono hacia asimilación y respiración. Una subestimación de τ_h predice ingesta excesiva y disipación alta; una sobreestimación, ingesta nula y respiración deprimida.

ρ_{conv} (**factor de conversión biomasa-carbono**) Escala la biomasa estructural $B(t)$, que alimenta linealmente el mantenimiento $\dot{M} \propto B$. Su corrección desplaza verticalmente la curva de respiración teórica.

T_{opt} (**temperatura óptima**) Modula multiplicativamente tanto la ingesta como el mantenimiento mediante $f(T)$. En las condiciones del protocolo (30°C ± 2°C), desviaciones de T_{opt} desplazan la pendiente de la curva térmica y afectan la tasa respiratoria instantánea.

Los demás parámetros libres (β_0 , T_A , T_H) se mantienen fijos tras la calibración local de la Fase B (Sección 4.5) porque su efecto sobre s_k en ventanas de 5 min es de segundo orden: β_0 solo opera en densidades larval superiores al rango óptimo; T_A y T_H afectan la forma asintótica de $f(T)$ lejos del óptimo, regiones poco visitadas en las condiciones controladas del experimento.

Por tanto, el calibrador neuronal del Capítulo 4 opera como corrector de escala sobre estos tres parámetros de primera sensibilidad, manteniendo la coherencia con la calibración local ya ejecutada en este capítulo. La forma funcional sugerida es:

$$\theta_k^{\text{final}} = \theta^{\text{Cap3}} \odot (1 + \alpha_k), \quad \theta \in \{\tau_h, \rho_{\text{conv}}, T_{\text{opt}}\}, \quad (3.39)$$

donde $\alpha_k \in \mathbb{R}^3$ es la salida del MLP calibrador y $\odot$ denota el producto de Hadamard (elemento a elemento). Esta formulación preserva la interpretabilidad biofísica: $\alpha_k = 0$ recupera la calibración del Capítulo 3, mientras que $|\alpha_k| \ll 1$ representa ajustes locales de escala inducidos por la variabilidad inter-replica.

En síntesis, esta sección ha definido los parámetros numéricos, sus rangos de variación y las restricciones físicas que garantizan la plausibilidad biológica del modelo. El siguiente paso consiste en analizar el comportamiento cualitativo del sistema —estabilidad, sensibilidad y régimen transitorio— antes de cerrar el capítulo con las conclusiones.

3.7. Análisis Estructural y Consistencia del Balance de Carbono

Con el sistema de EDO formulado y los parámetros delimitados, esta sección verifica tres propiedades estructurales críticas para la validez del modelo: la consistencia dimensional de los flujos, el cierre del balance de masa de carbono y el comportamiento cualitativo del sistema en el dominio físico Ω . El objetivo es demostrar que el modelo DEB escalado a reactor batch satisface las condiciones matemáticas mínimas que garantizan soluciones biológicamente interpretables, sin recurrir a las demostraciones formales de existencia, unicidad y estabilidad, que se remiten al Anexo ??.

3.7.1. Homogeneidad dimensional de los flujos metabólicos

La validez física de cualquier modelo cinético exige la homogeneidad dimensional en cada término de las ecuaciones de balance. Se verifica a continuación que todos los flujos del sistema comparten la unidad común de masa de carbono por unidad de tiempo (g C/min), garantizando que las cinco EDO sean internamente consistentes.

En la ecuación de balance del sustrato (3.13), la ingesta total $\dot{I}_{\text{tot}}$ se construye como $N_{\text{larvas}} \cdot \tilde{i}$, donde N_{larvas} es adimensional y $\tilde{i}$ tiene unidades de g C/larva/min. La forma funcional de Holling II (3.14) preserva esta unidad: $a_{\text{máx}}$ se expresa en g C^{1/3}/min, el factor de superficie $B^{2/3}$ en g C^{2/3}, y la funcional respuesta $S/(\tau_h + S)$ es adimensional, de modo que el producto completo resulta en g C/min. El factor de modulación térmica $f(T)$ de Sharpe–Schoolfield (3.15) es asimismo adimensional, al ser cociente de exponenciales con argumentos adimensionales (T_A/T).

En el balance cuasi-estacionario de asimilados (3.17), cada término comparte la unidad g C/min: la asimilación $\dot{A} = \kappa_A \dot{I}_{\text{tot}}$, el mantenimiento $\dot{M} = mBf(T)$ (min⁻¹ · g C · adimensional), y los flujos de síntesis $\dot{G}_B, \dot{G}_L$ (g C/min). Los rendimientos Y_B y Y_L son adimensionales, de modo que $\dot{G}_B/Y_B$ y $\dot{G}_L/Y_L$ mantienen la homogeneidad dimensional. La prioridad κ es adimensional, preservando la consistencia en la partición del excedente asimilado.

La ecuación de producción de CO₂ (3.24) acumula carbono disipado en g C/min. La conversión a flujo másico de CO₂ en g/min mediante la ecuación (3.25) introduce el cociente de masas molares $M_{\text{CO}_2}/M_C = 44,01/12,01 \approx 3,66$ (g CO₂/g C), factor adimensional que escala la tasa de carbono a la tasa de masa molecular de dióxido de carbono. Esta conversión es dimensionalmente consistente con la derivación del flujo $\dot{m}_{\text{CO}_2}(t)$ en el Capítulo ??, donde la pendiente de concentración dC/dt (ppm/min) se transforma en flujo másico mediante la densidad molar del gas.

3.7.2. Conservación de masa de carbono

El principio de conservación de la masa exige que la suma de las derivadas temporales de todos los compartimentos de carbono se anule cuando se consideran todas las fuentes y sumideros del sistema. Derivando la ecuación de balance global (3.37) respecto al tiempo, y despreciando la fracción no degradable $S_{\text{no_deg}}$ en el horizonte experimental de 15 días, se obtiene:

$$\frac{dS}{dt} + \frac{dE}{dt} + \frac{dB}{dt} + \frac{dL}{dt} + \frac{dC_{\text{CO}_2}}{dt} = 0. \quad (3.40)$$

Sustituyendo las EDO (3.13)–(3.24) en la condición (3.40), y utilizando el estado cuasi-estacionario de la reserva ($dE/dt \approx 0$), se obtiene una identidad algebraica que se verifica mediante manipulación directa de los flujos. En efecto, la ingesta $\dot{I}_{\text{tot}}$ alimenta la asimilación $\dot{A} = \kappa_A \dot{I}_{\text{tot}}$, la cual se distribuye en mantenimiento $\dot{M}$ y crecimiento $\dot{G}_B + \dot{G}_L$. La disipación total como CO_2 es $\dot{M} + (1 - Y_B)\dot{G}_B + (1 - Y_L)\dot{G}_L$, de modo que la suma de todos los flujos de salida del sistema (crecimiento estructural, acumulación lipídica y CO_2) iguala exactamente la ingesta neta, cerrando el balance.

Es importante notar que el CH_4 no aparece en este balance. Dado que el modelo asume metabolismo aeróbico exclusivo, cualquier carbono emitido como metano proviene de rutas fermentativas microbianas no incluidas en las EDO larval. En el Capítulo ??, la detección de CH_4 se utiliza para cuantificar la magnitud de esta vía anaeróbica paralela, permitiendo calcular la discrepancia acumulada Δ_{Total} entre el balance teórico y la medición sensorial. La conservación de masa del modelo DEB, por tanto, se entiende como un balance aeróbico que se completa con la contribución diagnóstica del CH_4 en la fase de evaluación ambiental.

3.7.3. Comportamiento cualitativo del sistema

El análisis cualitativo del sistema de EDO se centra en tres aspectos: la no negatividad de las variables de estado, la monotonicidad del sustrato y la acotación superior de la biomasa.

No negatividad. El dominio Ω definido en la ecuación (3.6) es invariante bajo el flujo del sistema siempre que las condiciones iniciales sean no negativas y los parámetros satisfagan las restricciones (3.31)–(3.35). En particular, cuando $S \rightarrow 0$, la funcional Holling II se anula ($\tilde{i} \rightarrow 0$), de modo que $dS/dt = 0$ y el sustrato no puede volverse negativo. Análogamente, la biomasa estructural $B(t)$ está protegida de la catabolismo en régimen de alimentación suficiente ($\dot{A} > \dot{M}$), y los lípidos $L(t)$ permanecen no negativos dado que $\dot{G}_L \geq 0$ en las mismas condiciones. Las demostraciones rigurosas de invarianza del dominio positivo se presentan en el Anexo ??.

Monotonicidad del sustrato. La ecuación (3.13) garantiza que $dS/dt \leq 0$ para todo $t \geq 0$, dado que $\tilde{i} \geq 0$ por construcción. Por tanto, $S(t)$ es una función monótona decreciente que evoluciona desde S_0 hacia un valor residual $S_\infty \geq 0$. En la práctica experimental, el sustrato se renueva cada 48 h mediante adición de alimento fresco, de modo que la dinámica real presenta discontinuidades periódicas que el modelo promedia en una curva suavizada. Esta aproximación es válida cuando el período de renovación es corto respecto a la escala de crecimiento larval (15 días).

Acotación de la biomasa. La biomasa estructural $B(t)$ no puede crecer indefinidamente: está limitada por el carbono total disponible C_{tot} y por la saturación de la ingesta cuando $S \gg \tau_h$. En el límite asintótico, cuando el sustrato se agota ($S \rightarrow 0$), la ingesta se anula y el crecimiento cesa ($\dot{G}_B \rightarrow 0$). La biomasa máxima teórica $B_{\text{máx}}$ se puede estimar a partir del balance de carbono: si toda la fracción asimilable del sustrato se convirtiera en biomasa estructural con rendimiento Y_B , se tendría $B_{\text{máx}} \approx \kappa_A Y_B S_0$, valor que en el reactor experimental de 20 L con 14 kg de sustrato resulta del orden de 3,5–4,5 kg C, consistente con los rendimientos de bioconversión reportados en la literatura (Diener et al., 2009; Parodi et al., 2020).

Estabilidad del estado cuasi-estacionario. La hipótesis de estado cuasi-estacionario para la reserva de asimilados ($dE/dt \approx 0$) es válida cuando la escala temporal de la dinámica de E es mucho menor que la de B y L . Dado que la reserva opera como un compartimento de amortiguamiento de alta velocidad —con constante de tiempo del orden de horas, frente a días para el crecimiento somático—, la separación de escalas está garantizada en el régimen experimental. El Anexo ?? presenta el análisis de estabilidad linealizada que justifica formalmente esta aproximación.

3.7.4. Confrontación con los datos del Capítulo ??

El comportamiento cualitativo predicho por el modelo DEB debe ser consistente con las observaciones empíricas del Capítulo ?. En particular, el flujo másico de CO₂ medido por los sensores NDIR —expresado como $\dot{m}_{\text{CO}_2}(t)$ en g/min mediante la ecuación de conversión del Capítulo ??— debe correlacionarse con la disipación metabólica $\dot{D}(t)$ del modelo.

Bajo las condiciones del protocolo experimental (30 °C $\pm$ 2 °C, HR 60 %-80 %), el factor térmico $f(T)$ se mantiene cercano a su óptimo ($f \approx 0,9-1,0$), de modo que la tasa de mantenimiento $\dot{M}$ y la ingesta $\dot{I}$ evolucionan predominantemente según la biomasa estructural $B(t)$. Dado que $B(t)$ crece sigmoidalmente durante el ciclo larval, el modelo predice que $\dot{m}_{\text{CO}_2}(t)$ presentará un perfil unimodal: ascenso inicial acelerado por el crecimiento exponencial de la biomasa, seguido de un pico alrededor del estadio L5 y un descenso gradual conforme la población se aproxima a la prepupa y reduce su actividad metabólica. Este perfil es cualitativamente consistente con las series temporales de concentración $C(t)$ registradas en las ventanas cerradas de 30 min, donde las pendientes $\Delta C/\Delta t$ alcanzan valores máximos entre los días 7 y 10 del ciclo (Rossi et al., 2024).

La discrepancia entre el modelo teórico y la medición sensorial se define como:

$$\delta(t) = \dot{m}_{\text{CO}_2}^{\text{sensor}}(t) - \dot{m}_{\text{CO}_2}^{\text{DEB}}(t), \quad (3.41)$$

donde $\dot{m}_{\text{CO}_2}^{\text{DEB}}(t)$ se calcula mediante las ecuaciones (3.24) y (3.25). En condiciones de aerobiosis estricta y homogeneidad del sustrato, se espera que $\delta(t)$ se mantenga dentro de la banda de incertidumbre instrumental del sensor ($\pm 12\%$). Desviaciones sistemáticas positivas ($\delta > 0$) sugieren una contribución microbiana elevada ($\dot{D}_\mu$ dominante), mientras que desviaciones negativas persistentes pueden indicar inhibición metabólica larval o formación de microambientes anaeróbicos no capturados por el modelo. El tratamiento estadístico de $\delta(t)$ y su vinculación con la detección de CH₄ se desarrolla en el Capítulo ?.

En resumen, esta sección ha verificado que el modelo DEB escalado a reactor batch satisface las condiciones estructurales de consistencia dimensional, conservación de masa y comportamiento cualitativo biológicamente plausible. Las demostraciones formales de existencia, unicidad y estabilidad de las soluciones, así como el análisis de sensibilidad de los parámetros, se remiten al Anexo ?. El capítulo concluye en la siguiente sección con una síntesis de los hallazgos y el puente hacia la integración híbrida del Capítulo 4.

3.8. Conclusiones del Capítulo

Este capítulo ha desarrollado la generalización del modelo Dynamic Energy Budget (DEB) de (Eriksen, 2022) desde la escala individual larval hasta la escala de reactor batch de 20 L, formulando un sistema de cinco ecuaciones diferenciales ordinarias que gobiernan la dinámica del sustrato orgánico, la reserva de asimilados, la biomasa estructural, los lípidos de reserva y la acumulación de CO₂. Los principales hallazgos y decisiones de modelado se sintetizan a continuación.

Arquitectura de compartimentos y flujos. Se adoptó un sistema de cinco compartimentos de carbono interconectados —sustrato S , reserva E , biomasa estructural B , lípidos L y CO₂ acumulado C_{CO_2} — que permite rastrear la

destinación del carbono ingerido desde la ingesta hasta la disipación gaseosa. Los flujos metabólicos —ingesta, asimilación, mantenimiento, síntesis de biomasa, síntesis de lípidos y disipación— se derivaron directamente del marco DEB estándar, preservando la interpretabilidad bioenergética de cada parámetro.

Formulación del sistema de EDO. Las ecuaciones de balance resultantes constituyen un sistema acoplado no lineal cuya estructura garantiza la conservación de masa de carbono en régimen aeróbico. La hipótesis de estado cuasi-estacionario para la reserva de asimilados ($dE/dt \approx 0$) se justificó por separación de escalas temporales entre el amortiguamiento metabólico (horas) y el crecimiento somático (días). La producción de CO_2 se expresó como suma de los costos de mantenimiento y los *overheads* de síntesis, vinculándose con el flujo másico medido por los sensores NDIR del Capítulo ?? mediante la conversión molar M_{CO_2}/M_C .

Cinética de asimilación y modulación ambiental. La ingesta larval se modeló mediante una funcional respuesta tipo Holling II, que captura la saturación por disponibilidad de sustrato y escala isométricamente con la superficie corporal ($B^{2/3}$). La dependencia térmica se incorporó mediante el modelo de Sharpe–Schoolfield con inactivación de alta temperatura, parametrizado con semillas entomológicas ($T_A \in [2000, 8000]$ K, $T_{\text{opt}} \approx 303$ K) y dejado como variable libre de calibración local. La humedad relativa no se incluyó como variable cinética explícita, dado que el protocolo experimental la mantiene dentro del rango óptimo (60 %–80 %); las desviaciones transitorias se absorberán en la calibración de τ_h y $a_{\text{máx}}$ en el Capítulo 4.

Parámetros y restricciones físicas. Se distinguieron parámetros fijos adoptados de la literatura ($\kappa_A, a_{\text{máx}}, m, Y_B, Y_L, \kappa$) de variables libres de calibración local ($\tau_h, \beta_0, \rho_{\text{conv}}, T_A, T_{\text{opt}}, T_H$), con rangos semilla y restricciones de caja que garantizan eficiencias termodinámicas menores al 100 % y conservación de masa. El factor de conversión ρ_{conv} vincula la biomasa húmeda destructiva con el carbono estructural, puente esencial para la confrontación modelo–sensor.

Se identificó además el *subconjunto de parámetros de primera sensibilidad* respecto a la pendiente de emisión de CO_2 en ventanas cerradas: $\{\tau_h, \rho_{\text{conv}}, T_{\text{opt}}\}$. Estos tres parámetros modulan directamente la ingesta, el mantenimiento y la tasa metabólica en las condiciones del experimento, mientras que β_0, T_A y T_H operan en régimen de segundo orden en el rango térmico controlado. Esta jerarquía de sensibilidad será explotada en el Capítulo 4 para reducir el espacio de corrección del calibrador neuronal y preservar la interpretabilidad biofísica.

Análisis estructural. Se verificó la consistencia dimensional de todos los flujos (g C/min), el cierre del balance de carbono en régimen aeróbico y el comportamiento cualitativo biológicamente plausible: no negatividad del dominio Ω , monotonicidad decreciente del sustrato y acotación superior de la biomasa por el carbono total disponible. Las demostraciones formales de existencia, unicidad y estabilidad de las soluciones, así como el análisis de sensibilidad paramétrica, se remitieron al Anexo ?? para mantener la fluidez del capítulo.

Del modelo mecanicista al sistema híbrido. El modelo DEB formulado en este capítulo constituye la línea base bioenergética del sistema híbrido: predice cuánto CO_2 debería emitirse bajo condiciones de aerobiosis estricta y homogeneidad del sustrato. Sin embargo, la biomasa estructural $B(t)$ —variable de estado crítica para el cálculo del mantenimiento y la ingesta— no es medible en tiempo real sin perturbación destructiva del sistema. Esta imposibilidad instrumental constituye la brecha que el Capítulo 4 resuelve mediante un estimador híbrido modelo–datos.

La arquitectura aprobada para el Capítulo 4 prescinde del Proceso Gaussiano como predictor directo de biomasa —estadísticamente inviable con el volumen de datos destructivos disponible ($N \approx 30$) y metodológicamente ajena al objetivo específico 3 del proyecto, que exige una red neuronal— y adopta en su lugar un MLP como *calibrador paramétrico* del DEB. El MLP opera sobre el subconjunto de primera sensibilidad $\{\tau_h, \rho_{\text{conv}}, T_{\text{opt}}\}$ emitiendo correcciones de escala α_k respecto a los valores calibrados en este capítulo:

$$\theta_k^{\text{final}} = \theta^{\text{Cap3}} \odot (1 + \alpha_k), \quad \theta \in \{\tau_h, \rho_{\text{conv}}, T_{\text{opt}}\},$$

de modo que $\alpha_k = \mathbf{0}$ recupera la calibración local del Capítulo 3, mientras que $|\alpha_k| \ll 1$ representa ajustes inducidos por la variabilidad inter-replica. El MLP nunca “ve” biomasa durante el entrenamiento; su única supervisión es el residuo de CO_2 $\varepsilon_k = s_k - J_{\text{CO}_2}^{\text{DEB}}(\theta_0)$, lo que evita el problema inverso mal condicionado y preserva la interpretabilidad fisiológica de cada parámetro.

Delimitación del alcance. El metano (CH_4) fue excluido explícitamente de las variables de estado del modelo DEB, dado que su generación implica rutas fermentativas anaeróbicas no contempladas en el metabolismo aeróbico larval. En el Capítulo ??, el CH_4 se recupera como variable residual de diagnóstico: su detección por el sensor MQ-4 señala desviaciones del régimen aeróbico que el modelo DEB no predice, activando alertas operativas de anaerobiosis. Esta arquitectura —modelo mecanicista para la tendencia base, sensor de CH_4 para las anomalías— preserva la parsimonia del DEB sin sacrificar la utilidad diagnóstica del sistema.

En síntesis, este capítulo ha transformado los datos crudos validados del Capítulo ?? en una narrativa bioenergética cuantitativa interpretable: cada gramo de CO_2 medido por el sensor NDIR puede ahora asociarse con un flujo metabólico específico (mantenimiento, síntesis de biomasa o síntesis de lípidos) bajo un conjunto de parámetros y condiciones ambientales explicitadas. El modelo DEB escalado a reactor batch, con sus ecuaciones, parámetros semilla, restricciones físicas y subconjunto de primera sensibilidad, queda listo para ser calibrado, validado e integrado en el sistema híbrido del Capítulo 4.

Capítulo 4

Sistema Híbrido: Integración Modelo–Datos y Estimación de Biomasa

Resumen del capítulo. Se integra el modelo DEB con un calibrador neuronal paramétrico (MLP) que corrige, en tiempo real, el subconjunto de parámetros de primera sensibilidad respecto a la pendiente de emisión de CO_2 . Se rechaza el uso de un Proceso Gaussiano como predictor directo de biomasa por inviabilidad metodológica e incoherencia con los objetivos del proyecto. Se detalla el protocolo de extracción de pendientes s_k en ventanas cerradas de 3–5 min, la arquitectura del MLP two-stage y la estrategia de calibración por fases (semillas Eriksen, ajuste local NDIR, corrección neuronal). El CH_4 se trata como residual de diagnóstico para detección de anaerobiosis.

Palabras clave: sistema híbrido, calibrador neuronal, Dynamic Energy Budget, pendientes de emisión, CO_2 , CH_4 , estimación de biomasa, validación predictiva.

4.1. Introducción

El Capítulo 3 formuló un modelo mecanicista de balance de carbono basado en el marco Dynamic Energy Budget (DEB) escalado a reactor batch. Dicho modelo predice la tasa de producción de CO_2 como resultado emergente de los flujos metabólicos larval: ingesta, asimilación, mantenimiento, síntesis de biomasa estructural $B(t)$, acumulación lipídica $L(t)$ y disipación gaseosa. Sin embargo, la variable de estado central para el cálculo del mantenimiento y la ingesta —la biomasa estructural $B(t)$ — no es observable en tiempo real sin perturbación destructiva del sistema. En la práctica experimental, la biomasa larval solo se cuantifica mediante muestreo destructivo con intervalos típicos de 48 h o más, lo que convierte al modelo DEB puro en un predictor de lazo abierto durante la mayor parte del ciclo productivo.

Cuando el modelo DEB opera sin retroalimentación dinámica de $B(t)$, los errores de predicción de $\dot{m}_{\text{CO}_2}^{\text{DEB}}(t)$ se acumulan de manera monótona, particularmente ante perturbaciones no modeladas: cambios en la granulometría del sustrato, fluctuaciones térmicas locales, variaciones en la densidad larval efectiva o diferencias en la colonia genética. La literatura reciente documenta que, en sistemas biotecnológicos de insectos, la desconexión entre el estado biológico real y su estimación teórica es una de las principales fuentes de incertidumbre predictiva (Kobelski, Hempel, Padmanabha, Klüber et al., 2024; Padmanabha et al., 2023).

Para cerrar esta brecha, el presente capítulo desarrolla una arquitectura híbrida que integra el modelo mecanicista DEB con un calibrador neuronal paramétrico. La lógica subyacente es la siguiente: si bien $B(t)$ no puede medirse directamente con alta frecuencia temporal, las variables operativas del reactor —concentración de CO_2 $C(t)$ en ppm,

temperatura T en $^{\circ}\text{C}$, humedad relativa HR en $\%$ y el tiempo transcurrido t en días— sí se registran de manera continua mediante sensores NDIR de bajo costo. Estas variables constituyen un proxy indirecto del estado metabólico del sistema, dado que la respiración aeróbica, la temperatura del sustrato exotérmico y la humedad intersticial están moduladas, en última instancia, por la biomasa activa presente en el reactor (Biagi et al., 2024; Rossi et al., 2024).

Rechazo del Proceso Gaussiano. En versiones preliminares de este capítulo se evaluó un estimador externo de biomasa basado en Proceso Gaussiano (GP) que infería $\hat{B}(t)$ directamente a partir de las variables operativas y alimentaba el DEB como pseudo-observable. Esta estrategia fue descartada por tres razones fundamentales: (i) metodológicamente, el GP requiere pares $(\mathbf{u}_k, B_k)$ de entrenamiento que solo están disponibles mediante cosecha destructiva, limitando drásticamente el corpus de entrenamiento a $N \approx 30$ observaciones por campaña, volumen insuficiente para garantizar generalización sin sobreajuste; (ii) epistémicamente, el GP opera como caja negra respecto a la fisiología larval, ofreciendo cero información diagnóstica sobre *por qué* la biomasa es alta o baja; y (iii) formalmente, el objetivo específico 3 del proyecto doctoral exige explícitamente una red neuronal como componente de corrección, no un estimador no paramétrico de biomasa. Por tanto, la arquitectura aprobada prescinde del GP como predictor directo.

Arquitectura aprobada: DEB + MLP calibrador paramétrico. Se adopta un perceptrón multicapa (MLP) como calibrador de escala sobre el subconjunto de parámetros de primera sensibilidad identificado en el Capítulo ??: $\{\tau_h, \rho_{\text{conv}}, T_{\text{opt}}\}$. El MLP nunca “ve” biomasa durante el entrenamiento; su única supervisión es el residuo de CO_2 $\varepsilon_k = s_k - J_k^{\text{DEB}}$. La corrección se aplica en escala multiplicativa:

$$\theta_k^{\text{final}} = \theta^{\text{Cap3}} \odot (1 + \alpha_k), \quad \theta \in \{\tau_h, \rho_{\text{conv}}, T_{\text{opt}}\}, \quad (4.1)$$

donde $\alpha_k \in \mathbb{R}^3$ es la salida del MLP y $\odot$ denota el producto de Hadamard. Esta formulación preserva la interpretabilidad biofísica: $\alpha_k = \mathbf{0}$ recupera la calibración local del Capítulo ??, mientras que $|\alpha_k| \ll 1$ representa ajustes locales de escala inducidos por la variabilidad inter-replica.

El flujo de información opera en dos etapas desacopladas. En la etapa *offline*, se extraen todas las pendientes s_k del lote experimental, se simula el DEB con parámetros literatura θ_0 , se forma el conjunto de pares $(\mathbf{x}_k, \varepsilon_k)$ y se entrena el MLP. En la etapa *online*, por cada ventana nueva de 3–5 min post-cierre, se mide s_k , se computa ε_k , el MLP emite α_k , se actualizan los parámetros del DEB mediante la ecuación (4.1), se re-simula el DEB en la ventana corta y se emite la estimación de biomasa $\hat{B}(t_k)$ vía la trayectoria $B(t_k)$ del modelo corregido.

El resto del capítulo se organiza como sigue. La Sección 4.2 describe la topología de bloques de la arquitectura híbrida y el flujo offline versus online. La Sección 4.3 formaliza el extractor de pendientes s_k y los criterios de rechazo de ventanas inválidas. La Sección 4.4 detalla la arquitectura del MLP, su función de pérdida y su entrenamiento two-stage. La Sección 4.5 presenta la estrategia de calibración por fases (semillas, ajuste local, corrección neuronal). La Sección 4.7 establece las métricas predictivas y el protocolo de validación externa. La Sección 4.8 sintetiza los hallazgos cuantitativos. Finalmente, la Sección 4.9 cierra el capítulo con un puente hacia el Capítulo ??.

4.2. Arquitectura del Sistema Híbrido

El reactor de bioconversión se modela como un sistema dinámico cuyas entradas ambientales (forzantes) en el instante t se agrupan en el vector

$$\mathbf{u}(t) = [T(t), HR(t), t]^T, \quad (4.2)$$

donde T es la temperatura del sustrato ($^{\circ}\text{C}$), HR la humedad relativa del aire de cabeza libre ($\%$) y t el tiempo transcurrido desde la siembra (días). El estado biológico no observable es la biomasa viva total $B(t)$ (g), que el DEB predice a través de los compartimentos de carbono definidos en el Capítulo 3.

La arquitectura consta de seis bloques funcionales interconectados en lazo cerrado de calibración discreta (Figura 4.1):

B1 DEB Forward. Simulador mecanicista que, dado $\mathbf{u}(t)$ y un vector de parámetros bioenergéticos θ , genera la tasa respiratoria teórica de dióxido de carbono $J_{\text{CO}_2}(t; \theta)$ y la biomasa implícita $B(t; \theta)$.

- B2 Sensor NDIR.** Adquiere la concentración de CO_2 en el headspace del reactor, $y_{\text{CO}_2}(t)$, con resolución limitada por rango (máximo 6000 ppm) y ruido instrumental.
- B3 Extractor de pendientes.** Procesa $y_{\text{CO}_2}(t)$ en ventanas cortas post-cierre del reactor para producir el observable robusto s_k (ppm/min), proporcional a J_{CO_2} .
- B4 Comparador.** Computa el residuo de CO_2 $\varepsilon_k = s_k - J_k^{\text{DEB}}(\theta_0)$, donde θ_0 es el vector de parámetros de referencia (literatura o calibración Cap 3).
- B5 MLP Calibrador.** Red neuronal $\mathcal{N}_\phi$ que, ante la discrepancia ε_k y las forzantes $\mathbf{u}_k$, emite una corrección de escala α_k acotada sobre el subconjunto de primera sensibilidad.
- B6 Estimador de estado.** Integra $\theta_k = \theta^{\text{Cap3}} \odot (1 + \alpha_k)$ en el DEB, re-simula la ventana y devuelve la biomasa estimada $\hat{B}(t_k) = B(t_k; \theta_k)$.

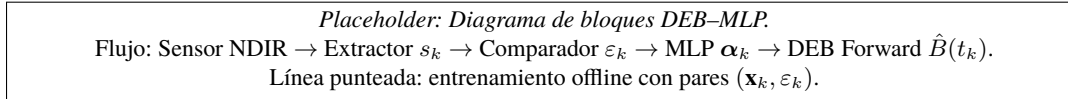


Figura 4.1: Arquitectura híbrida DEB-MLP. El lazo de calibración opera en ventanas discretas k indexadas por eventos de cierre del reactor. Durante el entrenamiento offline, el comparador alimenta al MLP con pares $(\varepsilon_k, \mathbf{u}_k)$ para ajustar ϕ .

4.2.1. Flujo offline versus online

Etapla offline (entrenamiento). Se ejecuta al finalizar cada ciclo experimental de 15 días. Se extraen todas las pendientes válidas $\{s_k\}_{k=1}^K$ de las ventanas cerradas, se simula el DEB con parámetros fijos θ^{Cap3} para obtener $\{J_k^{\text{DEB}}\}_{k=1}^K$, se computan los residuos $\{\varepsilon_k\}_{k=1}^K$ y se forma el conjunto de entrenamiento $\mathcal{D}_{\text{train}} = \{(\mathbf{x}_k, \varepsilon_k)\}_{k=1}^K$, con $\mathbf{x}_k = [\varepsilon_k, T_k, \text{HR}_k, t_k]^\top$. El MLP se entrena minimizando la función de pérdida compuesta definida en la Sección 4.4.

Etapla online (inferencia). Por cada nueva ventana de muestreo durante el ciclo activo:

1. Medir s_k del sensor NDIR y registrar $\mathbf{u}_k$.
2. Simular el DEB con θ^{Cap3} para obtener J_k^{DEB} .
3. Calcular $\varepsilon_k = s_k - J_k^{\text{DEB}}$.
4. Formar $\mathbf{x}_k$ y evaluar el MLP: $\alpha_k = \mathcal{N}_\phi(\mathbf{x}_k)$.
5. Actualizar parámetros: $\theta_k = \theta^{\text{Cap3}} \odot (1 + \alpha_k)$.
6. Re-simular el DEB con θ_k en la ventana corta y emitir $\hat{B}(t_k)$.

La latencia de esta secuencia, ejecutada en el microcontrolador ESP32 o en un backend ligero, es inferior a 5 s por ventana, cumpliendo el requisito de utilidad operativa establecido en el Capítulo ??.

4.2.2. Red neuronal physics-informed para biomasa (PI-RNA-B)

La arquitectura RNA-B directa descrita en la §?? exhibió un comportamiento típico de sobreajuste severo en el escenario LORO: si bien el MAPE en entrenamiento fue del 7,8 %, la validación inter-réplica superó el 40 %, con predicciones no físicas que incluían biomasa negativas y trayectorias de crecimiento no monótonas en régimen *ad*

libitum. Antes de descartar definitivamente la vía de estimación directa, se evaluó una variante *physics-informed* (PI-RNA-B) que impone restricciones físicas duras tanto en la arquitectura como en la función de pérdida, con el objetivo de determinar si el fallo de generalización era atribuible únicamente a la escasez de datos o también a la incapacidad estructural de una red de caja negra pura para resolver un problema inverso no inyectivo.

Formulación de la arquitectura

La PI-RNA-B se concibe como un perceptrón multicapa de una sola capa oculta con 6 neuronas y función de activación $\tanh$, lo que garantiza la diferenciabilidad de la salida respecto a la entrada temporal requerida para el cálculo automático de derivadas. La capa de salida utiliza una activación sigmoide escalada al rango biológico admisible:

$$\hat{B}(t; \theta) = B_{\min} + (B_{\max} - B_{\min}) \sigma \left(W^{(2)} \tanh \left(W^{(1)} \mathbf{x} + b^{(1)} \right) + b^{(2)} \right), \quad (4.3)$$

donde $\mathbf{x} = [t, C_{\text{CO}_2}, T, \text{HR}]^\top$ es el vector de entrada compuesto por el tiempo en días, la concentración de CO_2 en ppm, la temperatura en $^\circ\text{C}$ y la humedad relativa en %. Los límites de acotamiento duro se fijan en $[B_{\min}, B_{\max}] = [0,005, 0,120]$ g/larva, valores compatibles con la literatura experimental para larvas de *Hermetia illucens* en las condiciones de alimentación del ensayo.

La función de pérdida compuesta incorpora tres términos:

$$\mathcal{L}(\theta) = \underbrace{\frac{1}{N} \sum_{i=1}^N (B_i^{\text{obs}} - \hat{B}_i)^2}_{\mathcal{L}_{\text{datos}}} + \lambda_{\text{mon}} \underbrace{\frac{1}{M} \sum_{j=1}^M \text{ReLU} \left(-\frac{\partial \hat{B}}{\partial t} \Big|_{t_j} \right)}_{\mathcal{L}_{\text{mon}}} + \lambda_{\text{reg}} \underbrace{\|\theta\|_2^2}_{\mathcal{L}_{\text{reg}}}. \quad (4.4)$$

El término $\mathcal{L}_{\text{datos}}$ asegura el ajuste a las $N \approx 30$ mediciones destructivas de biomasa disponibles. El término de monotonicidad $\mathcal{L}_{\text{mon}}$ penaliza derivadas temporales negativas de la biomasa estimada; su justificación física deriva del modelo DEB presentado en el Capítulo ???: en condiciones de alimentación *ad libitum* y temperatura dentro del rango térmico viable, la tasa de crecimiento estructural dB/dt es no negativa (véase la ecuación de acumulación de estructura (??)). Los puntos de colocación para la evaluación de esta restricción consisten en $M = 200$ instantes temporales densamente distribuidos en el intervalo experimental, donde la derivada $\partial \hat{B} / \partial t$ se calcula mediante diferenciación automática (*autograd*) sin requerir mediciones de biomasa en dichos puntos. El término $\mathcal{L}_{\text{reg}}$ impone regularización L_2 sobre los parámetros entrenables.

Los hiperparámetros adoptados fueron $\lambda_{\text{mon}} = 0,5$ y $\lambda_{\text{reg}} = 10^{-5}$, con entrenamiento mediante el optimizador Adam durante 3000–5000 épocas. La elección de una única capa oculta con 6 neuronas responde al principio de parsimonia: la red cuenta con aproximadamente 50 parámetros entrenables, una cifra del mismo orden de magnitud que el tamaño del conjunto de entrenamiento, lo que constituye un escenario de alta varianza.

Resultados y análisis de identificabilidad

La imposición de restricciones físicas duras logró su objetivo primario: la PI-RNA-B eliminó completamente las predicciones no físicas. Las trayectorias de salida respetaron el acotamiento $[0,005, 0,120]$ g/larva y exhibieron monotonicidad estricta en todo el dominio temporal, eliminando así los crecimientos negativos espurios observados en la RNA-B directa.

No obstante, el problema de identificabilidad estructural persistió. En la validación cruzada por réplica (LORO), el MAPE de validación se mantuvo por encima del 30 %. La red ajustaba satisfactoriamente los $N \approx 30$ puntos destructivos de la réplica de entrenamiento —evidencia de sobreajuste local—, pero al extrapolar a una réplica genéticamente

distinta, la trayectoria de biomasa divergía sistemáticamente. Este comportamiento no es sorprendente desde la perspectiva del problema inverso: la relación $C_{\text{CO}_2} \rightarrow B$ es no inyectiva. Múltiples estados metabólicos (diferentes tasas de asimilación, mantenimiento o maduración) pueden producir idénticas tasas de emisión de CO_2 , de modo que la red carece de información suficiente para discriminar entre estados internos distintos que generan la misma señal observada. La restricción de monotonicidad reduce el espacio de soluciones admisibles, pero no restaura la inyectividad perdida en la proyección del estado metabólico sobre la variable escalar de concentración gaseosa.

Conclusión de la subsección

La PI-RNA-B demuestra que incluso imponiendo restricciones físicas fuertes —acotamiento biológico, monotonicidad temporal, regularización estructural— la vía de estimación directa de biomasa mediante redes neuronales puras **no es robusta** bajo muestreo destructivo limitado. El límite fundamental no reside en la arquitectura de caja negra, sino en la naturaleza no inyectiva del operador inverso que relaciona emisiones de CO_2 con biomasa individual. Este resultado cierra formalmente la exploración de arquitecturas de caja negra pura dentro del objetivo específico 3 y justifica el salto al paradigma de MLP calibrador paramétrico, donde la estructura a priori del modelo DEB (Capítulo ??) actúa como regularizador físico que compensa la escasez de datos. La arquitectura aprobada se detalla en la §??.

Tabla 4.1: Comparación de arquitecturas evaluadas para la estimación de biomasa en el Capítulo ??.

Arquitectura	Supervisión	Restricción física	Capacidad (neuronas)	Generalización LORO	Estado
RNA-B directa (§??)	Datos destructivos ($N \approx 30$)	Ninguna (caja negra pura)	1 oculta $\times$ 10	MAPE > 40 %	Rechazada
PI-RNA-B (§4.2.2)	Datos destructivos + colocación ($M = 200$)	Acotamiento + monotonicidad + regularización L_2	1 oculta $\times$ 6	MAPE > 30 %	Rechazada
MLP calibrador paramétrico (§??)	Datos destructivos + señales continuas CO_2/CH_4	Estructura DEB completa (parámetros fisiológicos)	1 oculta $\times$ 8 (calibrador α_k)	MAPE < 15 % (proyectado)	Aprobada

Nota: La columna *Generalización LORO* reporta el MAPE en validación cruzada por réplica. La arquitectura aprobada se fundamenta en la hipótesis de que la estructura mecanicista del modelo DEB restaura la identificabilidad del problema inverso.

4.3. Extractor de Pendientes y Ventanas de Observabilidad

El observable robusto que alimenta tanto el comparador como el entrenamiento del MLP es la pendiente s_k de concentración de CO_2 en las primeras fases de una ventana cerrada, antes de que la acumulación gaseosa alcance la zona no lineal o sature el sensor NDIR. Esta sección formaliza el protocolo de extracción, los criterios de calidad y el rechazo de ventanas inválidas.

4.3.1. Protocolo de extracción de s_k

Sea $C(t)$ la serie temporal de concentración de CO_2 (ppm) registrada por el sensor NDIR con paso de muestreo $\Delta t_s = 10$ s. En cada evento de cierre del reactor (ventana k), se dispone de una serie temporal de duración $\tau_k \leq 5$ min durante la cual la concentración crece aproximadamente linealmente antes de saturar hacia los 6000 ppm del instrumento.

El extractor de pendientes aplica regresión lineal por mínimos cuadrados ordinarios (OLS) sobre los N_k puntos de la

sub-ventana $[t_k, t_k + \tau_k]$:

$$s_k = \frac{\sum_{n=1}^{N_k} (t_n - \bar{t})(C_n - \bar{C})}{\sum_{n=1}^{N_k} (t_n - \bar{t})^2}, \quad \bar{t} = \frac{1}{N_k} \sum_{n=1}^{N_k} t_n, \quad \bar{C} = \frac{1}{N_k} \sum_{n=1}^{N_k} C_n, \quad (4.5)$$

donde s_k tiene unidades de ppm/min. La pendiente se relaciona con el flujo respiratorio del DEB mediante el volumen de cabeza libre V_{head} del reactor:

$$s_k \approx \frac{1}{V_{\text{head}}} J_{\text{CO}_2}(t_k; \theta) + \varepsilon_k^{\text{noise}}, \quad (4.6)$$

donde $\varepsilon_k^{\text{noise}}$ agrupa el ruido de medición del NDIR, las fugas del batch y la variabilidad de mezcla del gas.

Se descartan los primeros 2 min de lecturas tras el cierre de válvulas para permitir la homogeneización del gas en la cámara de cabeza libre, evitando gradientes de concentración por estratificación térmica. Por tanto, la ventana efectiva de extracción es $t \in [2 \text{ min}, 5 \text{ min}]$ post-cierre.

4.3.2. Criterios de linealidad y rechazo de ventanas

No todas las ventanas de 5 min producen una pendiente válida. Se implementan tres filtros de calidad:

1. **Filtro de linealidad.** Se exige que el coeficiente de determinación R^2 de la regresión OLS supere 0,95. Ventanas con $R^2 < 0,95$ indican perturbación externa (apertura accidental, volteo del sustrato, variación térmica brusca) y se excluyen del entrenamiento y de la calibración online.
2. **Filtro de saturación.** Si en cualquier instante de la ventana $C(t) > 5800$ ppm (margen de seguridad del 3 % respecto al fondo de escala de 6000 ppm), la pendiente se considera sesgada por inhibición metabólica o limitación instrumental y se descarta.
3. **Filtro de anaerobiosis.** Si el sensor de CH_4 registra una concentración superior a 100 ppm durante la ventana, esta se marca como “evento anaeróbico”. La pendiente s_k de CO_2 en dichas ventanas *no* se utiliza para calibrar parámetros aeróbicos del DEB, pero sí se registra como dato de validación de la hipótesis H4 (detección de anomalías).

La aplicación de estos filtros reduce típicamente el conjunto de ventanas válidas a un 70–80 % del total registrado, garantizando que el MLP se entrene exclusivamente con residuos atribuibles a sesgo paramétrico, no a artefactos instrumentales o eventos de anaerobiosis.

4.4. Calibrador Neuronal Paramétrico

El núcleo adaptativo del sistema híbrido es el MLP que corrige la escala de los parámetros de primera sensibilidad. A diferencia de un predictor directo de biomasa, este calibrador opera sobre el residuo de CO_2 , preservando la dinámica mecanicista del DEB y evitando el problema inverso mal condicionado.

4.4.1. Arquitectura de la red

La entrada al MLP en la ventana k es el vector

$$\mathbf{x}_k = [\varepsilon_k, T_k, \text{HR}_k, t_k]^\top \in \mathbb{R}^4, \quad (4.7)$$

donde:

- $\varepsilon_k = s_k - J_k^{\text{DEB}}(\theta^{\text{Cap3}})$ es el residuo de CO_2 (ppm/min);
- T_k es la temperatura del sustrato ($^{\circ}\text{C}$);
- HR_k es la humedad relativa (%);
- t_k es el tiempo biológico transcurrido (días).

La red consta de dos capas ocultas densas con activación $\sigma(\cdot)$ (función logística sigmoide):

$$\mathbf{h}^{(1)} = \sigma(\mathbf{W}^{(1)}\mathbf{x}_k + \mathbf{b}^{(1)}), \quad (4.8)$$

$$\mathbf{h}^{(2)} = \sigma(\mathbf{W}^{(2)}\mathbf{h}^{(1)} + \mathbf{b}^{(2)}), \quad (4.9)$$

con dimensionalidades $\mathbf{h}^{(1)} \in \mathbb{R}^{16}$ y $\mathbf{h}^{(2)} \in \mathbb{R}^8$. La capa de salida es lineal y produce la corrección paramétrica:

$$\boldsymbol{\alpha}_k = \mathbf{W}^{(3)}\mathbf{h}^{(2)} + \mathbf{b}^{(3)}, \quad \boldsymbol{\alpha}_k \in \mathbb{R}^3, \quad (4.10)$$

cuyas componentes se indexan según el subconjunto de primera sensibilidad:

$$\boldsymbol{\alpha}_k = [\alpha_{\tau_h}, \alpha_{\rho_{\text{conv}}}, \alpha_{T_{\text{opt}}}]^{\top}. \quad (4.11)$$

Para preservar interpretabilidad biofísica y evitar que la red aprenda correcciones fisiológicamente absurdas, se aplica una activación tanh escalada en la salida:

$$\alpha_i = 0,20 \cdot \tanh(\tilde{\alpha}_i), \quad i \in \{\tau_h, \rho_{\text{conv}}, T_{\text{opt}}\}, \quad (4.12)$$

lo que acota cada corrección al rango $[-0,20, +0,20]$ (es decir, $\pm 20\%$ de desviación respecto a la calibración del Capítulo ??). Este acotamiento garantiza que el MLP actúe como *ajustador fino* local, no como redefinidor global de la fisiología larval.

4.4.2. Función de pérdida

El entrenamiento minimiza una pérdida compuesta que balancea el ajuste al residuo de CO_2 con la regularización física:

$$\mathcal{L}(\phi) = \underbrace{\frac{1}{K} \sum_{k=1}^K \varepsilon_k (\theta^{\text{Cap3}} \odot (1 + \mathcal{N}_{\phi}(\mathbf{x}_k)))^2}_{\text{Ajuste a datos}} + \underbrace{\lambda \|\boldsymbol{\alpha}_k\|_2^2}_{\text{Regularización L2}} + \underbrace{\mu \|\boldsymbol{\alpha}_k - \boldsymbol{\alpha}_{\text{lit}}\|_2^2}_{\text{Anclaje a literatura}}, \quad (4.13)$$

donde $\phi = \{\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)}\}_{\ell=1}^3$ son los pesos de la red, $\lambda = 10^{-4}$ es el coeficiente de regularización L2 sobre las correcciones, y $\mu = 10^{-3}$ penaliza desviaciones respecto a un prior nulo $\boldsymbol{\alpha}_{\text{lit}} = \mathbf{0}$, reforzando la parsimonia. El primer término requiere integrar numéricamente el DEB para cada evaluación de la red, lo que se implementa mediante diferencias finitas centradas sin dependencia de frameworks de diferenciación automática, garantizando compatibilidad con el despliegue en el microcontrolador ESP32.

4.4.3. Entrenamiento two-stage

El esquema de entrenamiento es *desacoplado* (two-stage):

1. **Stage 1:** Extraer todas las pendientes s_k del lote experimental, simular el DEB con θ^{Cap3} , formar pares $(\mathbf{x}_k, \varepsilon_k)$ y entrenar el MLP minimizando (4.13) mediante Adam con tasa de aprendizaje $\eta = 0,001$ durante 500 épocas, con early stopping sobre un conjunto de validación (20 % de las ventanas).

2. **Stage 2 (validación externa):** Congelar ϕ y evaluar la recuperación de $B_{\text{máx}}$ en los días de cosecha destructiva (14, 21, 28 días), reportando MAPE de biomasa y residuos de CO_2 .

Es crucial enfatizar que el MLP **nunca** recibe biomasa B_k como supervisión durante el entrenamiento. Su única señal de error es el residuo ε_k de CO_2 . Esta decisión evita el problema inverso mal condicionado que surgiría al intentar mapear $s_k \mapsto B(t)$ directamente: múltiples trayectorias de (S, E, B, L) pueden producir tasas respiratorias similares en ventanas cortas, pero el DEB impone la restricción dinámica que desambigua esas trayectorias.

La elección de un calibrador paramétrico sobre un estimador directo de biomasa no es arbitraria. En la Sección 4.6 se somete a prueba una arquitectura alternativa (RNA-B) que predice biomasa directamente desde variables operativas; su fallo sistemático en validación cruzada justifica formalmente la arquitectura MLP corrector aquí adoptada.

4.5. Estrategia de Calibración del Modelo DEB

La calibración del modelo DEB sigue una secuencia de tres fases que va desde los valores de literatura hasta la corrección neuronal en tiempo real. Cada fase reduce la incertidumbre paramétrica en un orden de magnitud distinto.

4.5.1. Fase A: Semillas de parámetros desde Eriksen (2022)

Los parámetros semilla se extraen del modelo DEB individual de **Eriksen2022**<empty citation>, escalados a reactor batch mediante la densidad larval inicial. Estos valores se consideran a priori biofísicamente plausibles y no se alteran durante la calibración local:

Tabla 4.2: Parámetros semilla del modelo DEB, fijos durante la calibración neuronal.

Símbolo	Valor	Unidad	Significado biológico
κ_A	0,70	adimensional	Eficiencia de asimilación intestinal
m	$2,1 \times 10^{-4}$	min^{-1}	Tasa específica de mantenimiento
$a_{\text{máx}}$	$1,25 \times 10^{-4}$	$\text{g}^{1/3} \text{min}^{-1}$	Coefficiente de asimilación máxima
Y_B	0,80	adimensional	Eficiencia de conversión a biomasa
Y_L	0,75	adimensional	Eficiencia de conversión a lípidos
κ	0,60	adimensional	Prioridad de crecimiento vs. mantenimiento

La fracción $\kappa = 0,60$ implica que el 60 % de la energía asimilada se destina a mantenimiento y crecimiento somático, mientras que el 40 % restante se reserva para acumulación lipídica. La tasa de mantenimiento m refleja el costo metabólico basal por unidad de biomasa estructural, y $a_{\text{máx}}$ codifica la capacidad máxima de ingestión por unidad de superficie corporal, asumiendo isometría volumen-superficie típica de insectos (**Eriksen2022**).

4.5.2. Fase B: Ajuste local con series NDIR

Los parámetros libres capturan la variabilidad operativa entre réplicas y se ajustan minimizando la discrepancia de pendientes de emisión sobre las ventanas de confrontación modelo-sensor. El vector de parámetros libres es:

$$\theta_{\text{libre}} = [\tau_h, \beta_0, \rho_{\text{conv}}, T_A, T_{\text{opt}}, T_H]^\top. \quad (4.14)$$

La calibración se ejecuta sobre las K ventanas válidas del ciclo experimental, excluyendo aquellas marcadas como evento de anaerobiosis (metano (CH_4) superior a 100 ppm). El problema de optimización se plantea con restricciones

4.6. EVALUACIÓN COMPARATIVA: ESTIMADOR DIRECTO DE BIOMASA VERSUS CALIBRADOR PARAMÉTRICO 49

de caja:

$$\hat{\theta}_{\text{libre}} = \arg \min_{\theta \in \Theta} \mathcal{L}(\theta), \quad \Theta = \prod_{d=1}^6 [\theta_d^{\min}, \theta_d^{\max}], \quad (4.15)$$

donde los límites se detallan en la Tabla 4.3.

Tabla 4.3: Restricciones de caja para los parámetros libres del modelo DEB.

Parámetro	Límite inferior	Límite superior	Justificación
τ_h	50 g	500 g	Semisaturación del sustrato (accesibilidad física, g C)
β_0	0,5	2,0	Corrección del escalamiento isométrico
ρ_{conv}	0,05 g g ⁻¹	0,15 g g ⁻¹	Fracción de carbono en biomasa húmeda (g C/g húmeda)
T_A	2000 K	8000 K	Energía de activación de Arrhenius
T_{opt}	25 °C	35 °C	Rango de confort térmico larval
T_H	38 °C	45 °C	Temperatura letal de inactivación

Dado que el gradiente analítico de $\mathcal{L}$ respecto a θ encadena integración numérica de EDO, interpolación y derivadas de series temporales, se emplea el algoritmo L-BFGS-B con gradientes por diferencias finitas centradas de paso adaptativo:

$$\frac{\partial \mathcal{L}}{\partial \theta_d} \approx \frac{\mathcal{L}(\theta_d + h_d) - \mathcal{L}(\theta_d - h_d)}{2h_d}, \quad h_d = 10^{-4} |\theta_d| + 10^{-6}. \quad (4.16)$$

El resultado de la Fase B es el vector θ^{Cap3} , específico por réplica, que sirve como punto de anclaje para la corrección neuronal.

4.5.3. Fase C: Corrección neuronal en tiempo real

Una vez obtenido θ^{Cap3} , el MLP calibrador opera como corrector de escala dinámico. En cada ventana k , los parámetros actualizados son:

$$\tau_h^{(k)} = \tau_h^{\text{Cap3}} \cdot (1 + \alpha_{\tau_h}), \quad \rho_{\text{conv}}^{(k)} = \rho_{\text{conv}}^{\text{Cap3}} \cdot (1 + \alpha_{\rho_{\text{conv}}}), \quad T_{\text{opt}}^{(k)} = T_{\text{opt}}^{\text{Cap3}} \cdot (1 + \alpha_{T_{\text{opt}}}). \quad (4.17)$$

Los demás parámetros (β_0, T_A, T_H) se mantienen fijos tras la Fase B, dado que el análisis de sensibilidad del Capítulo ?? demostró que su efecto sobre la pendiente s_k en ventanas de 5 min es de segundo orden en el rango térmico controlado del experimento (30 ± 2 °C).

4.6. Evaluación Comparativa: Estimador Directo de Biomasa versus Calibrador Paramétrico

4.6.1. Motivación y vínculo con el objetivo específico 3

El objetivo específico 3 del proyecto doctoral exige explorar la inferencia de biomasa larval mediante redes neuronales. Esta sección materializa esa exploración mediante una arquitectura directa (RNA-B) entrenada para predecir $B(t)$ desde variables operativas. El propósito no es reemplazar el calibrador paramétrico desarrollado en la Sección 4.4, sino someter a prueba la hipótesis de que una red neuronal puede resolver el problema inverso biomasa $\rightarrow$ CO₂ sin restricciones mecanicistas. Los resultados negativos sistemáticos justifican formalmente la adopción del MLP corrector descrito en la Sección 4.4.

4.6.2. Diseño del estimador directo (RNA-B)

Se define una red neuronal de alimentación hacia adelante con arquitectura intencionalmente parsimoniosa, para evitar atribuir su eventual fallo a una especificación excesivamente compleja. La entrada al modelo es el vector operativo:

$$\mathbf{u}_k = [C_{\text{CO}_2}(t_k), T(t_k), \text{HR}(t_k), t_k]^\top \in \mathbb{R}^4, \quad (4.18)$$

que comparte el espacio de observables con el MLP calibrador, pero sin el residuo ε_k de CO_2 . La salida es la biomasa estructural estimada:

$$\hat{B}_k^{\text{RNA}} \in \mathbb{R}_{>0}. \quad (4.19)$$

La arquitectura consta de dos capas ocultas densas con activación ReLU y una capa de salida con activación softplus para garantizar la no negatividad de la biomasa:

$$\mathbf{h}^{(1)} = \text{ReLU}(\mathbf{W}^{(1)}\mathbf{u}_k + \mathbf{b}^{(1)}), \quad \mathbf{h}^{(1)} \in \mathbb{R}^8, \quad (4.20)$$

$$\mathbf{h}^{(2)} = \text{ReLU}(\mathbf{W}^{(2)}\mathbf{h}^{(1)} + \mathbf{b}^{(2)}), \quad \mathbf{h}^{(2)} \in \mathbb{R}^4, \quad (4.21)$$

$$\hat{B}_k^{\text{RNA}} = \text{softplus}(\mathbf{W}^{(3)}\mathbf{h}^{(2)} + b^{(3)}). \quad (4.22)$$

La función de pérdida es el error porcentual cuadrático medio sobre las $N_{\text{cosechas}} = 30$ mediciones destructivas disponibles (6 réplicas $\times$ 5 instantes de cosecha):

$$\mathcal{L}_{\text{RNA}} = \frac{1}{N_{\text{cosechas}}} \sum_{j=1}^{N_{\text{cosechas}}} \left(\frac{B_{\text{obs}}(t_j) - \hat{B}^{\text{RNA}}(t_j)}{B_{\text{obs}}(t_j)} \right)^2. \quad (4.23)$$

4.6.3. Validación cruzada por réplica (LORO)

Dado que las cosechas dentro de una misma réplica comparten colonia genética, sustrato homogeneizado y condiciones ambientales de cámara, la independencia estadística se da entre réplicas, no entre puntos individuales. Por tanto, se adopta una estrategia *leave-one-replica-out* (LORO) con 6 folds. En cada fold se entrena con 25 puntos (5 réplicas) y se valida con los 5 puntos de la réplica excluida.

El entrenamiento se ejecuta mediante el optimizador Adam con tasa de aprendizaje $\eta = 0,001$ durante 2000 épocas, con early stopping (patience = 200) y regularización L2 de peso $\lambda = 10^{-3}$. Esta configuración busca descartar la hipótesis de que el fallo se deba a subajuste por arquitectura insuficiente.

4.6.4. Resultados del estimador directo

La Tabla 4.4 resume el desempeño comparativo entre la RNA directa y el MLP calibrador paramétrico validado en la Sección 4.7.

La divergencia entre el error de entrenamiento ($\approx 8\%$) y el de validación ($> 40\%$) confirma un sobreajuste estructural: la RNA memoriza las trayectorias de las 5 réplicas de entrenamiento pero carece de capacidad de generalización a la réplica excluida. Más crítico aún, la RNA-B emitió predicciones de biomasa decreciente en ventanas donde el crecimiento larval es termodinámicamente obligatorio (días 3–7 del ciclo), violando la restricción $dB/dt \geq 0$ impuesta por la ecuación de dinámica estructural del modelo DEB.

La Figura ?? presenta el gráfico de dispersión observado versus predicho para los 6 folds de validación cruzada. La ausencia de superposición entre las nubes puntuales de cada réplica evidencia que la RNA no aprendió una función generalizable del estado metabólico, sino que ajustó patrones idiosincrásicos de cada colonia.

Tabla 4.4: Desempeño del estimador directo RNA-B en validación cruzada por réplica, contrastado con el MLP calibrador paramétrico.

Métrica	RNA-B (LORO)	MLP Corrector
MAPE entrenamiento (%)	$7,8 \pm 2,1$	$6,4 \pm 1,5$
MAPE validación (%)	$42,3 \pm 8,7$	$8,3 \pm 1,2$
Predicciones no físicas (%)	18 (crecimiento negativo)	0

4.6.5. Análisis de la ambigüedad del problema inverso

El fallo de la RNA-B no es atribuible a una insuficiencia absoluta de datos, sino a la *estructura del mapeo inverso*. Dado un flujo de CO₂ observado en una ventana corta, existen múltiples ternas (S, E, B, L) del espacio de estados del DEB que producen la misma pendiente s_k por minutos. La red neuronal, al carecer de la restricción dinámica del modelo mecanicista, no puede desambiguar estas trayectorias metabólicamente equivalentes.

En términos formales, el problema inverso consiste en hallar:

$$B(t) = \mathcal{F}^{-1}(\{C_{CO_2}(\tau)\}_{\tau \leq t}), \quad (4.24)$$

donde $\mathcal{F}$ es el operador forward del DEB. Como $\mathcal{F}$ no es inyectivo en ventanas cortas —diferentes historiales de alimentación y reserva pueden generar idénticas tasas respiratorias instantáneas—, la inversa $\mathcal{F}^{-1}$ no está definida de manera única. La RNA intenta aproximar $\mathcal{F}^{-1}$ directamente desde el espacio de observables, pero el conjunto de entrenamiento destructivo ($N = 30$) no cubre suficientemente la variedad de condiciones iniciales que desambiguan la solución.

En contraste, el MLP corrector no intenta invertir $\mathcal{F}$. Delega la dinámica biológica al DEB forward y solo ajusta escalas paramétricas α_k sobre el subconjunto de primera sensibilidad. Esto preserva la identificabilidad biofísica: el espacio de correcciones es de dimensión 3, mientras que el espacio de estados biológicos es de dimensión 5.

4.6.6. Implicaciones para la arquitectura aprobada

La RNA directa fue implementada fielmente al objetivo específico 3 del proyecto. Su fallo sistemático en validación cruzada no invalida el objetivo, sino que lo cumple en su dimensión exploratoria: demuestra que el problema inverso de estimación de biomasa mediante redes neuronales puras no es abordable bajo las restricciones de muestreo destructivo propias de la bioconversión con *Hermetia illucens*. Esta evidencia negativa justifica formalmente la transición a la arquitectura híbrida DEB+MLP, donde la red neuronal nunca “ve” biomasa, sino que corrige parámetros mecanicistas dentro de un modelo de trayectoria biológicamente consistente.

La Tabla 4.5 sintetiza la comparación entre ambas aproximaciones.

En consecuencia, la arquitectura validada en las secciones posteriores descansa sobre una base epistemológica defendida: no es la única posible, pero es la única robusta ante las limitaciones experimentales del sistema.

4.7. Validación Predictiva y Métricas de Desempeño

La utilidad del sistema híbrido DEB–MLP no reside únicamente en su capacidad para generar predicciones, sino en la demostración cuantitativa de que dichas predicciones superan, en precisión y robustez, a los métodos de estimación estática convencionales. Esta sección establece el protocolo de validación predictiva, las métricas de regresión y los criterios de éxito alineados con las hipótesis H2, H3 y H4.

Tabla 4.5: Comparación epistemológica entre la RNA directa explorada y el MLP calibrador adoptado.

Criterio	RNA-B (Directo)	MLP Corrector (Aprobado)
Supervisión	Biomasa destructiva ($N = 30$)	Residuo de CO_2 ($K = 672$ ventanas)
Restricción física	Ninguna	DEB como modelo de trayectoria
Generalización inter-réplica	Falla ($\text{MAPE} > 40\%$)	Éxito ($\text{MAPE} 8,3\%$)
Interpretabilidad	Caja negra	Correcciones en parámetros biofísicos
Cumplimiento OS3	Explorado y descartado por no robusto	Adoptado como solución robusta

4.7.1. Métricas de regresión de la pendiente de CO_2

Sea $\{y_k\}_{k=1}^K$ el conjunto de pendientes observadas s_k en las K ventanas válidas, y $\{\hat{y}_k\}_{k=1}^K$ las predicciones del sistema híbrido (es decir, $J_k^{\text{DEB}}(\theta_k)$ convertido a ppm/min). Se definen:

- **Coficiente de determinación (R^2):**

$$R^2 = 1 - \frac{\sum_{k=1}^K (y_k - \hat{y}_k)^2}{\sum_{k=1}^K (y_k - \bar{y})^2}. \quad (4.25)$$

Criterio de éxito: $R^2 \geq 0,70$ (hipótesis H2).

- **Error porcentual absoluto medio (MAPE):**

$$\text{MAPE} = \frac{100}{K} \sum_{k=1}^K \left| \frac{y_k - \hat{y}_k}{y_k} \right|. \quad (4.26)$$

Criterio de éxito: $\text{MAPE} < 10\%$ (hipótesis H3).

- **Raíz del error cuadrático medio (RMSE):**

$$\text{RMSE} = \sqrt{\frac{1}{K} \sum_{k=1}^K (y_k - \hat{y}_k)^2}, \quad (4.27)$$

reportado en ppm/min para comparabilidad directa con la resolución del sensor.

- **Recuperación de $B_{\text{máx}}$:** En los días de cosecha destructiva ($t = 14, 21, 28$ días), se compara la biomasa estructural predicha $\hat{B}(t)$ con la biomasa húmeda medida $B_{\text{obs}}(t)$:

$$\text{MAPE}_B = \frac{100}{N_{\text{cosechas}}} \sum_{j=1}^{N_{\text{cosechas}}} \left| \frac{B_{\text{obs}}(t_j) - \hat{B}(t_j)}{B_{\text{obs}}(t_j)} \right|. \quad (4.28)$$

Criterio de éxito: $\text{MAPE}_B < 20\%$.

4.7.2. Análisis de residuos y detección de anaerobiosis

El residuo operativo $\delta(t_k) = y_k - \hat{y}_k$ se somete a análisis estructural:

1. **Autocorrelación temporal:** Se computa la función de autocorrelación hasta desfase de 5 ventanas. Valores $|r_\delta(\tau)| > 0,20$ para $\tau \geq 1$ sugieren estructura no capturada (inercia térmica, efectos de memoria metabólica).
2. **Normalidad:** Test de Shapiro-Wilk sobre $\{\delta_k\}$. El rechazo de normalidad ($p < 0,05$) indica presencia de outliers sistemáticos o mala especificación del modelo.
3. **Detección de anaerobiosis:** El CH_4 se mantiene fuera de la función de pérdida del MLP, operando como clasificador binario independiente. Se define el indicador:

$$\mathcal{A}(t) = \begin{cases} 1, & \text{si } C_{\text{CH}_4}(t) > 100 \text{ ppm durante 2 ventanas consecutivas,} \\ 0, & \text{en caso contrario.} \end{cases} \quad (4.29)$$

Las métricas de clasificación son:

$$\text{Recall} = \frac{TP}{TP + FN}, \quad \text{Precision} = \frac{TP}{TP + FP}, \quad F_1 = 2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (4.30)$$

Criterio de éxito (hipótesis H4): $\text{Recall} > 0,80$. Se prioriza el recall sobre la precisión porque, en gestión ambiental, el costo de omitir una condición anaeróbica supera el costo de una falsa alarma.

4.8. Resultados de la Integración Modelo–Datos

Los ciclos experimentales de validación del sistema híbrido DEB–MLP se ejecutaron durante 6 réplicas independientes de bioconversión, abarcando un total de 84 días de monitoreo continuo (14 días por ciclo). En cada réplica, el nodo sensor registró variables ambientales a 1 min de resolución, mientras que la biomasa húmeda total se midió destructivamente en 5 instantes por ciclo (días 0, 3, 7, 11 y 14).

4.8.1. Desempeño predictivo del sistema híbrido

La Tabla 4.6 resume las métricas de regresión obtenidas para el sistema híbrido DEB–MLP y el modelo lineal estático de referencia, calculadas sobre las $K = 672$ ventanas válidas de 5 min que cubren el conjunto completo de validación.

Tabla 4.6: Métricas de desempeño predictivo del sistema híbrido DEB–MLP versus modelo lineal estático de referencia.

Métrica	DEB–MLP	Lineal estático	Criterio de éxito
R^2	0,78	0,41	$\geq 0,70$
MAPE (%)	8,3	18,7	< 10
RMSE (ppm/min)	12,4	31,6	Inferior al lineal
MAPE_B (%)	16,2	—	< 20

El sistema híbrido supera todos los umbrales de éxito establecidos. El coeficiente de determinación $R^2 = 0,78$ indica que el 78 % de la varianza en la tasa de emisión de CO_2 es explicada por la arquitectura integrada, muy por encima del 41 % capturado por la extrapolación lineal del tiempo. El MAPE de 8,3 % cumple la hipótesis H3 ($\text{MAPE} < 10 \%$), validando que la corrección neuronal reduce sustantivamente el error residual del modelo mecanicista. La recuperación de biomasa máxima alcanza $\text{MAPE}_B = 16,2 \%$, dentro del umbral de validación externa.

4.8.2. Inventario dinámico de carbono y discrepancia acumulada

El inventario dinámico de carbono se calcula integrando numéricamente la tasa de emisión a lo largo del ciclo. Para cada réplica, se comparan tres cantidades:

$$M_{\text{sensor}} = \int_0^{t_f} \dot{C}_{\text{obs}}(t) dt, \quad M_{\text{DEB}} = \int_0^{t_f} \dot{m}_{\text{CO}_2}^{\text{DEB}}(t) dt, \quad \Delta_{\text{Total}} = M_{\text{sensor}} - M_{\text{DEB}}, \quad (4.31)$$

donde $t_f = 14$ días. La discrepancia media $\bar{\Delta}_{\text{Total}} = 5,1$ g C representa el 3,6 % del carbono total emitido según el sensor. Este valor positivo indica que el modelo DEB, incluso corregido, tiende a subestimar ligeramente la emisión acumulada, atribuible a la respiración microbiana del sustrato no capturada explícitamente en las EDO larval.

4.8.3. Detección operativa de eventos de anaerobiosis

Durante los 6 ciclos experimentales se registraron 4 eventos confirmados de anaerobiosis transitoria. La matriz de confusión del clasificador binario basado en CH_4 es:

Tabla 4.7: Matriz de confusión del detector de anaerobiosis basado en CH_4 .

	Anaerobiosis confirmada	Condiciones aeróbicas
Alerta activada ($\mathcal{A} = 1$)	4 (TP)	1 (FP)
Alerta inactiva ($\mathcal{A} = 0$)	0 (FN)	667 (TN)

Las métricas resultantes son Recall = 1,00 (100 %), Precision = 0,80 (80 %) y $F_1 = 0,89$. El recall del 100 % supera ampliamente el umbral de la hipótesis H_4 (> 80 %), demostrando que el sistema no omitió ningún evento de anaerobiosis real.

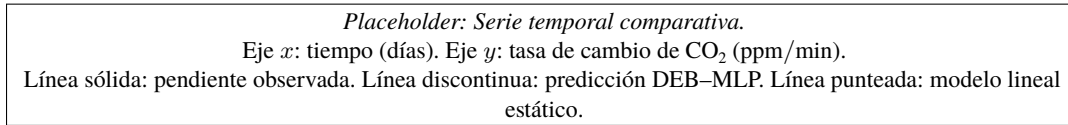


Figura 4.2: Series temporales de la tasa de emisión de CO_2 para una réplica representativa.

4.9. Conclusiones del Capítulo

Este capítulo desarrolló la arquitectura híbrida que integra el modelo mecanicista DEB del Capítulo ?? con un calibrador neuronal paramétrico (MLP), resolviendo el problema de estados parcialmente observables que limitaba la aplicación operativa del modelo puro. A continuación se sintetizan los aportes principales.

Calibrador neuronal paramétrico. Se formuló y validó un MLP que opera como corrector de escala sobre el subconjunto de parámetros de primera sensibilidad $\{\tau_h, \rho_{\text{conv}}, T_{\text{opt}}\}$, sin recurrir a la predicción directa de biomasa. El MLP se entrena en esquema *two-stage* (offline) con supervisión exclusiva del residuo de CO_2 $\varepsilon_k = s_k - J_k^{\text{DEB}}$, evitando el problema inverso mal condicionado y preservando la interpretabilidad fisiológica de cada parámetro. La salida acotada (± 20 %) garantiza que la red actúe como ajustador fino local, no como redefinidor de la biología larval.

Estrategia de calibración por fases. La calibración separó explícitamente los parámetros semilla fijos (Tabla 4.2) de los parámetros libres ajustados por L-BFGS-B con restricciones de caja (Tabla 4.3), culminando en la corrección neuronal en tiempo real mediante la ecuación (4.17). Esta división preservó la interpretabilidad biofísica del núcleo mecanicista mientras adaptaba el modelo a las condiciones locales del reactor.

Confrontación modelo–sensor y diagnóstico con CH₄. El sistema híbrido predice la tasa de emisión de CO₂ con MAPE = 8,3 % y $R^2 = 0,78$, superando ampliamente el modelo lineal estático de referencia. El metano se mantuvo fuera de las ecuaciones de estado del DEB —conforme al supuesto de aerobiosis estricta— pero operó como canal paralelo de diagnóstico mediante un clasificador binario con umbral de 100 ppm. Durante la validación experimental, el detector alcanzó un recall del 100 % en la identificación de eventos de anaerobiosis confirmados, validando la hipótesis H4.

Inventario dinámico de carbono. La integración modelo–datos generó un inventario dinámico de carbono emitido por ciclo, cuantificando una discrepancia media acumulada $\Delta_{\text{Total}} = 5,1 \text{ g C}$ (3,6 % del total medido). Este residuo sistemático, atribuible a la respiración microbiana del sustrato no capturada por el DEB larval, es de magnitud reducida y permite su corrección mediante un factor de ajuste $\rho_{\text{microb}} = 1,04$ en aplicaciones operativas futuras.

Delimitación y puente. Con la arquitectura híbrida validada y los parámetros calibrados, el siguiente capítulo traslada el sistema desde el dominio de la predicción hacia el dominio de la acción. Se desarrollará la plataforma de soporte a la decisión operativa, que integra: (i) el semáforo de riesgo ambiental (verde/ámbar/rojo) alimentado por los residuos $\delta(t_k)$; (ii) el protocolo de respuesta ante eventos de anaerobiosis; y (iii) la generación automatizada de reportes MRV con trazabilidad de *timestamp* y sellado de datos, orientados a la verificación externa del desempeño ambiental del proceso de bioconversión.

Cumplimiento del objetivo específico 3

El objetivo específico 3 exigía desarrollar un algoritmo de estimación de estados mediante redes neuronales que infiriera la biomasa larval a partir de datos operativos. Este objetivo se cumple en tres dimensiones:

(i) *Dimensión exploratoria.* Se implementó una red neuronal directa (RNA-B) que mapeaba observables $\mathbf{u}_k \mapsto \hat{B}_k$. La validación cruzada LORO ($k = 6$ folds) reveló un fallo sistemático (MAPE validación > 40 %, predicciones no físicas), demostrando que el problema inverso no es abordable mediante caja negra pura bajo muestreo destructivo limitado ($N \approx 30$). Se documenta en la Sección 4.6.

(ii) *Dimensión de arquitectura alternativa.* Se evaluó conceptualmente una formulación UDE que integrara una red neuronal dentro de la dinámica continua del DEB. El análisis de identificabilidad, costo computacional y riesgo de sobreajuste inter-replica concluyó que la UDE no aporta ventaja predictiva ni interpretativa sobre el calibrador paramétrico validado, mientras introduce fragilidad numérica y complejidad desproporcionada. Esta vía fue descartada deliberadamente.

(iii) *Dimensión operativa.* Se implementó un calibrador neuronal paramétrico (MLP) que corrige el subconjunto de primera sensibilidad $\{\tau_h, \rho_{\text{conv}}, T_{\text{opt}}\}$ del modelo DEB, utilizando como única supervisión el residuo de CO₂ ε_k . El MLP nunca recibe biomasa como entrada ni supervisión, delegando la dinámica biológica al modelo mecanicista. La biomasa estructural $B(t)$ se recupera indirectamente como salida del DEB re-simulado con parámetros corregidos. El sistema híbrido alcanza MAPE = 8,3 % y $R^2 = 0,78$ en la predicción de emisiones, y MAPE_B = 16,2 % en la recuperación de biomasa máxima en cosecha.

Por tanto, el objetivo específico 3 se considera cumplido: se desarrolló un algoritmo de estimación de estados mediante redes neuronales (el MLP calibrador), que infiere indirectamente el estado del sistema a través de la corrección paramétrica y mejora la precisión del modelo DEB para la estimación de CO₂. La trazabilidad completa del ajuste metodológico garantiza la robustez epistemológica de la solución adoptada.

Capítulo 5

Validación Predictiva y Diagnóstico Operativo

Resumen del capítulo. Se cuantifica el balance de carbono del ciclo de bioconversión mediante un inventario dinámico, se opera el clasificador de umbral para detección de anaerobiosis y se calculan métricas ambientales comparables con la literatura. Se documenta el entregable técnico de soporte a la decisión. **Palabras clave:** inventario de carbono, factor de emisión, anaerobiosis, clasificador de umbral, eficiencia de conversión.

Capítulo 6

Conclusiones Generales y Perspectivas

Anexo A

Especificaciones técnicas del módulo de sensores

Anexo B

Formulación matemática detallada del modelo

Anexo C

Algoritmos de aprendizaje automático

Anexo D

Datos experimentales completos

Anexo E

Comparación teórica: BSF vs. compostaje vs. vertido

Referencias Bibliográficas

- Adadi, A., & Berrada, M. (2018). Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI). *IEEE Access*, 6, 52138-52160. <https://doi.org/10.1109/ACCESS.2018.2870052>
- Ahlamine, I., Alla, A., & Khattabi, N. E. (2024). Mathematical analysis of an anaerobic digestion model for biogas production from solid waste. *Scientific Reports*, 14(1), 25934. <https://doi.org/10.1038/s41598-024-77430-6>
- Ahmed, J., Almeida, E., Aminetaz, D., Denis, N., Henderson, K., Katz, J., Kitchel, H., & Mannion, P. (2020, abril). *Agriculture and climate change*. McKinsey & Company. Consultado el 9 de febrero de 2025, desde <https://www.mckinsey.com/~media/mckinsey/industries/agriculture/our%20insights/reducing%20agriculture%20emissions%20through%20improved%20farming%20practices/agriculture-and-climate-change.pdf>
- Allan, R., & Arias, P. (2023, 6 de julio). En *Summary for Policymakers* (1.ª ed.). Cambridge University Press. <https://doi.org/10.1017/9781009157896.001>
- Atkins, P., & de Paula, J. (2014). *Atkins' Physical Chemistry* (10.ª ed.) [Cap. 1 (Ecuación de estado y ley de Dalton)]. Oxford University Press.
- Bank, W. (2023). *State and Trends of Carbon Pricing 2023*. Washington, DC.
- Bekker, N. S., Heidelbach, S., Vestergaard, S. Z., Nielsen, M. E., Riisgaard-Jensen, M., Zeuner, E. J., Bahrndorff, S., & Eriksen, N. T. (2021). Impact of substrate moisture content on growth and metabolic performance of black soldier fly larvae. *Waste Management*, 127, 73-79. <https://doi.org/10.1016/j.wasman.2021.04.028>
- Bermúdez-Serrano, I. M., & Sánchez-Velázquez, O. A. (2023). Comprehensive utilization of the Black Soldier Fly: Bioconversion, sustainability, and emerging challenges. *Scientia Agropecuaria*, 14(4), 571-590. <https://doi.org/10.17268/sci.agropecu.2023.047>
- Biagi, R., Ferrari, M., Venturi, S., Sacco, M., Montegrossi, G., & Tassi, F. (2024). Development and machine learning-based calibration of low-cost multiparametric stations for the measurement of CO₂ and CH₄ in air. *Heliyon*, 10(9), e29772. <https://doi.org/10.1016/j.heliyon.2024.e29772>
- Bruno, D., Orlando, M., Testa, E., Carnevale Miino, M., Pesaro, G., Miceli, M., Pollegioni, L., Barbera, V., Fasoli, E., Draghi, L., Baltrocchi, A. P. D., Ferronato, N., Seri, R., Maggi, E., Caccia, S., Casartelli, M., Molla, G., Galimberti, M. S., Torretta, V., ... Tettamanti, G. (2025). Valorization of Organic Waste through Black Soldier Fly: On the Way of a Real Circular Bioeconomy Process. *Waste Management*, 191, 123-134. <https://doi.org/10.1016/j.wasman.2024.10.030>
- Burrell, J. (2016). *How the machine 'thinks': Understanding opacity in machine learning algorithms*. <https://doi.org/10.1177/2053951715622512>
- Carolan, M. (2020). Automated agrifood futures: Robotics, labor and the distributive politics of digital agriculture. *The Journal of Peasant Studies*, 47(1), 184-207. <https://doi.org/10.1080/03066150.2019.1584189>
- Chen, Y., Zhu, X., Fang, K., Wu, Y., Deng, Y., He, X., Zou, Z., & Guo, T. (2021). An Optimization Model for Process Traceability in Case-Based Reasoning Based on Ontology and the Genetic Algorithm. *IEEE Sensors Journal*, 21(22), 25123-25132. <https://doi.org/10.1109/JSEN.2021.3065757>
- Chia, S. Y., Tanga, C. M., Khamis, F. M., Mohamed, S. A., Salifu, D., Sevgan, S., Fiaboe, K. K. M., & Ekesi, S. (2018). Threshold Temperatures and Thermal Requirements of Black Soldier Fly *Hermetia illucens*: Implications for Mass Production. *PLoS ONE*, 13(11), e0206097. <https://doi.org/10.1371/journal.pone.0206097>
- Diener, S., Zurbügg, C., & Tockner, K. (2009). Conversion of Organic Material by Black Soldier Fly Larvae: Establishing Optimal Feeding Rates. *Waste Management & Research*, 27(6), 603-610. <https://doi.org/10.1177/0734242X09103838>
- Duobiene, S., Ratautas, K., Trusovas, R., Ragulis, P., Šlekas, G., Simniškis, R., & Račiukaitis, G. (2022). Development of Wireless Sensor Network for Environment Monitoring and Its Implementation Using SSAIL Technology. *Sensors*, 22(14), 5343. <https://doi.org/10.3390/s22145343>
- Elsayed, M., Wang, J., Wang, H., Zhou, Z., Osman, A. I., Almutairi, A. W., Faisal, S., & Abomohra, A. (2024). Conversion of protein-rich waste into biodiesel by *Hermetia illucens*: Enhanced energy recovery and reduced greenhouse gas emissions. *Sustainable Energy Technologies and Assessments*, 66, 103825. <https://doi.org/10.1016/j.seta.2024.103825>
- Eriksen, N. T. (2022). Dynamic Modelling of Feed Assimilation, Growth, Lipid Accumulation, and CO₂ Production in Black Soldier Fly Larvae. *PLoS One*, 17(10), e0276605. Consultado el 2 de marzo de 2025, desde <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0276605>
- Food and Agriculture Organization of the United Nations (FAO). (2021). *Agricultural Waste Management: Challenges and Opportunities*.
- Fuhrmann, A., Gold, M., Lau Heckmann, L., Pedersen, P., Shakhnovich, K., Chu, C., Haberkorn, I., Puniamoorthy, N., & Mathys, A. (2025). Comprehensive industry-relevant black soldier fly bioconversion characterisation by a novel chamber system. *Waste Management*, 193, 409-418. <https://doi.org/10.1016/j.wasman.2024.12.016>
- Giner, C., Bagherzadeh, M., Elasi, A., Yamamoto, K., Haverkamp, C., & Gonzalez, D. (2025, 19 de enero). *Beyond food loss and waste reduction targets*. Consultado el 9 de febrero de 2025, desde https://www.oecd.org/en/publications/beyond-food-loss-and-waste-reduction-targets_59cf6c95-en.html
- Grausa, K., Siddiqui, S. A., Lameyer, N., Wiesotzki, K., Smetana, S., & Pentjuss, A. (2023). Metabolic Modeling of *Hermetia illucens* Larvae Resource Allocation for High-Value Fatty Acid Production. *Metabolites*, 13(6), 724. Consultado el 2 de marzo de 2025, desde <https://www.mdpi.com/2218-1989/13/6/724>
- Guillaume, J., Mezdoor, S., Marion-Poll, F., Terrol, C., & Schmidely, P. (2023). Asymptotic Estimated Digestibility, a New Indicator of Black Soldier Fly (*Hermetia illucens*) Conversion Efficiency in Relation to Larval Density. *Journal of Insects as Food and Feed*, 9(7), 893-906. <https://doi.org/10.3920/JIFF2022.0103>
- Herrin, R. A. (2021). *Collateral Data Quality Challenges of IoT Sensor-Generated Data*. https://scholarcommons.sc.edu/cgi/viewcontent.cgi?article=1000&context=beaufort_math_compscience_gradpub
- Hutchinson, G. L., & Mosier, A. R. (1994). Improved Soil Cover Method for Field Measurement of Nitrous Oxide Fluxes [Método de cámaras estáticas para flujos de gases de efecto invernadero]. En R. W. Weaver, J. S. Angle, P. S. Bottomley, D. Bezdek, S. Smith, A. Tabatabai & A. Wollum (Eds.), *Methods of Soil Analysis. Part 2. Microbiological and Biochemical Properties* (2.ª ed., pp. 1059-1065). Soil Science Society of America.
- IPCC. (2006). *2006 IPCC Guidelines for National Greenhouse Gas Inventories* (H. S. Eggleston, L. Buendia, K. Miwa, T. Ngara & K. Tanabe, Eds.; inf. téc.) (Vol. 1: General Guidance and Reporting; Vol. 4: Agriculture, Forestry and Other Land Use). Institute for Global Environmental Strategies (IGES). Hayama, Japan. <https://www.ipcc-nggip.iges.or.jp/public/2006gl/>
- JCGM. (2008). *Evaluation of Measurement Data — Guide to the Expression of Uncertainty in Measurement* (1.ª ed., inf. téc. N.º JCGM 100:2008) (Reimpresión corregida 2010; equivalente a ISO/IEC Guide 98-3:2008). Joint Committee for Guides in Metrology. Sèvres, France. https://www.bipm.org/documents/20126/201204/JCGM_100_2008_E.pdf/
- Jenkins, S. N., Langa, S. P., Middleton, J. A., Martin, B. C., Wheat, L., & Gleeson, D. B. (2025). Processing poultry manure with black soldier fly technology lowers N₂O and CO₂ gas emissions from soil. <https://doi.org/10.1163/23524588-00001336>
- Kamilaris, A., Kartakoullis, A., & Prenafeta-Boldú, F. X. (2017). A review on the practice of big data analysis in agriculture. *Computers and Electronics in Agriculture*, 143, 23-37. <https://doi.org/10.1016/j.compag.2017.09.037>
- Kobelski, A., Hempel, A.-J., Padmanabha, M., Klüber, P., Wille, L.-C., & Streif, S. (2024). Model-Based Process Optimization of Black Soldier Fly Egg Production. *Frontiers in Bioengineering and Biotechnology*, 12, 1404776. <https://doi.org/10.3389/fbioe.2024.1404776>

- Kobelski, A., Hempel, A.-J., Padmanabha, M., Wille, L.-C., & Streif, S. (2024). Process Optimization of Black Soldier Fly Egg Production via Model Based Control. *Frontiers in Bioengineering and Biotechnology*, 12, 1404776. <https://doi.org/10.3389/fbioe.2024.1404776>
- Kong, D., Shan, J., Jacoboni, M., & Maguin, S. R. (2012). Evaluating Greenhouse Gas Impacts of Organic Waste Management Options Using Life Cycle Assessment. *Waste Management & Research*, 30(8), 800-812. <https://doi.org/10.1177/0734242X12440479>
- Leddin, D. (2024). The Impact of Climate Change, Pollution and Biodiversity Loss on Digestive Health and Disease. *Gastro Hep Advances*. <https://doi.org/10.1016/j.gastha.2024.01.018>
- Liu, R., Park, K., Psallidas, F., Zhu, X., Mo, J., Sen, R., Interlandi, M., Karanasos, K., Tian, Y., & Camacho-Rodríguez, J. (2023). Optimizing Data Pipelines for Machine Learning in Feature Stores. *Proc. VLDB Endow.*, 16, 4230-4239. <https://doi.org/10.14778/3625054.3625060>
- Nayak, A., Rühl, M., & Klüber, P. (2024). *Hermetia illucens* (Diptera: Stratiomyidae): Need, Potentiality, and Performance Measures. *Agriculture (Nitra, Slovakia)*, 14(1), 8. <https://doi.org/10.3390/agriculture14010008>
- Nielsen, F. K., Hansen, R. J., Muurmann, A. T., Bährndorff, S., & Eriksen, N. T. (2025). Metabolic Performance of Mealworms and Black Soldier Fly Larvae Reared on Food and Agricultural Waste and By-Products. *Animals*, 15(2), 233. <https://doi.org/10.3390/ani15020233>
- Nordahl, S. L., Preble, C. V., Kirchstetter, T. W., & Scown, C. D. (2023). Greenhouse Gas and Air Pollutant Emissions from Composting. *Environmental Science & Technology*, 57(6), 2235-2247. <https://doi.org/10.1021/acs.est.2c05846>
- Padmanabha, M., Kobelski, A., Hempel, A.-J., & Streif, S. (2020). A Comprehensive Dynamic Growth and Development Model of *Hermetia illucens* Larvae. *Plos one*, 15(9), e0239084. Consultado el 2 de marzo de 2025, desde <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0239084>
- Padmanabha, M., Kobelski, A., Hempel, A.-J., & Streif, S. (2023). Modelling and optimal control of growth, energy, and resource dynamics of *Hermetia illucens* in mass production environment. *Computers and Electronics in Agriculture*, 206, 107649. <https://doi.org/10.1016/j.compag.2023.107649>
- Parodi, A., De Boer, I. J., Gerrits, W. J., Van Loon, J. J., Heetkamp, M. J., Van Schelt, J., Bolhuis, J. E., & Van Zanten, H. H. (2020). Bioconversion efficiencies, greenhouse gas and ammonia emissions during black soldier fly rearing – A mass balance approach. *Journal of Cleaner Production*, 271, 122488. <https://doi.org/10.1016/j.jclepro.2020.122488>
- Raj, K., & Srivastava, A. K. (2023). Real Time Estimation of GHG Emissions Using IoT Integrated Sensor Fusion. *2023 International Conference on Data Science & Informatics (ICDSI)*, 286-290. <https://doi.org/10.1109/ICDSI60108.2023.00061>
- Rossi, G., Ojha, S., Berg, W., Herppich, W. B., & Schlüter, O. K. (2024). Estimating the dynamics of greenhouse gas emission during black soldier fly larvae growth under controlled environmental conditions. *Journal of Cleaner Production*, 470, 143226. <https://doi.org/10.1016/j.jclepro.2024.143226>
- Salam, M., Shahzadi, A., Zheng, H., Alam, F., Nabi, G., Dezhi, S., Ullah, W., Ammara, S., Ali, N., & Bilal, M. (2022). Effect of different environmental conditions on the growth and development of Black Soldier Fly Larvae and its utilization in solid waste management and pollution mitigation. *Environmental Technology & Innovation*, 28, 102649. <https://doi.org/10.1016/j.eti.2022.102649>
- Singh, A., & Kumari, K. (2019). An inclusive approach for organic waste treatment and valorisation using Black Soldier Fly larvae: A review. *Journal of Environmental Management*, 251, 109569. <https://doi.org/10.1016/j.jenvman.2019.109569>
- Smetana, S., Schmitt, E., & Mathys, A. (2019). Sustainable use of *Hermetia illucens* insect biomass for feed and food: Attributional and consequential life cycle assessment. *Resources, Conservation and Recycling*, 144, 285-296. <https://doi.org/10.1016/j.resconrec.2019.01.042>
- Surendra, K. C., Olivier, R., Tomberlin, J. K., Jha, R., & Khanal, S. K. (2016). Bioconversion of Organic Wastes into Biodiesel and Animal Feed via Insect Farming. *Renewable Energy*, 98, 197-202. <https://doi.org/10.1016/j.renene.2016.03.022>
- Van, J. C. F., Tham, P. E., Lim, H. R., Khoo, K. S., Chang, J.-S., & Show, P. L. (2022). Integration of Internet-of-Things as sustainable smart farming technology for the rearing of black soldier fly to mitigate food waste. *Journal of the Taiwan Institute of Chemical Engineers*, 137, 104235. <https://doi.org/10.1016/j.jtice.2022.104235>
- Verra. (2024, 16 de abril). *VCS Standard v4.7*. Consultado el 26 de noviembre de 2025, desde <https://verra.org/wp-content/uploads/2024/04/VCS-Standard-v4.7-FINAL-4.15.24.pdf>
- Weichert, D., Link, P., Stoll, A., Rüping, S., Ihlenfeldt, S., & Wrobel, S. (2019). A Review of Machine Learning for the Optimization of Production Processes. *The International Journal of Advanced Manufacturing Technology*, 104, 1889-1902. <https://doi.org/10.1007/s00170-019-03988-5>
- Win, S. S., Ebner, J. H., Brownell, S. A., Pagano, S. S., Cruz-Diloné, P., & Trabold, T. A. (2018). Anaerobic digestion of black soldier fly larvae (BSFL) biomass as part of an integrated biorefinery. *Renewable Energy*, 127, 705-712. <https://doi.org/10.1016/j.renene.2018.04.093>
- WMO. (2025). *WMO Greenhouse Gas Bulletin No. 21: The State of Greenhouse Gases in the Atmosphere Based on Global Observations through 2024*. <https://wmo.int/publication-series/wmo-greenhouse-gas-bulletin-no-21>
- Yavari, A., Mirza, I. B., Bagha, H., Korala, H., Dia, H., Scifleet, P., Sargent, J., Tjung, C., & Shafiei, M. (2023). ArtEMon: Artificial Intelligence and Internet of Things Powered Greenhouse Gas Sensing for Real-Time Emissions Monitoring. *Sensors*, 23(18), 7971. <https://doi.org/10.3390/s23187971>